I1–I4 残差谱组织干预实验报告

1 I1–I4 的具体干预

以下 $E_t \in \mathbb{R}^{W \times d_\epsilon}$ 表示第 t 个读出时刻保存的白化残差窗口；W 是窗口内样本数，d_ϵ 是残差特征维度。每个干预都会把父窗口 E_t 改写为干预窗口 E'_t，再重新计算对应的残差信号 ψ_t。图中的 $\Delta\psi_t$ 定义为干预后信号与 Parent 信号之差：

$$\Delta\psi_t = \psi_t(E'_t) - \psi_t(E_t).$$

1.1 Parent：父残差

Parent 表示不做任何干预的原始父窗口：

$$E'_t = E_t.$$

它作为离线重算的参照，用来确认干预前的 ψ_t 与父训练日志一致。

1.2 I1：方向性低秩结构注入

I1 用来模拟残差集中到某个方向上的情况。代码先计算父窗口中心化协方差的最大特征向量 v_1，然后沿该方向注入一阶低秩扰动：

$$\eta'_i = \eta_i + a_i \cdot s_1 \cdot r_{\mathrm{rms}} \cdot v_1,$$

其中 $a_i \sim \mathcal{N}(0,1)$，当前 $s_1 = 1.0$。这里的 r_{rms} 是父窗口中心化白化残差的均方根半径：

$$r_{\mathrm{rms}} = \sqrt{\frac{1}{W}\sum_{i=1}^{W} \|\eta_i - \bar{\eta}_t\|_2^2}.$$

它用于把 I1 的方向性扰动缩放到与当前父残差窗口相匹配的量级，避免在不同阶段或不同潜变量维度下注入不可比较的固定幅度。如果 ψ_t 真的响应方向性谱凝聚，I1 应该使 ψ_t 明显升高。

1.3 I2：能量匹配各向同性扰动

I2 保持中心化残差总能量与父窗口一致，但把能量分散到随机方向。具体做法是生成高斯噪声 Z，中心化后按 Frobenius 范数缩放：

$$Z_c = Z - \bar{Z}, \qquad E'_t = Z_c \cdot \frac{\|E_t - \bar{E}_t\|_F}{\|Z_c\|_F}.$$

这样 I2 与父窗口具有相同量级的总能量，但缺少相干主方向。若 ψ_t 不是简单的能量指标，I2 不应像 I1 那样升高。

1.4 I3：逐样本范数保持的方向随机化

I3 保留每个样本的残差长度，但随机化方向。对每个样本生成随机单位方向 u_i，令

$$\eta_i' = \|\eta_i\|_2 u_i.$$

因此 I3 控制了逐样本残差幅度，只破坏跨样本方向协同。若 ψ_t 依赖方向组织，则 I3 会显著降低 ψ_t。

1.5 I4：统一缩放

I4 将整个白化残差窗口统一乘以缩放系数：

$$E_t' = s_4 E_t,$$

当前 $s_4 = 2.0$。它主要改变幅度，不改变方向结构。由于当前读出包含迹归一化，若没有跨入低能量分支，I4 理论上应基本保持 ψ_t 不变。

2 结果

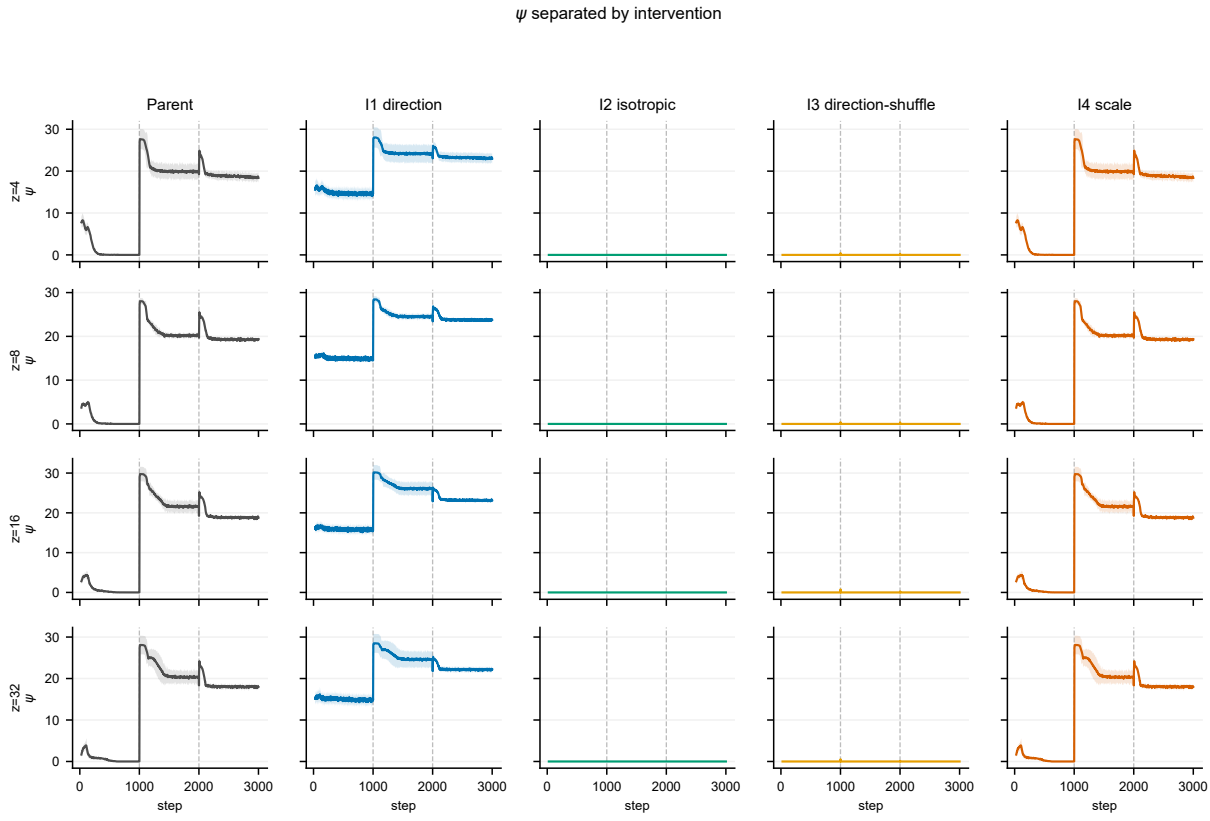


图 1: I1–I4 干预后的绝对 ψ_t 曲线。每一行对应一个潜变量维度 z，每一列对应一种干预；实线为三个种子的均值，阴影为标准差。虚线表示阶段切换位置。

图 1 显示，Parent 在阶段切换处出现明显的残差谱响应。I1 注入方向性低秩结构后，ψ_t 在大部分阶段保持较高水平，说明方向集中会增强信号。I2 和 I3 的 ψ_t 基本接近零，说明当残差方

向被各向同性化或随机化后，谱上端结构被破坏。I4 与 Parent 的形状高度接近，说明统一放大残差幅度并不会显著改变该读数。

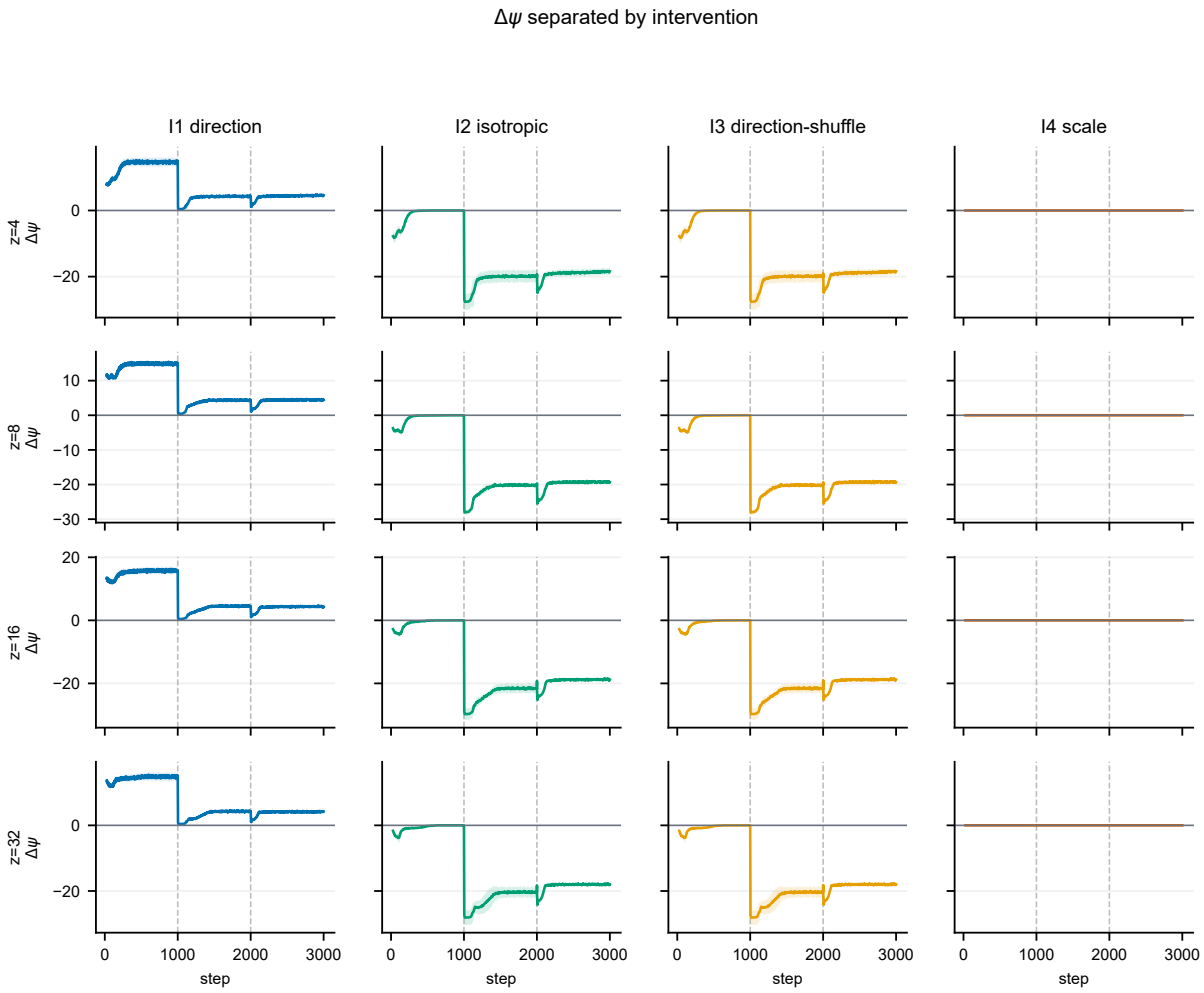


图 2: I1–I4 相对 Parent 的 $\Delta\psi_t$ 曲线。每一行对应一个潜变量维度 z，每一列对应一种干预；实线为三个种子的均值，阴影为标准差。

图 2 更直接展示了干预效应。I1 的 $\Delta\psi_t$ 整体为正，说明方向性结构注入会增加残差信号；I2 和 I3 的 $\Delta\psi_t$ 多数为负，尤其在阶段切换后下降明显，说明仅保留能量或范数但打散方向会削弱信号；I4 的 $\Delta\psi_t$ 接近零，符合迹归一化后对统一幅度变化不敏感的预期。

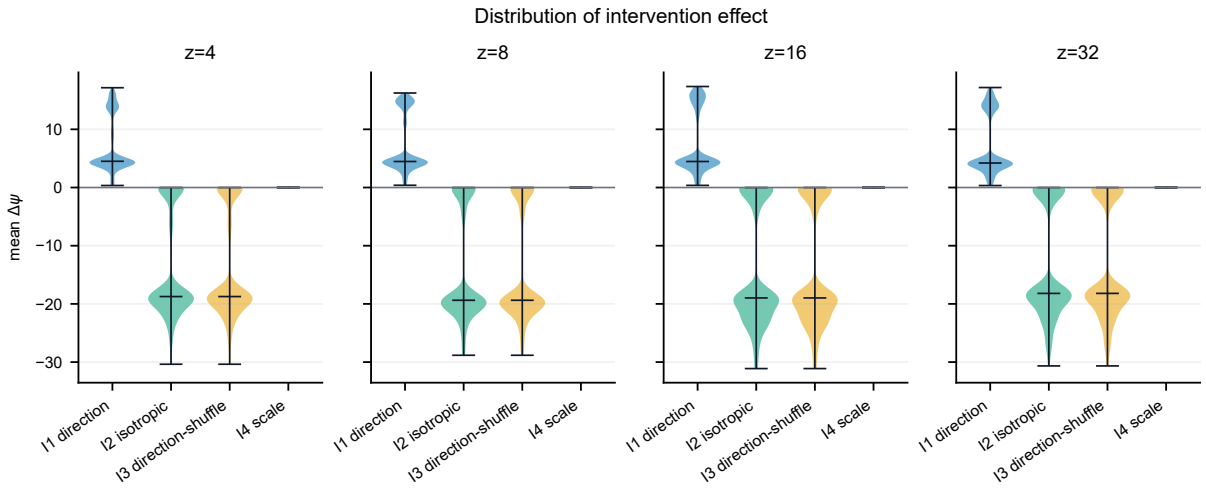


图 3: 各干预在所有窗口上的 $\Delta\psi_t$ 分布。每个小提琴图汇总对应维度下三个种子和全部记录窗口的干预效应。

图 3 从分布层面验证了上述趋势。I1 的分布主要位于零以上，I2 和 I3 主要位于零以下，I4 集中在零附近。整体来看，这组结果支持：ψ_t 主要响应残差的方向性谱组织，而不是单纯响应残差能量或幅度。