Residual geometry signals when representations should reorganize

Jun XXX[1*] and Coauthor YYY[1]

[1*]School/Department, University/Institute, City, Country.

*Corresponding author(s). E-mail(s): jun.xxx@university.edu;
Contributing authors: coauthor.yyy@university.edu;

当环境的数据生成结构发生变化时，学习系统必须保持有效。一个核心困难在于，学习者赖以组织经验的内部表征结构可能不再适合当前数据，但这种失配未必首先表现为误差大小的增加。许多人工系统将表征结构保持为固定形式，只调整连续参数，因而尚不清楚如何仅凭内部信号判断何时应当重新组织表征。这里我们表明，拟合残差的协方差几何提供了这样的信号。当分布变化改变潜在结构时，固定拓扑的潜变量模型会留下方向性残差；在本文考察的优化预算和容量范围内，这种方向性在延长训练和受控增加潜在容量后仍然存在。这种残差各向异性会先于下游性能下降而升高，也会先于常见的标量拟合质量诊断指标发生变化。通过将残差方向与残差幅度解耦的干预实验，我们表明该信号具有几何性，而不是误差大小的代理指标。在受控数据流和非平稳视觉基准上，该信号还可用于预测外部定义的失效事件，说明它不只是 **SOMA** 编辑回路中的内部变量。基于这一信号，我们提出 **Self-Organized Manifold Abstraction**，简称 **SOMA**。**SOMA** 通过拟合–复杂度目标，将连续适应与局部拓扑编辑耦合起来：只有当残差各向异性持续存在时，系统才会提出编辑；只有当这些编辑在短暂重新适应后降低该目标时，它们才会被保留。在没有变化点标签的情况下，**SOMA** 能够在受控流形数据流中追踪内在维度和局部表征粒度的变化；在非平稳视觉基准上，相对于匹配的固定拓扑基线和基于回放的基线，**SOMA** 将遗忘和累积适应成本分别降低 [**X**]% 和 [**Y**]%。这些结果表明，拟合残差不仅记录模型拟合得多差，也编码当前表征

组织是否仍然适用。残差几何因此可作为表征失效的早期、外部可检验诊断指标，并为学习系统判断何时需要重组表征提供一种原则。

Learning systems must remain effective when the structure of their environment changes, yet a learner's internal organization can become mismatched to new data before its error visibly grows—leaving open how a system could tell, from its own signals, when its representation should reorganize rather than merely be retrained. Here we show that the geometry of a model's fit residuals provides such a signal. When change alters the underlying structure of the data, models with fixed internal structure leave residuals concentrated along a few shared directions; within the training budget and capacity range examined here, neither longer training nor added capacity removes this directionality. It rises before performance degrades and before standard scalar error measures change, and interventions that separate the direction of residuals from their size show the signal to be geometric rather than a proxy for error magnitude. Because it also predicts failure events defined outside the model, it is not an artefact of any single system. Building on this signal, we introduce Self-Organized Manifold Abstraction (SOMA), which reorganizes its representation only when residual geometry warrants it and only when doing so improves a single fit–complexity objective; without change-point labels, SOMA recovers shifts in intrinsic dimensionality and local granularity and lowers forgetting and adaptation cost relative to fixed-structure and replay baselines. Residual geometry thus offers an early, externally testable indicator of representational failure—and a principle for when a representation should change.

学习系统通常需要在内部形成一套结构，用以组织经验并约束后续适应。这套结构决定了哪些变化能够被轻易吸收，哪些变化会反复表现为未解释的残差。当环境的数据生成结构保持近似稳定时，固定的表征组织通常足以支持有效适应；但在非平稳环境中，环境的数据生成结构可能发生改变，而不只是表层统计发生漂移。此时学习者面临一个基本问题：它如何仅凭自身信号判断，当前的表征组织是否已经不再适合当前数据？

这一问题在人工学习系统中尤为突出。许多系统在训练前固定表征结构，随后主要通过连续参数更新来适应变化。在持续学习与表征学习中，遗忘、适应成本升高与迁移脆弱等代价已有广泛观察，并通常通过经验回放、参数正则化、模块路由或显式任务标识加以缓解。这些方法可以稳定参数更新，但通常并不直接回答潜在结构何时应由学习者自身重新组织；即使结构可以改变，其时机也常由外部任务边界、验证损失或预设调度决定。因此一个更前置的问题仍未解决：学习者能否从自身的拟合残差中判断，问题已不只是参数是否训练充分，而是表征组织本身是否需要重组？

我们提出，这样的信号存在于残差的协方差几何中。通行做法将残差压缩为一个标量（例如重构误差或训练损失），并以其大小衡量模型拟合得多差。但当数据生成结构改变而模型内部结构保持固定时，未解释的变化未必首先表现为残差幅度增加，而可能表现为残差沿少数共同方向持续聚集。这种方向性说明，当前组织虽能降低总体误差，却仍难以吸收某一类新变化；这种持续的失配，正是当前表征格式开始失效的早期信号。

我们首先在底层结构受控、且变化点不向模型暴露的非平稳数据流中检验这一信号，并通过解耦残差方向与残差幅度的干预，表明它来自几何而非误差大小。随后我们在非平稳视觉基准上追问：在不依赖 SOMA 编辑回路的情况下，该信号能否预测外部定义的分布转变与下游性能持续下降。作为原理性验证，我们将这一信号付诸行动，构建 Self-Organized Manifold Abstraction（SOMA）：当残差几何持续指示当前组织难以吸收新变化时，系统提出局部表征重组，并仅当该重组在短暂再适应后降低同一拟合–复杂度目标时才予保留。

由此本文要确立的不是又一种可变容量方法，而是一条更一般的原则——拟合残差不仅记录模型拟合得多差，也编码当前表征组织是否仍然适用；读取这一几何结构，便为学习者判断何时应继续拟合、何时应重组表征，提供了一个内部且可外部检验的依据。

Relation to methods that change capacity, routing or structure. 稀疏 MoE[8–11]、模块化路由 [12, 13] 和参数高效适配器扩展 [14–17] 等方法也改变容量、路由或可用参数子空间。与这些方法相比，SOMA 关注的不是哪些参数子空间或模块被使用，而是潜在表征拓扑何时需要局部重组。在这些相关方法中，结构、路由或容量变化通常由任务边界、路由器、验证损失或预设调度决定；SOMA 则以残差协方差几何决定候选编辑的时机，并以同一拟合–复杂度目标决定编辑是否保留（系统性对照见 Extended Data Table S5）。

Fixed-topology adaptation leaves directional residuals. 我们首先追问，当数据的生成结构发生改变时，固定拓扑适配是否会留下难以吸收的方向性残差。如果固定拓扑模型在非平稳条件下的局限仅源于潜在容量或训练不足，那么扩大潜在维度或延长优化应显著削弱这一残差方向性。为检验这一可能，我们构造了一个受控非平稳数据流（Fig. 1a）：其底层流形依次经历 S^1、T^2 与局部分裂结构，且变化点不向模型暴露。从 S^1 到 T^2 的转变增加了内在维度，局部分裂阶段则改变了所需的表征粒度；这两类变化分别挑战潜在维度与局部表征粒度，不同于通常可由连续参数适配部分吸收的平滑漂移。

我们首先在该数据流上考察标准固定拓扑 VAE[2]。若当前拓扑难以吸收某类变化，未被解释的部分预期会沿少数共同方向持续出现，在残差的协方差结构中留下方向性痕迹。我们用残差各向异性 Ξ_t 量化这一方向性；Ξ_t 越高，表示残差协方差越集中于少数主方向（定义见 Methods）。固定拓扑模型在每个阶段内均能降低重构误差，但在本文考察的训练预算内，阶段切换后残差仍保留持续的方向性成分（Ξ_t 升高；Fig. 1b）。这表明，标量重构误差的下降并不意味着未解释变化已被当前拓扑充分吸收。

这种持续性不能仅由潜在容量或优化预算解释。将潜在维度扩大至 4× 的过参数化变体仍保留持续的方向性残差；在一个延长训练、compute 预算显著放大的固定拓扑对照（CM-fix；其总预算与后文自组织模型匹配，见 Methods）下，方向性依然存在（Fig. 1c），说明在所测预算范围内，这一现象既不能由容量不足、也不能由训练不足解释。这一方向性残差并非无害的数值现象，而是与下游表征能力的损失同步发生。将在线记录的 Ξ_t 与冻结编码器线性探针准确率置于同一时间轴上比较（Fig. 1d）：每次结构转变之后，Ξ_t 升高的同一时刻下游探针准确率随之下降，且二者在该阶段内均未回到转变前水平。这种同步表明，残差几何所标记的并不是损失曲线可见的拟合波动，而是一种伴随实际性能损失的结构层面失配。因此，这些方向性残差指向一种结构层面的失配，而不是可以靠更大模型或更长训练消除的拟合问题。这一失配既然不能由更大模型或更长训练消除，就引出一个独立于任何重组机制的问题：残差的这种几何结构，本身能否作为表征失效的信号？

Residual geometry anticipates representational failure. 在观察到持续的方向性残差后，我们在将其用于结构重组之前，先检验这种几何结构本身——独立于任何拓扑编辑机制——是否承载关于表征失效的诊断信息。为成为有用的诊断信号，残差几何应当能够预测在残差度量之外定义的事件，并且优于仅反映残

图 1 Fixed-topology adaptation leaves directional residuals. a, Controlled non-stationary stream. The underlying manifold transitions through S^1 (d^{int}=1), T^2 (d^{int}=2) and a locally split structure with increased representational granularity; phase boundaries (dashed) are not exposed to the model. **b,** Under fixed-topology adaptation, within-phase reconstruction error decreases (light curve, right axis) while residual anisotropy Ξ_t rises after each phase boundary and persists (dark curve, left axis); an eigenvalue-based measure of directional concentration in the sliding-window residual covariance (Methods). The contrast shows that a falling scalar error does not imply the directional component has been absorbed. Lines, mean across n=10 seeds; shading, s.e.m. **c,** Capacity and compute controls. Phase-3 Ξ_t remains elevated across latent-capacity variants, including a 4× over-parameterized model, and under a compute-matched fixed-topology control (CM-fix; Methods), indicating the directional component is not explained by capacity or training budget within the tested range. Bars, mean ± s.e.m. (n=10). **d,** On the same stream under fixed-topology adaptation, residual anisotropy Ξ_t (dark, left axis) and downstream linear-probe accuracy (light, right axis) share a common time axis; phase boundaries (dashed) are not exposed to the model. After each boundary Ξ_t rises while probe accuracy drops, and neither returns to its pre-transition level within the phase, showing that the directional residual coincides with an unrecovered downstream cost. Lines, mean across n=10 seeds; shading, s.e.m.

差大小或总体拟合状态的标量诊断。因此，本节所有分析均使用固定拓扑模型的残差，不执行任何拓扑重组。

在受控数据流上，我们将真实结构转变时刻和独立测得的下游线性探针准确率持续下降作为外部事件。我们比较 Ξ_t 与预先指定的标量拟合诊断对这些事件的 AUROC 和 lead time；标量诊断涵盖直接的残差幅度信号（重构误差、残差 ℓ_2 范数）与更一般的拟合诊断（ELBO 变化、D_{KL} 变化）。对真实结构转变的检测，Ξ_t 的 AUROC 高于预先指定标量诊断集合中的最佳基线；对探针准确率下降的预测，Ξ_t 的中位 lead time 更早，即在标量诊断变化之前更多步即已升高（n=10 个种子，双侧配对检验；统计检验、效应量与 95% 置信区间见 Methods 与 Source Data；Fig. 2b,c）。

相关性本身无法区分这种预测力来自残差的几何结构还是其幅度变化。因此，我们对固定拓扑模型的残差施加四组受控干预（Fig. 2d–f）。注入持续方向性的合成残差（I1）提高 Ξ_t；而注入总残差能量与 I1 匹配的各向同性噪声（I2），即使将重构误差抬升到与 I1 相当的水平，也并未提高 Ξ_t。保持每个残差范数但随机旋转其方向（I3）显著降低 Ξ_t，表明仅保留残差幅度不足以维持该信号。最具决定性的是整体缩放（I4）：将所有残差幅度统一放大使重构误差按比例升高，Ξ_t 却基本不变——这与 Ξ_t 的尺度归一化定义一致（Methods），排除了“整体残差能量增加即可解释 Ξ_t 升高”的可能。I3（打乱方向）与 I4（整体缩放）共同将几何成分与幅度成分作了系统性隔离，表明 Ξ_t 依赖的是跨样本方向一致性，而非残差能量本身。

在底层拓扑和结构变化时刻均未知的 CLEAR 与 CLOC 上，我们使用同一固定拓扑模型被动监测残差几何。与受控流不同，此处无可解析的真实变点，我们改用评估协议预先定义的分布转变和冻结探针准确率的持续下降作为外部事件（定

图 2 Residual geometry anticipates representational failure. All panels use residuals of a fixed-topology model; no topology edits are performed. **a,** External events and passive-monitoring setup: ground-truth structural transitions and independently measured downstream linear-probe degradation (Methods). **b,** Detection of external events: AUROC of Ξ_t versus pre-specified scalar diagnostics (reconstruction error, residual ℓ_2 norm, ELBO change, D_{KL} change). **c,** Lead time of Ξ_t relative to the strongest scalar diagnostic. **b,c**: n=10 seeds; two-sided paired test, effect sizes and 95% CIs in Source Data. **d–f,** Causal interventions separating geometry from magnitude: directional injection (I1) and energy-matched isotropic noise (I2) (**d**); norm-preserving random rotation of residuals (I3) (**e**); and uniform magnitude scaling (I4), which raises reconstruction error while leaving Ξ_t essentially unchanged, consistent with its scale-normalized definition (**f**). Bars, mean ± s.e.m. (n=10). **g,** Passive monitoring on the real streams. On CLEAR and CLOC, AUROC and median lead time of Ξ_t for externally defined events exceed those of the best pre-specified scalar diagnostic, using the same fixed-topology model with no topology edits (n=10 seeds; significance and false-alarm statistics in Source Data).

义见 Methods）。Ξ_t 的 AUROC 为 **[AUROC-Xi-CLEAR]** 与 **[AUROC-Xi-CLOC]**，中位 lead time 为 **[LEAD-Xi-CLEAR]** 与 **[LEAD-Xi-CLOC]** 步，在两条数据流上均高于预先指定标量诊断集合中的最佳基线（Fig. 2g；差异显著性、置信区间与误报统计见 Source Data）。

因此，在所测模型范围内，残差几何已经满足独立诊断信号的两个条件：它预测外部定义的失效事件，且其预测能力来自方向性结构而非残差幅度。这引出下一个问题：学习系统能否在这一信号持续指示失配时据其重组自身？

Residual geometry drives self-limited topology edits. 我们接着检验，这一诊断信号能否被付诸行动——通过将它与局部拓扑编辑耦合，使系统仅在残差几何持续指示失配时才提出结构重组。

为此我们构建 Self-Organized Manifold Abstraction（SOMA）。SOMA 将连续参数适配与离散局部拓扑编辑耦合在同一拟合–复杂度目标 $\mathcal{V}$ 下（定义见 Methods）。当残差几何在一个时间窗口内持续指示失配时，系统提出候选编辑；候选编辑只有在短程再适配后降低 $\mathcal{V}$（$\Delta\mathcal{V} < 0$）时才被保留。因此，残差几何决定编辑的时机，统一目标决定编辑的接受；二者均不依赖外部变化点标注或预设调度。

在 §1 的同一受控数据流上，SOMA 在无任何变化点标注的情况下追踪了底层结构变化：潜在内在维度在 $S^1 \to T^2$ 转变后由 1 增至 2，局部表征粒度在分裂阶段由 K=1 增至 K=4 （Fig. 3b）。每次被接受的编辑之后，此前升高的残差各向异性 Ξ_t 回落（Fig. 3c），下游线性探针准确率随之恢复（Fig. 3d）。这表明，驱动 R2 中诊断信号的同一方向性结构，正是被这些局部拓扑编辑所消除的对象。

关键在于，仅仅“允许结构改变”并不足以解释这一结果；收益取决于候选编辑是否在残差几何指示失配时提出。我们以四个共享 SOMA 局部算子、参数继承、短程再适配预算与 $\Delta\mathcal{V} < 0$ 接受准则、仅触发方式不同的对照系统检验这一点（Fig. 3e,f）。这些对照共同表明：编辑能力本身不足以解释 SOMA 的恢复，收

图 3 Residual geometry drives self-limited topology edits. a, SOMA closed loop. Continuous adaptation proceeds under the current topology; persistent residual anisotropy triggers proposal of local edits, retained only if they reduce the fit–complexity objective $\mathcal{V}$ after brief re-adaptation. Residual geometry gates *when* an edit is proposed; $\Delta\mathcal{V}<0$ gates *whether* it is retained. **b,** Self-organized evolution of structural state on the controlled stream: the common-manifold dimension d_c tracks the $S^1 \to T^2$ change and the node count K tracks increased granularity in the split phase. **c,** After each accepted edit (triangles), the previously elevated Ξ_t returns toward baseline (trigger level G_ϕ, dashed). Lines, mean across n=10 seeds; shading, s.e.m. **d,** Downstream linear-probe accuracy approaches its pre-transition level after accepted edits under SOMA, but does so more slowly or incompletely under the fixed-schedule and magnitude-trigger (M-trig) controls and under fixed-topology disentanglement baselines (β-VAE[3], FactorVAE[18]). **e,** Outcomes under matched trigger controls that share SOMA's operators, parameter inheritance, re-adaptation budget and $\Delta\mathcal{V}<0$ acceptance, differing only in trigger: recovery time, residual anisotropy and probe accuracy for fixed-schedule, M-trig, candidate-matched random timing (R-trig) and oracle change-point (O-cp). Only Ξ_t-triggering matches the O-cp reference. **f,** Time-aligned edit fraction (TAEF; Methods): fraction of accepted edits within $\pm\Delta_{\mathrm{TAEF}}$ steps of a ground-truth boundary; edits are enriched near transitions under Ξ_t-triggering but not under M-trig or R-trig. Bars, mean ± s.e.m. (n=10).

益取决于编辑时机是否与残差几何对齐。固定调度对照在预设时刻而非残差几何峰值附近提出编辑；尽管编辑能力相同，残差方向性未被有效化解，探针准确率也未充分恢复。以残差幅度而非几何触发的对照（M-trig）与真实结构变化的时间对齐较差，确认触发信号必须包含方向性几何，而不只是误差大小，这与 R2 的干预结论一致。以候选编辑数匹配但随机择时的对照（R-trig）也降低了 TAEF 与恢复水平，排除了“编辑次数本身”解释收益的可能。相对于由真实结构转变时刻触发的 oracle 对照（O-cp），残差几何触发达到相近的恢复水平（差距见 Source Data），表明该内部信号捕捉到了结构重组所需的大部分时机信息。我们以触发对齐的编辑及时性（TAEF；Methods）量化上述差异；Ξ_t 触发在该指标上显著优于幅度与随机触发（Fig. 3f；n=10 个种子，双侧配对检验；统计量见 Source Data）。与该指标一致，被接受的编辑中有 $[X]$% 落入真实结构转变后 $[N]$ 步以内（Extended Data Fig. S6），直接量化了编辑与结构转变的时间对齐。

在整段数据流上，被接受的累积编辑数呈次线性增长，说明结构增长受到复杂度项约束，而非随数据无界扩张（完整的自限性分析与工作区间见 Extended Data）。

在生成结构已知、可解析验证的受控流上确立这一机制后，我们接着检验它在没有可解析真实结构的自然非平稳流上是否同样有效。

Self-organized topology changes the cost structure of adaptation. 我们在 CLEAR 与 CLOC 这两个公开非平稳视觉基准上检验上述机制，其中底层结构不可解析，且变化点不向模型暴露。我们关注的不是渐近平均准确率，而是分布变化前后适配的动力学与代价结构。

我们将 SOMA 与三类基线比较（Fig. 4a）：固定拓扑自监督表征学习器（SimCLR[21]、DINO[22]），用于检验高质量固定表征是否足以应对结构变化；代表性持

续学习方法（ER[23]、A-GEM[24]、DER++[25]），用于检验是否只需更好的遗忘缓解；以及一个在预设时刻执行相同局部编辑的固定调度结构编辑器，用于检验是否只需可变容量、而不需残差几何决定编辑时机。所有方法采用相同的编码器–解码器骨干与数据访问预算；评估时每隔固定步数冻结编码器训练线性探针，报告平均准确率、遗忘、后向迁移、恢复时间与累积适配成本（完整协议见 Methods）。

在两条数据流上，SOMA 保持了与最强固定拓扑基线相当的最终平均线性探针准确率（[X1]% 与 [X2]%；差异未达显著；Fig. 4b），因此后续在代价结构上的差异不能归因于渐近性能的不同；在线、无任务标识、回放容量受限的设置下，显式持续学习基线的准确率较低（[Z1]–[Z2]%）。差异出现在适配的代价结构上：在每次分布变化之后，SOMA 的下游准确率下降更浅，以更少的更新步数达到预定义恢复阈值（默认 η_{rec}=0.95 倍切换前峰值；Methods），后向迁移（BWT）在两条数据流上均高于主要非 SOMA 基线，而固定拓扑自监督与回放基线的 BWT 明显为负（Fig. 4b,c）。相对于固定拓扑与基于回放的基线，SOMA 将遗忘降低 [Q]%（n=10 个种子，双侧 Wilcoxon 符号秩配对检验，FDR 校正；效应量与 95% 置信区间见 Source Data）。作为适配努力的次级汇总指标，CAC 相对于预先指定的回放基线在 CLEAR 与 CLOC 上分别降低 [Q]% 与 [Q2]%（Fig. 4c,d；权重选择与敏感性分析见 Methods 及 Supplementary Table S2）。固定调度结构编辑器尽管拥有相同的编辑能力，其恢复时间和 CAC 均未达到 SOMA 水平，再次表明收益来自残差几何决定的时机，而非可变容量本身。

真实流上的机制特征与 §1–§3 一致：残差各向异性在评估协议标记的分布转变之前或附近升高，被接受的拓扑编辑随后发生，其后 Ξ_t 回落（Fig. 4e），表明 R2 与 §3 在受控流中刻画的同一机制，在底层结构未知的真实数据上依然运作。被接受的累积编辑数在真实流上仍呈次线性趋势，说明复杂度约束没有在真实数据上失效。

组件消融支持这一归因（Extended Data Table S4）：单独去除复杂度先验、几何提案分数或统一目标中的辅助项，均削弱恢复时间、CAC 或编辑稳定性。其中辅助项主要稳定共性子空间的潜在分工，而复杂度先验与几何提案分数是稀疏、与事件对齐且低成本的结构编辑所必需的（完整数值见 Extended Data Table S4）。没有任一单独组件能复现完整效果，表明真实流收益依赖于“几何决定时机、统一目标筛选接受、复杂度项限制增长”的耦合。

综合四节结果，同一个由残差几何读出的信号既能在固定拓扑模型中预示表征失效，又能在非平稳视觉流中为表征重组的时机提供依据；SOMA 在训练与编

图 4 Self-organized topology changes the cost structure of adaptation. a, Protocol on CLEAR and CLOC and the three baseline families: fixed-topology self-supervised learners (SimCLR, DINO), representative continual-learning methods (ER, A-GEM, DER++) and a fixed-schedule structural editor. **b,** Final mean linear-probe accuracy is comparable between SOMA and the strongest fixed-topology baseline (difference not significant), so the later differences below are not attributable to asymptotic performance. **c,** Adaptation dynamics around each shift: depth of accuracy drop, steps to a pre-defined recovery threshold, and backward transfer (BWT). **d,** Cumulative adaptation cost (CAC), a secondary summary of adaptation effort (weight sensitivity in Supplementary Table S2). **e,** On the real streams, Ξ_t rises around protocol-marked shifts, accepted edits follow, and Ξ_t then declines; the accepted-edit count grows sublinearly. **b–e**: n=10 seeds; two-sided paired test, statistics in Source Data.

辑过程中不使用变化点标注。这指向一个超越具体系统的问题：拟合残差的几何结构能在多大范围内充当学习系统重组自身的内部依据。

讨论

我们的结果改变了在非平稳学习中应如何解读残差。标准做法是把残差压缩成一个标量——重构误差、ELBO 或训练损失——作为拟合优度的度量。我们表明这种概括可能并不完整：当数据的生成结构发生变化时，固定表示难以吸收的那部分变异，可能并不只是表现为更大的误差，而是表现为集中在少数几个共享方向上的残差。在允许 SOMA 采取行动之前，这种残差各向异性的上升早于本文所测量的标量拟合诊断和下游性能退化（图 2b,c）；而因果干预进一步表明，具有预测性的信息由残差的方向、而非其大小所承载（图 2d–f）。因此，残差同时携带两类信息：一是大小，刻画瞬时的失拟程度；二是协方差几何，指示当前的表示格式是否正变得不再适用。

SOMA 给出了一个原理验证，说明这一信号是可以被加以利用的。它通过一个共享的拟合—复杂度目标，将连续的参数自适应与离散的结构重组耦合在一起：残差几何决定何时提出候选编辑，而该目标决定这些编辑是否被保留。这种耦合使结构变化具有自限性——编辑是稀疏的、与事件对齐的，且被接受的编辑累计数量随数据流长度呈次线性增长（见扩展数据）。更广泛地看，这一结果提示：参数学习与表示组织不必交由彼此分离的过程来掌管；二者可以由同一个目标来协调，而残差几何则为其提供时机信号。

这些结论也受到若干局限的约束。第一，我们的证据来自本文所研究的固定拓扑潜变量模型。同样的方向性信号是否也会在独立训练的架构、更大规模的模型以及其他模态中先于表示失效出现，是本工作提出的核心开放问题。第二，当数据中含有可由紧凑的潜在组织所表达、且可复用的共有结构时，SOMA 最为有用；而当有用的结构高度分散、或难以紧凑地复用时，局部重组带来的收益可能较为有限。此外，我们的理论只确立了逐次编辑意义下的下降性，而非全局最优

性，最终得到的结构仍依赖于路径。最后，尽管与生物结构可塑性的类比 [31] 启发了本工作的部分内容，但 SOMA 并不是对这类过程的机理模型。

本工作所确立的东西，比一套完整的学习系统更窄，又比单一的基准结果更宽：拟合残差的几何所携带的信息，不仅关乎当前拟合得有多好，更关乎表示应当在何时发生改变。这使残差几何有望成为表示重组的一个内部判据候选，而其普适性现在尚需在不同的模型族、规模与模态上加以检验。

References

[1] Friston, K. The free-energy principle: a unified brain theory? *Nat. Rev. Neurosci.* **11**, 127–138 (2010).

[2] Kingma, D. P. & Welling, M. Auto-encoding variational Bayes. In *Proc. Int. Conf. Learning Representations* (ICLR, 2014).

[3] Higgins, I. *et al.* β-VAE: learning basic visual concepts with a constrained variational framework. In *Proc. Int. Conf. Learning Representations* (ICLR, 2017).

[4] Chen, R. T. Q., Li, X., Grosse, R. B. & Duvenaud, D. K. Isolating sources of disentanglement in variational autoencoders. *Adv. Neural Inf. Process. Syst.* **31** (2018).

[5] Fritzke, B. A growing neural gas network learns topologies. *Adv. Neural Inf. Process. Syst.* **7**, 625–632 (1995).

[6] Kohonen, T. Self-organized formation of topologically correct feature maps. *Biol. Cybern.* **43**, 59–69 (1982).

[7] Antoniak, C. E. Mixtures of Dirichlet processes with applications to Bayesian nonparametric problems. *Ann. Stat.* **2**, 1152–1174 (1974).

[8] Shazeer, N. *et al.* Outrageously large neural networks: the sparsely-gated mixture-of-experts layer. In *Proc. Int. Conf. Learning Representations* (ICLR) (2017).

[9] Fedus, W., Zoph, B. & Shazeer, N. Switch transformers: scaling to trillion parameter models with simple and efficient sparsity. *J. Mach. Learn. Res.* **23**(120), 1–39 (2022).

[10] Jiang, A. Q. *et al.* Mixtral of experts. Preprint at https://arxiv.org/abs/2401.04088 (2024).

[11] Dai, D. *et al.* DeepSeekMoE: towards ultimate expert specialization in mixture-of-experts language models. Preprint at https://arxiv.org/abs/2401.06066 (2024).

[12] Rosenbaum, C., Klinger, T. & Riemer, M. Routing networks: adaptive selection of non-linear functions for multi-task learning. In *Proc. Int. Conf. Learning Representations* (ICLR) (2018).

[13] Pfeiffer, J., Ruder, S., Vulić, I. & Ponti, E. M. Modular deep learning. *Trans. Mach. Learn. Res.* (2023).

[14] Hu, E. J. *et al.* LoRA: low-rank adaptation of large language models. In *Proc. Int. Conf. Learning Representations* (ICLR) (2022).

[15] Wang, X. *et al.* Orthogonal subspace learning for language model continual learning. In *Findings of the Association for Computational Linguistics: EMNLP 2023* 10658–10671 (2023).

[16] Liang, Y.-S. & Li, W.-J. InfLoRA: interference-free low-rank adaptation for continual learning. In *Proc. IEEE Conf. Computer Vision and Pattern Recognition* (CVPR) 23638–23647 (2024).

[17] Wang, X. & Zhu, W. Advances in neural architecture search. *Natl Sci. Rev.* **11**, nwae282 (2024).

[18] Kim, H. & Mnih, A. Disentangling by factorising. In *Proc. Int. Conf. Machine Learning* (ICML) 2649–2658 (2018).

[19] Lin, Z., Shi, J., Pathak, D. & Ramanan, D. The CLEAR benchmark: continual LEArning on real-world imagery. In *Adv. Neural Inf. Process. Syst.* **34**,

Datasets and Benchmarks Track (2021).

[20] Cai, Z., Sener, O. & Koltun, V. Online continual learning with natural distribution shifts: an empirical study with visual data. In *Proc. IEEE Int. Conf. Computer Vision* (ICCV) 8281–8290 (2021).

[21] Chen, T., Kornblith, S., Norouzi, M. & Hinton, G. A simple framework for contrastive learning of visual representations. In *Proc. Int. Conf. Machine Learning* (ICML) 1597–1607 (2020).

[22] Caron, M. *et al.* Emerging properties in self-supervised vision transformers. In *Proc. IEEE Int. Conf. Computer Vision* (ICCV) 9650–9660 (2021).

[23] Chaudhry, A. *et al.* On tiny episodic memories in continual learning. Preprint at https://arxiv.org/abs/1902.10486 (2019).

[24] Chaudhry, A., Ranzato, M. A., Rohrbach, M. & Elhoseiny, M. Efficient lifelong learning with A-GEM. In *Proc. Int. Conf. Learning Representations* (ICLR) (2019).

[25] Buzzega, P., Boschini, M., Porrello, A., Abati, D. & Calderara, S. Dark experience for general continual learning: a strong, simple baseline. *Adv. Neural Inf. Process. Syst.* **33**, 15920–15930 (2020).

[26] Quinn, P. C., Eimas, P. D. & Rosenkrantz, S. L. Evidence for representations of perceptually similar natural categories by 3-month-old and 4-month-old infants. *Perception* **22**, 463–475 (1993).

[27] O'Doherty, C. *et al.* Infants have rich visual categories in ventrotemporal cortex at 2 months of age. *Nat. Neurosci.* **29**, 693–702 (2026).

[28] Winke, N., Lüthi, A., Herry, C. & Jercog, D. Prefrontal neural geometry of learned cues guides motivated behaviours. *Nature* **651**, 164–173 (2026).

[29] Greco, A., Moser, J., Preissl, H. & Siegel, M. Predictive learning shapes the representational geometry of the human brain. *Nat. Commun.* **15**, 9670 (2024).

[30] Isomura, T. & Friston, K. In vitro neural networks minimise variational free energy. *Sci. Rep.* **8**, 16926 (2018).

[31] Holtmaat, A. & Svoboda, K. Experience-dependent structural synaptic plasticity in the mammalian brain. *Nat. Rev. Neurosci.* **10**, 647–658 (2009).

[32] Lopez-Paz, D. & Ranzato, M. A. Gradient episodic memory for continual learning. *Adv. Neural Inf. Process. Syst.* **30**, 6467–6476 (2017).

[33] Gondal, M. W. *et al.* On the transfer of inductive bias from simulation to the real world: a new disentanglement dataset. *Adv. Neural Inf. Process. Syst.* **32**, 15708–15718 (2019).

[34] Eastwood, C. & Williams, C. K. I. A framework for the quantitative evaluation of disentangled representations. In *Proc. Int. Conf. Learning Representations* (ICLR) (2018).

[35] Kumar, A., Sattigeri, P. & Balakrishnan, A. Variational inference of disentangled latent concepts from unlabeled observations. In *Proc. Int. Conf. Learning Representations* (ICLR) (2018).

[36] Loshchilov, I. & Hutter, F. Decoupled weight decay regularization. In *Proc. Int. Conf. Learning Representations* (ICLR) (2019).

[37] Kraskov, A., Stögbauer, H. & Grassberger, P. Estimating mutual information. *Phys. Rev. E* **69**, 066138 (2004).

Methods

我们将残差各向异性 Ξ_t 定义为一个模型外部测量量：它由模型残差计算得到，但不是某一特定模型或结构编辑机制的内部变量；对固定拓扑的潜变量模型或编码–解码模型均可事后或在线计算，且不预设特定的后验族、先验族或结构编辑机制。我们首先在受控与自然非平稳数据流上刻画 Ξ_t，检验其能否在外部定义的表征失效发生之前给出预警；随后才引入 SOMA，说明其如何利用这一经过验证的信号提出并接受局部结构编辑。因此，Ξ_t 独立于 SOMA 被定义和验证，并非由其编辑回路反向给出。

推断与生成模型、结构诱导先验与辅助正则项、局部编辑算子及其参数继承规则、接受准则的自限性与收敛性、Ξ_t 的替代定义与稳健性、相图判据、数据流生成、基准协议、超参数与算力见 Supplementary Notes 1–8。

Residual anisotropy: a diagnostic of residual geometry

残差各向异性 Ξ_t 是一个模型外部诊断量，可由固定拓扑潜变量模型或编码–解码模型的残差特征事后或在线计算，不要求特定后验族、先验族或结构编辑机制。本文先独立定义并验证 Ξ_t，再考察 SOMA 如何利用该信号进行结构重组。

许多常见残差诊断将未解释变化压缩为标量幅度，例如重构误差或残差范数，用以刻画模型的拟合误差大小。Ξ_t 则量化未解释变化在残差子空间中的方向集中程度，提供一类与残差幅度互补的结构性信息。对一个将观测 o_t 映射为重构或预测均值 $\hat{o}_t$ 的模型，定义残差特征

$$\boldsymbol{\epsilon}_t = h(o_t) - h(\hat{o}_t) \in \mathbb{R}^{d_\epsilon}, \tag{1}$$

其中同一读出映射 h 可取恒等映射、固定特征提取器或模型内部表征读出。主实验默认 $h = \mathrm{id}$，即在观测空间计算残差；尺度不变性均相对于所选残差特征空间定义。对图像流，同一定义另以不参与当前模型训练的固定特征读出 h 评估，以确认该信号并非像素级残差的伪迹；该替代选择与其余残差空间的结果定性一致，见 Supplementary Note 4。

在最近 W 个残差特征构成的滑动窗口上，估计去均值样本协方差矩阵 $\widehat{\Sigma}_t$。取其按降序排列的前 $r_\Sigma \triangleq \min(d_\epsilon, W-1)$ 个特征值，并将数值误差产生的极小负值截断为零。当 $\mathrm{tr}(\widehat{\Sigma}_t) > \eta_{\mathrm{floor}}$ 时，按特征值之和归一化得谱分布 $\{\tilde{\lambda}_{t,i}\}$，并将残差各向异性定义为归一化谱熵的反向变换：

$$\Xi_t \triangleq 1 - \frac{H_t}{\log r_\Sigma}, \qquad H_t = -\sum_{i=1}^{r_\Sigma} \tilde{\lambda}_{t,i} \log \tilde{\lambda}_{t,i}, \tag{2}$$

其中约定 $0 \log 0 = 0$。当 $\mathrm{tr}(\widehat{\Sigma}_t) \le \eta_{\mathrm{floor}}$ 时，令 $\Xi_t = 0$；该约定表示缺乏可靠的方向性残差信号，而非将低能量残差解释为真正各向同性。本文所有实验设置均满足 $r_\Sigma > 1$；退化的一维残差情形不用于各向异性估计。

由谱熵归一化与低能量约定，$\Xi_t \in [0, 1]$。$\Xi_t \to 0$ 表示在窗口所支撑的残差子空间上谱接近均匀，$\Xi_t \to 1$ 表示残差方差集中于单一主导方向。由于 $\{\tilde{\lambda}_{t,i}\}$ 经归

一化构成概率分布，Ξ_t 仅取决于残差协方差谱的形状，而与其整体尺度无关；因此，除低能量阈值约定外，Ξ_t 对非零残差整体缩放 $\boldsymbol{\epsilon}_t \mapsto k\boldsymbol{\epsilon}_t$ 保持不变。

窗口长度 W 在所有模型、诊断量与数据流上保持固定，并仅通过独立校准流预先确定；该校准过程不使用评估流中的事件标签、下游探针结果或模型编辑结果。因此，Ξ_t 与全部标量诊断均在相同时间分辨率下估计，保证后续 lead-time 比较不受窗口选择影响。W、η_{floor} 的默认取值，基于其他特征值统计量的替代定义（顶特征值占比、阈值化有效秩等）及上述各项的敏感性分析见 Supplementary Note 4。

Controlled non-stationary manifold stream and fixed-topology controls

本节定义 Fig. 1 所用的受控非平稳数据流及其固定拓扑对照。同一设置也用于后续残差几何的外部验证，以区分需要潜在拓扑调整的结构变化与可由连续参数更新、更大容量或更长训练预算吸收的非拓扑变化。

潜在结构

数据流分三个相继阶段。底层结构依次为：单一圆周 S^1（内在维度 d^{int}=1）；环面 T^2（d^{int}=2），相对前一阶段新增一个独立变化因子；以及局部分裂结构，它保留 T^2 的全局坐标，但在局部区域引入 K^{int}=4 个可分辨子组。两次阶段转换提出两种不同性质的表征需求：由 S^1 到 T^2 要求增加全局坐标维度，由 T^2 到局部分裂则要求在坐标维度不变的前提下提高局部表征粒度。每一时刻从当前阶段的潜在支持上采样一点，经跨阶段固定的非线性渲染映射 Φ 得到像素观测 o_t，使阶段间差异主要由底层结构变化决定，而非由渲染过程变化引入。Φ 的参数化、局部分裂的子组定义、各阶段的采样分布与向模型暴露内容的完整清单见 Supplementary Note 6。

时间线与暴露

三阶段依次持续 T_1, T_2, T_3 步，在线数据暴露总步数 $T = T_1+T_2+T_3$，即数据流长度。真实阶段边界由数据流生成器记录，但不以任何形式向模型暴露；训练与任何在线决策均不使用变化点、阶段标识或阶段顺序。这些信息仅用于离线评估与作图标注。阶段长度的预扫描判据与取值见 Supplementary Note 6。

固定拓扑模型与对照

除显式说明的容量、正则项与计算预算差异外，在该流上比较的模型共享相同的编码–解码骨干、优化器与在线数据暴露步数 T。固定拓扑控制组用于检验：在仅更新连续参数、不改变表征拓扑的前提下，模型能否吸收上述阶段变化。该组包含初始潜在维度匹配的固定拓扑 VAE[2]、潜在维度为其 4× 的高容量 VAE（容量对照）、β-VAE[3] 与 FactorVAE[18]（其 β 与总相关权重见 Supplementary Table S2）。

我们另设计算匹配的固定拓扑对照 CM-fix。它不执行任何拓扑编辑；主分析中，其总计算预算与含编辑模型匹配，包括后者用于候选再适配的预算。为检验结论对优化预算的敏感性，我们还在不增加可见样本、不暴露阶段边界的条件下，将连续更新预算扩展至编辑模型预算的 $[1, 3]$ 倍。若在这些追加预算下仍观察到持续升高的 Ξ_t，则训练预算不足不能充分解释该现象（算力核算见 Supplementary Note 8）。结构编辑类对照也在同一数据流上运行；因其定义依赖 SOMA 的局部算子与接受准则，具体设置在 SOMA 机制和相应对照实验中给出。

报告的量

该流上报告三类量：残差各向异性 Ξ_t、冻结编码器线性探针准确率（分类目标由底层坐标的固定分箱构造，标签仅用于离线探针训练与评估，不参与在线模型更新），以及拓扑演化（包括结构规模、结构维度及编辑事件时间戳）。指标的完整定义与统计协议见 *Evaluation metrics, statistical analysis and reproducibility*；分箱规则与记录格式见 Supplementary Note 6。

External validation of residual geometry by prediction and controlled perturbation

为评估残差各向异性 Ξ_t 是否提供模型外部的预测信息，本节在固定拓扑 VAE 上计算 Ξ_t，全程不执行拓扑编辑，也不调用 SOMA。所评估事件在不使用 Ξ_t、残差几何或 SOMA 输出的条件下定义，其阈值与持续准则在计算任何预测指标之前固定。因此本节检验的是 Ξ_t 对外部定义事件的预测能力，而不是 SOMA 编辑回路的触发性能。受控分析使用上一节定义的非平稳流与固定拓扑 VAE。

外部事件

考察两类事件：分布变化点（$S^1 \to T^2$ 与 $T^2 \to$ 局部分裂），由生成器记录；下游探针准确率持续退化，定义为冻结线性探针准确率相对预先定义的稳定基线

窗口超过阈值并持续一定时长的首次时刻（具体取值见 Supplementary Note 8）。两类事件分别刻画分布层面的结构变化与表征层面的功能退化。

标量诊断对照

将 Ξ_t 与四个标量拟合诊断量比较：重构误差、残差 ℓ_2 范数、ELBO 相邻窗口差分与 D_{KL} 窗口均值。四者覆盖残差幅度与整体拟合状态，并在同一长度 W 的滑动窗口内估计，保证时间分辨率可比。方向性在评估前预先设定，使较大值表示较高事件风险。各诊断量符号约定与窗口统计见 Supplementary Note 8。

预测性评估

对每个候选信号报告 AUROC 与 lead time，其定义与统计协议在末节给出。AUROC 基于相同事件/非事件窗口标注计算；lead time 在统一预设虚警率下报告，以保证不同信号可比。窗口划分、防泄漏机制与阈值选择规则见 Supplementary Note 8。

受控残差扰动

在固定拓扑模型阶段 1 末期冻结状态下，对残差特征施加四组离线扰动并记录响应。I1（方向性合成残差）：$\boldsymbol{\epsilon}_t + k_1 a_t \boldsymbol{v}_{\mathrm{inj}}$，其中 $\boldsymbol{v}_{\mathrm{inj}}$ 为窗口内固定单位方向，a_t 为样本间独立标量系数；I2（能量匹配各向同性噪声）：$\boldsymbol{\epsilon}_t + \boldsymbol{\eta}_t$，其中 $\boldsymbol{\eta}_t$ 为各向同性噪声，σ^2 使窗口平均 trace 增量与 I1 匹配；I3 对每个样本施加独立随机正交变换 R_t；I4 对所有残差施加统一非零缩放 $k \in \{2, 4, 8\}$。所有扰动不更新模型参数、不回传梯度，也不触发结构编辑。四组扰动共同检验 Ξ_t 是否主要响应残差协方差谱的形状而非能量。扰动实现细节见 Supplementary Note 8。

自然视觉基准流上的被动监测

将同一协议应用于 CLEAR 与 CLOC 流，这些流没有生成器提供的解析变化点，以外部定义的分布分箱与探针持续退化作为事件，在同一固定拓扑模型上记录 Ξ_t 与标量诊断。两条流的构造、分布分箱与在线训练协议见 *Non-stationary visual streams and continual-adaptation protocols*。

触发信号对照

上述被动分析在不执行编辑的条件下确立 Ξ_t 的几何性。为检验同一几何区分（方向性相对幅度）在主动编辑回路中是否同样决定适配质量，我们另设三个触发信号对照，它们共享 SOMA 的局部算子、参数继承规则、短程重适配预算与

$\Delta\mathcal{V} < 0$ 接受准则（定义见 *SOMA: structural adaptation using residual geometry*），仅在何时提出候选编辑这一点上不同。*M-trig*（残差幅度触发）在滑动窗口内残差范数 $\|\boldsymbol{\epsilon}_t\|_2$（等价地，重构误差）超过预设阈值时提出候选，即以幅度而非几何作为触发信号。*R-trig*（随机时刻触发）在与 SOMA 候选编辑数逐种子匹配的随机时刻提出候选，作为与编辑机会数匹配的随机下界；候选编辑数为 SOMA 在线运行的内部统计量，独立于编辑接受结果。*O-cp*（oracle 变化点触发）在真实结构转变时刻提出候选，作为已知分布变化点处触发时机的参照；该参照反映变化点处的触发，而非 SOMA 接受准则下的最优时机，两者在变化无需结构重组、或重组需推迟至积累足够新分布样本时可能不一致。三个对照均在 *Controlled non-stationary manifold stream and fixed-topology controls* 一节的受控流上运行；阈值与匹配规则的预扫描见 Supplementary Note 8，完整结果见 Extended Data Fig. S7。

SOMA: structural adaptation using residual geometry

SOMA 使用前述验证的残差几何信号来决定何时提出结构重组，但 Ξ_t 本身不由 SOMA 定义。模型状态分为连续参数 θ 与结构状态 $\phi = (A, B, K, d_c)$：θ 控制编码与生成映射，ϕ 描述潜在表征拓扑，包括节点连接 A、节点嵌入 B、结构节点数 K 与共性子空间维度 d_c。其中 K 与 d_c 显式列出，以对应改变结构粒度的节点算子和改变共性维度的维度算子；形状与参数化细节见 Supplementary Note 1。对每个观测，模型推断潜在状态 $z_t = (c_t, r_t)$，其中共性坐标 c_t 编码跨情境稳定的结构，情境特异分量 r_t 承载局部变化。在线过程中，θ 在固定结构下连续适配，ϕ 仅在触发后通过离散局部编辑更新。

连续适配与结构编辑受同一拟合–复杂度目标约束：

$$\mathcal{V}(\theta, \phi) = \mathcal{F}(\theta, \phi) + \mathcal{R}_{\text{aux}}(\theta, \phi) + \lambda_{\text{cmp}}\mathcal{C}(\phi), \tag{3}$$

其中 $\mathcal{F}$ 为累积变分自由能，$\mathcal{R}_{\text{aux}}$ 汇总稳定 c–r 分工的辅助正则项，$\mathcal{C}(\phi)$ 为结构复杂度惩罚，λ_{cmp} 为其权重。推断与生成模型、结构诱导先验、辅助正则项的解析形式见 Supplementary Note 1。

在 Stage I 中，SOMA 固定 ϕ 并连续更新 θ。此时结构复杂度项保持常数，连续适配只优化拟合项与辅助正则项，且不改变 K 或 d_c。当连续适配趋于饱和而残差仍表现出持续方向性时，SOMA 进入结构检查。具体地，令 $\bar{g}_t$ 与 $\bar{\Xi}_t$ 分别为连续适配进展（$\mathcal{J}_{\text{cont}}$ 的梯度范数 g_t）与残差各向异性 Ξ_t 在 M 个连续结构检查

上、间隔 τ_{check} 步的移动平均：

$$\bar{g}_t = \frac{1}{M}\sum_{j=0}^{M-1} g_{t-j\tau_{\text{check}}}, \qquad \bar{\Xi}_t = \frac{1}{M}\sum_{j=0}^{M-1} \Xi_{t-j\tau_{\text{check}}}. \tag{4}$$

当

$$\bar{g}_t < G_\theta \quad \text{且} \quad \bar{\Xi}_t \geq G_\phi \tag{5}$$

同时成立时触发候选编辑。第一个条件表示连续参数更新已难以继续降低目标，第二个条件表示未解释残差仍具有方向结构。这里 Ξ_t 为前文定义的模型外部测量量；它决定何时提出候选编辑，但不决定候选是否被保留。

在 Stage II 中，SOMA 在当前结构 ϕ 的局部邻域内生成候选结构 ϕ'。候选由四类局部算子产生：split 与 merge 改变 K，用于调整局部结构粒度；grow 与 prune 改变 d_c，用于调整共性子空间维度。所有候选按统一继承规则初始化：未受影响的参数继承原值，新增参数近零初始化，并仅在短程重适配中更新。候选须满足预设结构预算，且不改变 r 子空间与情境特异先验。候选按提案分数排序：

$$s_{\text{op}}(\phi') = E_{\text{op}}(\phi') - \lambda_{\text{cmp}}\big[\mathcal{C}(\phi') - \mathcal{C}(\phi)\big], \tag{6}$$

其中 $E_{\text{op}}(\phi')$ 衡量候选与当前残差几何的局部契合度，并对残差整体缩放不敏感。该分数只用于确定候选评估顺序，不更新模型参数，也不作为最终接受准则。算子定义、继承规则与提案分数见 Supplementary Notes 1–2。

SOMA 采用 first-accept 接受规则。候选按 s_{op} 的顺序逐一评估；每个候选经 n_{warmup} 步短程重适配得到 $\theta^*_{\phi'}$ 后，接受第一个满足

$$\Delta\mathcal{V} \triangleq \mathcal{V}(\theta^*_{\phi'}, \phi') - \mathcal{V}(\theta, \phi) < 0 \tag{7}$$

的候选。若没有候选降低 $\mathcal{V}$，则保持当前结构不变并返回连续适配。由于 $\mathcal{V}$ 含有复杂度惩罚，结构扩张必须带来足够的拟合改进以补偿复杂度增长；压缩操作则可接受小幅拟合损失，只要复杂度节省带来净目标下降。因此，残差几何只决定何时以及优先尝试何种局部编辑，而编辑是否保留由统一目标决定。这一机制使结构演化自限：当当前结构已能低成本吸收残差结构时，扩张候选无法获得足够的目标下降，结构增长自然停止。first-accept 策略、候选池、短程重适配预算、目标序列的分段下降性、有界性与自限性证明见 Supplementary Notes 2–3。

Non-stationary visual streams and continual-adaptation protocols

本节定义 Fig. 4 所用的非平稳视觉基准、在线适配协议与基线。不同于前述具有已知潜在结构的受控流，这两个公开基准没有生成器给出的潜在结构或解析变化点，其分布变化由数据采集时序与数据集元信息定义。

公开非平稳视觉流

CLEAR[19] 是按拍摄时间排序的公开图像流，分布随时间渐进漂移；CLOC[20] 是大规模在线分类流，分布变化由地理位置与采集时间共同决定。主文结果使用固定的时间分箱、统一的训练/探针/测试划分与统一图像预处理；具体数据集版本、图像量级、类别构造、分箱边界与预处理参数见 Supplementary Note 8。两条流在训练中不暴露任务边界或类别切换，并用于前述残差几何外部验证中的被动监测分析。

在线适配协议

所有方法按单遍数据流接收新样本：每张图像仅作为新样本到达一次，无 epoch 概念。任务边界、变化点与采集时间戳不作为输入特征或控制信号暴露给模型。显式持续学习基线从统一容量的回放缓冲中重采样；SOMA、SimCLR 与 DINO 不维护回放缓冲。显式持续学习基线使用官方标签进行在线更新，作为有标签监督对照，但不暴露任务编号、变化点或未来样本。SOMA 与自监督基线在在线适配阶段不使用标签；标签仅用于离线探针训练与评估。所有方法共享视觉编码骨干与新样本暴露步数；批量大小、主干优化预算以及回放、教师网络、投影头和编辑重适配等方法特有成本按预设协议匹配或单独核算，见 Supplementary Note 8。架构与超参数见 Supplementary Tables S1 与 S2。

基线

基线分为三类，分别检验不同能力来源。*固定拓扑自监督表示学习*包括 SimCLR[21] 与 DINO[22]，用于检验固定拓扑自监督表征在非平稳流中的稳定性。*显式持续学习*包括 ER[23]、A-GEM[24] 与 DER++[25]，覆盖回放、梯度约束与蒸馏三类遗忘缓解策略。*固定调度结构编辑*与 SOMA 共享候选生成与排序、参数继承、短程重适配与接受准则；唯一差异是候选检查由预设间隔触发，而非由 Ξ_t 触发，用以分离拓扑可变性与编辑时机的贡献。

受控视觉补充协议

为在可控视觉场景中精确操纵变化形态，我们在 Shapes3D[18] 上注入三类显式参数化的非平稳协议：突变，即概念集合在预设变点处瞬时切换；渐变，即被操控参数在过渡窗内单调插值；以及循环，即系统在多个环境族间周期往返。变点位置与环境标识对模型不可见。这三类协议作为受控补充，其变点序列、过渡窗长度、周期长度与环境族构造见 Supplementary Table S3C，详细设置与结果见 Extended Data Fig. S5 与 Supplementary Note 7。

评估与可复现性

评估采用冻结编码器线性探针协议：每隔预设训练步冻结当前编码器，在标注探针训练集上训练线性分类器，并在独立探针测试集上报告指标；Ξ_t 同时在线记录。本基准上报告的指标及统计协议见 *Evaluation metrics, statistical analysis and reproducibility*。所有超参数，包括 Ξ_t 的窗口 W 与谱地板 η_{floor}、复杂度权重 λ_{cmp} 及各基线超参数，均由独立预扫描或留出校准流设定；评估流不参与任何超参数选择，以避免后验调参（详见 Supplementary Note 8）。

Phase-diagram analysis of self-organized structural adaptation

为刻画 SOMA 自组织结构的工作区域，我们在控制平面 $(\lambda_{\text{cmp}}, G_\phi)$ 上系统扫描：复杂度权重 λ_{cmp} 跨四个数量级，触发阈值 G_ϕ 跨两个数量级。每个配置使用相同的在线暴露长度、训练预算与受控流生成协议；除扫描参数外，G_θ、候选池、warm-up 预算与结构上界保持为校准值。对每个配置记录最终拓扑规模 K、共性子空间维度 d_c、残差各向异性 Ξ_t、编辑时机、下游探针性能与累计适配代价（CAC）。

由这些量将工作区域划分为三类相区：欠组织（高 Ξ_t 持续而编辑罕见，结构不足以吸收变化）、自组织（编辑与生成器定义的结构转变对齐，结构规模随内在需求增长后趋于稳定）、以及过度碎片化（编辑过于频繁，结构规模持续增长而不带来下游收益）。为验证跨流形的标度结构，我们在 S^1、T^2、S^2 三类具有不同几何或拓扑结构的底层流形上重复扫描。相区分类的操作性判据、用于跨流形比较的归一化 $\left(\lambda_{\text{cmp}}/d^{\text{int}}, G_\phi/\Xi_{\text{base}}\right)$，其中 Ξ_{base} 为校准流上的基线残差各向异性尺度，以及相区边界塌缩的统计检验见 Supplementary Note 5。

Evaluation metrics, statistical analysis and reproducibility

表征与持续学习指标

主要表征质量以冻结编码器线性探针准确率衡量。非平稳基准上另报告遗忘、后向迁移（*BWT*）、恢复时间与累计适配代价（*CAC*）。遗忘定义为每个评估分箱在其后续时间内的最大准确率下降，并对分箱及随机种子取平均。*BWT*[32] 为训练结束时早期分箱准确率相对于其首次稳定基线准确率的差值，再对分箱取平均（稳定基线窗口见 Supplementary Note 8）。恢复时间为评估窗口切换后准确率首次达到 $\eta_{\mathrm{rec}} A^{\max}$ 所需步数，其中 η_{rec}=0.95，$A^{\max}$ 为该窗口在对应运行中的离线参考峰值；未在评估期内恢复的运行按最大观测长度处理。*CAC* 为连续参数位移与离散结构编辑代价归一化后的加权和，其权重由独立校准流确定。非平稳适配以恢复时间与 BWT 为主指标，CAC 作为次级指标（几何解释与权重扰动稳定性见 Supplementary Note 8）。

拓扑–数据对齐

受控数据流上报告 *TAEF*（time-aligned edit fraction），定义为落入真实阶段边界 $\pm\Delta_{\mathrm{TAEF}}$ 步窗口内的接受编辑数占全部接受编辑数的比例。无接受编辑的运行按 TAEF=0 处理；窗口重叠与多编辑计数规则见 Supplementary Note 8。真实阶段边界仅用于离线评估，不参与训练或触发判定。

少样本复用

Few-shot reuse（$\mathrm{AUC}_{\mathrm{shot}}$）定义为冻结编码器下线性探针准确率随支撑样本数 k 变化曲线的归一化曲线下面积，$\mathrm{AUC}_{\mathrm{shot}} \in [0,1]$，数值越高表示少样本复用越强；支撑样本网格 $\mathcal{K}_{\mathrm{shot}}$ 与逐数据集协议见 Supplementary Note 7。

残差几何的外部验证

AUROC 在每个随机种子内基于相同的事件窗口与非事件窗口标注计算，随后跨种子聚合；置信区间按随机种子聚类，不将同一运行内的时间窗口视为独立样本。*Lead time* 为信号首次超过由校准流确定的阈值到事件发生之间的步数，阈值在所有信号上按相同目标虚警率设定。所有信号（Ξ_t 与各标量诊断）的窗口长度 W 与标注规则保持一致，以保证提前量可比；未在事件前报警的事件记为零提前量（阈值选择规则与防泄漏机制见 Supplementary Note 8）。

统计分析

曲线为 n 个独立随机种子的均值，阴影或误差棒为 s.e.m.，n 在图注中给出；关键标量比较同时报告 95% 置信区间。统计检验以种子聚合指标为独立样本，不将同一运行内的时间窗口或评估分箱视作独立重复。相同种子集与数据流下的配对比较采用双侧 Wilcoxon signed-rank 检验，非配对情形用双侧 Mann–Whitney U 检验。报告效应量（Cliff's δ，配对比较为 matched rank-biserial correlation；Hedges' g 仅用于近似正态的聚合指标）。对超过两组的比较，P 值经 Benjamini–Hochberg 法在每个图、每个指标的预设比较族内做 FDR 校正。原始统计数据见 Source Data。

可复现性

所有超参数（Ξ_t 的窗口 W、谱地板 η_{floor}、触发阈值 G_θ, G_ϕ、复杂度权重 λ_{cmp} 及各基线超参数）由独立预扫描或留出校准流确定，评估流不参与任何超参数选择。软件版本、代码提交、硬件配置、随机种子列表、数据预处理、超参数选择协议与算力核算见 Supplementary Note 8 与 Code availability。

Supplementary Information

本 Supplementary Information 提供支撑主文 Methods 与 Results 的技术补充, 涵盖 SOMA 的算法细节、跳变映射、提案分数实现、稳定性分析、累计适配代价的几何动机、残差各向异性的替代定义以及超参数敏感性分析。各 Supplementary Notes 沿用主文 Methods 的符号约定与公式标号。

Supplementary Note 1 | Algorithmic details of SOMA

Variational free energy

对每一时刻的观测 o_t，SOMA 推断潜在状态 $z_t = (c_t, r_t)$。在当前结构 ϕ 下时刻 t 的变分自由能为

$$\mathcal{F}_t(\theta, \phi) = \mathbb{E}_{q_\theta(z_t \mid o_{\le t})}[-\log p_\theta(o_t \mid z_t, \phi)] + D_{\mathrm{KL}}(q_\theta(z_t \mid o_{\le t}) \,\|\, p(z_t \mid \phi)), \qquad (8)$$

$o_{\le t}$ 在非时序任务下退化为 o_t；累积自由能记为 $\mathcal{F} = \sum_t \mathcal{F}_t$。推断模型由共享编码骨干 $h_\theta(o)$ 与两路头部 (c 头与 r 头) 输出后验均值与协方差；c_t 的先验由 B 的列向量给出 K 个均值锚点，A 调制其相对耦合，共同决定共性子空间内的先验密度；r_t 服从与结构无关的高斯先验，$p(r_t) = \mathcal{N}(0, I)$。

Auxiliary inductive biases

辅助项 $\mathcal{R}_{\text{aux}}$ 包含三项：

$$\mathcal{R}_{\text{aux}} = \lambda_{\text{dis}}\mathcal{L}_{\text{dis}} + \lambda_{\perp}\mathcal{L}_{\perp} + \lambda_{\text{sym}}\mathcal{L}_{\text{sym}}. \tag{9}$$

分量解耦项 $\mathcal{L}_{\text{dis}}$ 在聚合后验 $q(c) = \mathbb{E}_{p_{\text{data}}(o)}[q_\theta(c \mid o)]$、$q(r)$ 下抑制内部维度间相关与跨分量耦合：

$$\mathcal{L}_{\text{dis}} = \text{TC}(q(c)) + \text{TC}(q(r)) + I_q(c; r), \tag{10}$$

$\text{TC}(\cdot)$ 为总相关，$I_q(c; r)$ 为聚合后验下的互信息，均以 minibatch-weighted sampling[4] 估计。

局部几何正交项 $\mathcal{L}_{\perp}$ 约束两路头部相对共享特征的 Jacobian 列空间近似正交。记 $J_c(o) = \partial \hat{c}_\theta(o)/\partial h_\theta(o)$，$J_r(o) = \partial \hat{r}_\theta(o)/\partial h_\theta(o)$，则

$$\mathcal{L}_{\perp} = \mathbb{E}_{o\sim p_{\text{data}}}\left[\left\| J_c(o)\, J_r(o)^{\top}\right\|_F^2\right]. \tag{11}$$

弱对称约束 $\mathcal{L}_{\text{sym}}$ 通过预先指定的变换生成集 $\mathcal{G}_{\text{gen}}$ 使 c 优先编码跨变换稳定的结构，情境相关变化以等变形式映射至 r：

$$\mathcal{L}_{\text{sym}} = \mathbb{E}_{o,\, g\sim\text{Unif}(\mathcal{G}_{\text{gen}})}\left[\left\|\hat{c}_\theta(g\cdot o) - \hat{c}_\theta(o)\right\|_2^2 + \left\|\hat{r}_\theta(g\cdot o) - T_g\hat{r}_\theta(o)\right\|_2^2\right], \tag{12}$$

T_g 为 g 在 r 子空间上的线性表示，与生成集一同给定。本文受控评估中 $\mathcal{G}_{\text{gen}}$ 取流形上的平移与有限旋转生成元；视觉基准中取像素级标准增广 (随机裁剪、水平翻转、颜色抖动) 的有限子集。

Continuous-adaptation objective

Stage I 在固定结构状态 ϕ 下仅优化连续参数 θ，此时复杂度项 $\lambda_{\text{cmp}}\mathcal{C}(\phi)$ 为常数，统一目标 $\mathcal{V}$ 退化为连续适配目标

$$\mathcal{J}_{\text{cont}}(\theta; \phi) = \mathcal{F}(\theta, \phi) + \mathcal{R}_{\text{aux}}(\theta, \phi), \tag{13}$$

即累积变分自由能 $\mathcal{F}$ (式 (8)) 与辅助归纳偏置 $\mathcal{R}_{\text{aux}}$ (式 (9)) 之和。θ 通过 $\mathcal{J}_{\text{cont}}$ 的随机梯度下降更新；辅助项中未启用的部分按 Supplementary Table S2 将相应权重置零。

Topology-editing operators

四类局部算子的形式定义如下。

Node split：给定候选节点 k，$\Psi_{\text{split}}(\phi; k)$ 将其替换为两个新节点 k_a, k_b，$K' = K + 1$。B 中第 k 列沿候选分裂方向对称分裂：

$$B'_{:,k_a} = B_{:,k} + \alpha_{\text{sp}} \boldsymbol{v}_k, \qquad B'_{:,k_b} = B_{:,k} - \alpha_{\text{sp}} \boldsymbol{v}_k, \tag{14}$$

$\boldsymbol{v}_k$ 为节点邻域共性坐标残差的顶特征向量，$\alpha_{\text{sp}} > 0$ 为分裂幅度；A 中节点 k 对应的行与列复制为两份并保持非负。

Node merge：给定候选节点对 (k_a, k_b)，Ψ_{merge} 将两节点合并为单节点 k'，$K' = K - 1$，节点嵌入按近期使用率加权：

$$B'_{:,k'} = \frac{w_{k_a} B_{:,k_a} + w_{k_b} B_{:,k_b}}{w_{k_a} + w_{k_b} + \epsilon_w}, \tag{15}$$

$\epsilon_w > 0$ 为数值稳定项；A 中两节点对应的行与列按相同稳定加权方式合并。

Common-subspace dimension grow：给定候选新增方向 $\boldsymbol{v}_\perp$ (由当前共性子空间无法解释的残差方向标识)，Ψ_{grow} 将共性流形维度由 d_c 增至 $d_c + 1$；B 在底部追加一行 (小随机扰动以打破对称)，编码–解码网络在 c 端口的新增通道近零初始化；A 与 K 不变。

Common-subspace dimension prune：给定候选维度 d^*，Ψ_{prune} 将 d_c 减至 $d_c - 1$；B 中第 d^* 行被删除，编码–解码网络在 c 端口的对应通道被删除；A 与 K 不变。

四类算子共享参数继承原则：未受影响的 A, B 分量与编码–解码网络权重原值继承；新增维度相关权重以近零初始化，并仅在 Stage II 的短程重适配中更新。所有候选须满足 $K' \geq 1$, $d'_c \geq 1$, $K' \leq K_{\max}$, $d'_c \leq d_{c,\max}$；违反约束的候选不进入后续评估。节点近期使用率 $w_k(\phi) = \sum_{\tau \in \mathcal{W}_t} u_{\tau k}(\phi)$，其中 $\mathcal{W}_t$ 为触发判定附近的近期统计窗口 (默认取式 (25) 中的残差滑动窗口)。

本节给出 SOMA 的完整算法实现细节, 作为 Methods 中 Stage I、Stage II 以及 *Candidate scoring, short re-adaptation and acceptance* 的伪代码参考。本节不引入新机制, 仅汇总执行时序、检查周期、参数继承、状态更新与编辑历史记录规则。

Overall iteration structure

SOMA 以两阶段交替方式运行: Stage I 在固定结构状态 ϕ 下沿 $\mathcal{J}_{\text{cont}}$ (式 (13)) 更新连续参数 θ; 每 τ_{check} 步检查 Stage II 触发条件 (式 (5)); 若满足则进入一轮候选生成、评分、短程重适配与接受判定。若某个候选被接受, 系统以新的 (θ, ϕ) 返回 Stage I; 否则 ϕ 保持不变, θ 继续 Stage I 更新。两阶段由同一总目标 $\mathcal{V}$ (式 (3)) 约束: Stage I 在固定 ϕ 下优化 $\mathcal{V}$ 的连续部分 $\mathcal{J}_{\text{cont}}$, Stage II 用完整 $\mathcal{V}$ 比较候选结构。真实阶段边界不向 SOMA 暴露, 仅用于离线计算 TAEF、recovery time 与 lead time; 训练期间 Stage II 只由 $\bar{g}_t < G_\theta$ 与 $\bar{\Xi}_t \geq G_\phi$ 触发。

Pseudocode

SOMA 的完整流程总结于 Algorithm 1。

Algorithm 1 SOMA: self-organized model adaptation

Require: 数据流 $\{o_t\}_{t=1}^{T}$; 初始结构 $\phi_0 = (A_0, B_0, K_0)$, $d_{c,0} = \mathrm{rows}(B_0)$; 初始参数 θ_0; 超参数 $(\tau_{\text{check}}, M_{\text{smooth}}, W, G_\theta, G_\phi, n_{\text{warmup}}, K_{\text{cand}}, \lambda_{\text{cmp}}, \eta_{\text{floor}}, K_{\max}, d_{c,\max}, \ldots)$.

$\theta \leftarrow \theta_0$, $\phi \leftarrow \phi_0$, $\mathcal{H}_{\text{edit}} \leftarrow \emptyset$
for $t = 1, 2, \ldots, T$ **do**
  接收观测 o_t
  $\theta \leftarrow \mathrm{OptimizerStep}(\theta, \nabla_\theta \mathcal{J}_{\text{cont}}(\theta; \phi))$ ▷ Stage I
  更新 $\widehat{\Sigma}_t$ (式 (25)); 计算 Ξ_t (式 (2))
  if $\mathrm{tr}(\widehat{\Sigma}_t) \le \eta_{\text{floor}}$ **then**
    $\Xi_t \leftarrow 0$
  end if
  if $t \bmod \tau_{\text{check}} = 0$ **then**
    计算 $\bar{g}_t, \bar{\Xi}_t$ (式 (4))
    if $\bar{g}_t < G_\theta$ **and** $\bar{\Xi}_t \ge G_\phi$ **then** ▷ Stage II 触发
      在邻域 $\mathcal{N}(\phi)$ 内枚举候选 $\{\phi' = \Psi_{\text{op}}(\phi; \cdot)\}$, 丢弃违反域约束者
      对每个候选计算 $E_{\text{op}}(\phi')$ 与 $s_{\text{op}}(\phi')$ (式 (6))
      按 s_{op} 降序取前 K_{cand} 个候选构成 $\mathcal{Q}_t$
      accepted $\leftarrow$ **false**
      for all $\phi' \in \mathcal{Q}_t$ (按 s_{op} 顺序) **do**
        $\phi^- \leftarrow \phi$, $\theta^- \leftarrow \theta$
        按 Stage II 继承规则从 θ^- 初始化 θ'
        for $j = 1, \ldots, n_{\text{warmup}}$ **do**
          $\theta' \leftarrow \mathrm{OptimizerStep}_{\text{warm}}(\theta', \nabla_{\theta'} \mathcal{J}_{\text{cont}}(\theta'; \phi'))$
        end for
        $\Delta\mathcal{V} \leftarrow \mathcal{V}(\theta', \phi') - \mathcal{V}(\theta^-, \phi^-)$
        if $\Delta\mathcal{V} < 0$ **then**
          $(\theta, \phi) \leftarrow (\theta', \phi')$
          将 $(t, \phi^-, \phi, \Delta\mathcal{V})$ 追加到 $\mathcal{H}_{\text{edit}}$
          accepted $\leftarrow$ **true**
          break ▷ first-accept
        end if
      end for
      if not accepted **then**
        保持 (θ, ϕ) 不变, 继续 Stage I
      end if
    end if
  end if
end for
return $(\theta, \phi, \mathcal{H}_{\text{edit}})$

Stage I details

Stage I 使用通用优化器 OptimizerStep 更新连续参数 (本文实验中为 AdamW 或标准 SGD; 优化器、学习率与调度见 Supplementary Table S2)。$\mathcal{J}_{\text{cont}}$ 包含变分自由能 $\mathcal{F}$ 以及启用实验中的辅助项 $\mathcal{L}_{\text{dis}}$、$\mathcal{L}_{\perp}$ 和 $\mathcal{L}_{\text{sym}}$ (式 (13)); 各项估计方式见 Methods, 权重与启用设置见 Supplementary Table S2。残差特征 $\boldsymbol{\epsilon}_t$ 与滑动窗口协方差 $\widehat{\Sigma}_t$ 同步更新; 低能量窗口 ($\text{tr}(\widehat{\Sigma}_t) \le \eta_{\text{floor}}$) 中令 $\Xi_t = 0$, 且不参与触发评估。

Stage II details

Stage II 每 τ_{check} 步执行一次触发判定; 触发判据 $\bar{g}_t < G_\theta \wedge \bar{\Xi}_t \ge G_\phi$ (式 (5)) 在 M_{smooth} 个连续检查周期上取移动平均, 以避免瞬时噪声触发。触发后, 系统在当前结构的局部邻域 $\mathcal{N}(\phi)$ 内枚举候选 $\phi' = \Psi_{\text{op}}(\phi; \cdot)$, 其中 Ψ_{op} 为四类主要局部算子之一: split (待分裂节点 k)、merge (待合并节点对 (k_a, k_b))、grow (待扩展方向 $\boldsymbol{v}_\perp$) 与 prune (待裁剪维度 d^*) (具体编辑规则见 Methods)。候选须满足域约束 $K' \ge 1$, $d'_c \ge 1$, $K' \le K_{\max}$, $d'_c \le d_{c,\max}$, $A' \in \mathbb{R}_{\ge 0}^{K' \times K'}$; 违反约束的候选不进入评分。评分使用提案分数 s_{op} (式 (6)), 按降序取前 K_{cand} 个候选构成 $\mathcal{Q}_t$, 按顺序逐个评估并采用 first-accept 终止。所有候选的 proposal scoring 与 warm-up 后的 $\Delta\mathcal{V}$ 比较均使用同一评分批次或同一残差窗口计算, 以保证候选差异来自结构编辑本身而非随机采样差异。

Parameter inheritance and state updates

每个候选 ϕ' 对应的参数初始化按 Methods 各算子段定义的继承规则: split —节点 k 对应的 B 列按 $B_{:,k} \pm \alpha_{\text{sp}} \boldsymbol{v}_k$ 分裂, A 对应的行与列复制为两份并保持非负; merge —两节点对应的 B 列与 A 行/列按近期使用率加权合并; grow —B 在底部追加一行 (小随机扰动以打破对称), 解码器在 c 端口的新增通道采用近零初始化, 新增 common-subspace 方向及对应解码器通道在 warm-up 中优化; prune —B 中第 d^* 行与解码器对应通道删除。其余 A, B 分量及编码–解码网络权重原值继承。

若候选被拒绝, 其 warm-up 后参数 θ' 被丢弃, 下一个候选从原始 (θ, ϕ) 独立继承初始化, 以避免候选间优化轨迹污染。若候选被接受, (θ, ϕ) 更新为 (θ', ϕ'), 并将 $(t, \phi^-, \phi, \Delta\mathcal{V})$ 写入 $\mathcal{H}_{\text{edit}}$。若所有候选均被拒绝, 当前状态保持不变。$\mathcal{H}_{\text{edit}}$ 用于离线计算 TAEF、CAC 与编辑事件统计。

Termination and reset behavior

SOMA 在达到训练总步数预算 T 时终止。本文实验中, 触发判据 (式 (5)) 作为持续监控机制运行至训练结束, 不预设额外的全局终止条件。系统的自限性体现在: 当当前 ϕ 已能解释残差结构时, 进一步扩张通常难以获得足够目标下降, 结构编辑因此趋于停止 (Methods, *Complexity penalty and self-limitation*)。连续与离散停止判据 ($\|\nabla_\theta \mathcal{J}_{\text{cont}}\| < \varepsilon_\theta$ 与 $\Xi_t < \varepsilon_\phi$) 及其稳定性讨论见 Supplementary Note [N-stab]。除持续更新的滑动残差窗口外, SOMA 不维护跨触发的候选搜索记忆: 每次触发仅基于当前残差统计与当前 ϕ 状态生成候选; 被拒绝候选的 warm-up 状态不参与后续触发的初始化。

Supplementary Note 2 | Proposal scoring and first-accept rationale

本节补充 Methods 中候选评分与接受策略的实现细节, 包括局部证据评分、有限候选池、结构跳变映射、first-accept 相对于全局 arg min 的设计理由, 以及候选池大小和短程重适配预算的鲁棒性分析。

Role of the proposal score

提案评分在 warm-up 之前计算, 不更新模型参数; s_{op} 仅用于候选排序与候选池截断。结构编辑是否接受仍由短程重适配后的 $\Delta\mathcal{V} < 0$ (式 (7)) 判定; 因此本节中 “评分高” 仅表示排序优先级。

Operator-specific scoring rules

对四类局部算子, 提案分数

$$s_{\text{op}}(\phi') = E_{\text{op}}(\phi') - \lambda_{\text{cmp}} \Delta\mathcal{C}_{\text{op}}(\phi')$$

由局部证据强度 E_{op} 与复杂度变化共同决定。这里 E_{op} 是越大越优先的证据强度 (evidence), 其值越高表示候选越契合当前残差几何; 该证据不是最终接受目标。

证据强度建立在两个通用的局部量之上。其一为节点投影强度: 虽然先验在式 (**??**) 中写作连续形式, B 的列仍定义结构节点在共性子空间中的局部支点。对每个时刻 t, 共性坐标点估计 $\hat{c}_\theta(o_{\le t})$ 在第 k 个支点上的非负投影强度定义为

$$u_{tk}(\phi) = \frac{\langle \hat{c}_\theta(o_{\le t}), B_{:,k} \rangle^2}{\|B_{:,k}\|_2^2 + \epsilon}, \tag{16}$$

其中 $\hat{c}_\theta(o_{\le t}) \triangleq \mathbb{E}_{q_\theta}[c_t \mid o_{\le t}]$ 为共性坐标的后验均值, $\epsilon > 0$ 为数值稳定项。其二为局部证据 Rayleigh 商: 对扩张类算子 (split, grow), E_{op} 由候选编辑诱导的残差特征方向 $u \in \mathbb{R}^{d_\epsilon}$ 上的归一化协方差 Rayleigh 商给出:

$$E_{\text{op}}(\phi') = \frac{u^\top \widetilde{\Sigma}_t u}{\|u\|_2^2 + \epsilon}, \tag{17}$$

其中 $\widetilde{\Sigma}_t = \widehat{\Sigma}_t / (\operatorname{tr} \widehat{\Sigma}_t + \epsilon)$ 为迹归一化的残差协方差。若候选方向原定义在 c 子空间中 (如 $\boldsymbol{v}_k$), 则先经局部解码映射至残差特征空间得到 u。四类算子的 E_{op} 按类别分别实例化:

Split: 对候选节点 k, E_{op} 由节点邻域内共性坐标残差的顶特征向量 $\boldsymbol{v}_k \in \mathbb{R}^{d_c}$ 经局部解码映射至残差特征空间后, 在归一化协方差 $\widetilde{\Sigma}_t$ 下的 Rayleigh 商给出 (式 (17)); 节点邻域定义为投影强度 $\pi_{tk}(\phi)$ (式 (16)) 处于前 ρ_{nbhd} 分位数的样本集合。该分数优先选择局部残差在单一方向上持续集中的节点, 即当前节点粒度不足以解释其邻域内变异的情形。

Grow: 对候选新增方向, E_{op} 由 $\widehat{\Sigma}_t$ 的顶特征向量在当前共性子空间正交补内的分量 $\boldsymbol{v}_\perp$ 给出的 Rayleigh 商定义。该方向首先在残差特征空间中确定, 随后通过与编码器/解码器局部线性化一致的映射初始化新增共性子空间方向, 具体映射与 Methods 中 grow 算子的继承规则一致。

Merge: 对候选节点对 (k_a, k_b), E_{op} 由三部分组成——B 列相似性、A 的行/列耦合相似性, 以及近期使用模式相似性:

$$E_{\text{merge}} = \alpha_B \cos\big(B_{:,k_a}, B_{:,k_b}\big) + \alpha_A \operatorname{sim}_A(k_a, k_b) + \alpha_w \operatorname{sim}\big(\mathbf{w}_{k_a}, \mathbf{w}_{k_b}\big),$$

其中 sim_A 同时考虑 A 的行相似性与列相似性 (以处理可能的非对称耦合), $\mathbf{w}_k$ 为节点 k 在近期窗口的使用率向量, $(\alpha_B, \alpha_A, \alpha_w)$ 为分量权重。各相似度均归一化为越大表示越相似; 三项越高, merge 候选优先级越高。

Prune: 对候选维度 d^*, E_{op} 由该维度的低贡献度给出。实现中使用 $B_{d^*,:}$ 行范数、该维度的平均激活幅度以及删除后残差增加的近似估计; 这些量越小, 归一化后的低贡献度分数越高, 因此 E_{op} 越高, prune 候选优先级越高。

对压缩类算子, $\Delta\mathcal{C}_{\text{op}}(\phi') < 0$, 因此 $-\lambda_{\text{cmp}}\Delta\mathcal{C}_{\text{op}}$ 进一步推高其综合得分, 反映“复杂度节省” 对候选优先级的正向贡献。在每次 Stage II 触发事件内, 四类算子的局部证据经统一的非负尺度归一化 (min–max); 零方差情形按常数项处理。该归一化使局部证据与 $\Delta\mathcal{C}_{\text{op}}$ 处于可比较的排序尺度, 且不跨触发事件累积。

Candidate ranking and bounded candidate pool

触发后, 系统首先在当前结构的局部邻域 $\mathcal{N}(\phi)$ 内枚举所有满足域约束的候选, 按 s_{op} 降序排列, 取前 K_{cand} 个构成候选池:

$$\mathcal{Q}_t = \mathrm{TopK}_{K_{\mathrm{cand}}}\Big(\big\{\phi' \in \mathcal{N}(\phi) : \phi' \text{ 满足域约束}\big\},\ s_{\mathrm{op}}\Big). \tag{18}$$

候选排序使用同一检查时刻的结构状态、残差窗口与使用率统计; 接受判定使用相同的 n_{warmup}, 并在同一比较批次或残差窗口上计算 $\Delta\mathcal{V}$, 以避免接受结果被优化步数或随机采样差异混淆。与全局结构搜索方法不同, SOMA 不在每次触发时遍历所有可能结构, 而是仅在当前 ϕ 一步可达的邻域内按残差几何提示的方向局部展开。K_{cand} 的具体取值与敏感性见本节末段。

Jump map and first-accept rule

当 Stage II 触发条件 (式 (5)) 满足时, 结构状态的离散更新由跳变映射给出:

$$\phi^+ = \underset{\phi' \in \mathcal{Q}_t}{\text{first-accept}} \big\{\phi' : \mathcal{V}(\theta^{\mathrm{warm}}_{\phi'}, \phi') < \mathcal{V}(\theta, \phi)\big\}, \tag{19}$$

其中 $\theta^{\mathrm{warm}}_{\phi'}$ 表示从继承参数出发经 n_{warmup} 步短程重适配后的状态, 不是候选结构下的充分优化解; first-accept 按 s_{op} 顺序返回 $\mathcal{Q}_t$ 中第一个满足下降条件的候选。当候选被接受时, 连续参数同步更新为 $\theta^+ = \theta^{\mathrm{warm}}_{\phi^+}$。本文约定: 若 $\mathcal{Q}_t$ 中满足下降条件的候选集合为空, 则 first-accept 返回当前结构, 即 $(\theta^+, \phi^+) = (\theta, \phi)$。该跳变映射是 Methods 中接受准则 (式 (7)) 在结构状态上的显式写法。

First-accept versus $\arg\min$

First-accept 是局部可接受性规则, 不是对 $\mathcal{Q}_t$ 或更大结构空间的最优化规则。式 (19) 采用 first-accept 而非穷举比较后选取最大下降量的 $\arg\min$ 策略, 基于三方面考虑。

(i) 候选下 $\mathcal{V}$ 值的可比性有限。$\theta^{\mathrm{warm}}_{\phi'}$ 仅为 n_{warmup} 步短程重适配后的近似状态, 而非候选拓扑下的充分优化结果。不同候选从不同继承状态出发, 有限 warm-up 后的 $\mathcal{V}$ 差异同时受结构变化与短程优化路径影响。因此, 二元下降判据 $\Delta\mathcal{V} < 0$ 只检验候选是否可接受, 避免将细小目标值差异解释为精确结构排序。

(ii) 下降性论证的最低要求。Supplementary Note 4 中统一目标 $\mathcal{V}$ 的分段单调性论证仅要求存在某个被接受候选使 $\Delta\mathcal{V} < 0$, 而不要求该候选是局部 $\arg\min$。

first-accept 满足这一分段下降性论证的最低要求, $\arg\min$ 的额外比较并不改善该论证所需的最低条件。

(iii) 计算开销。$\arg\min$ 要求对 $\mathcal{Q}_t$ 中每个候选完成完整的 n_{warmup} 步重适配并计算 $\mathcal{V}$; first-accept 在首个合格候选出现时即终止, 平均评估候选数通常小于 K_{cand}, 在保持下降性的同时降低结构检查阶段的计算开销 (具体观测数见本节末段)。

Robustness to candidate pool size and warm-up budget

我们在双因子环面数据上检验 SOMA 对 K_{cand} 与 n_{warmup} 的鲁棒性。K_{cand} 在 $\{2, 4, 8, 16\}$ 上扫描, n_{warmup} 在 $\{50, 100, 200, 400\}$ 上扫描, 每组配置使用 $n_{\text{seed}} = 10$ 个独立随机种子, 报告最终拓扑 K^*, d_c^*、下游探针性能、接受率与平均每次触发的实际评估候选数四类量。Extended Data 中报告以下鲁棒性结果: (a) $K_{\text{cand}} \geq 4$ 时, 最终拓扑与下游探针性能保持稳定, 并与主实验配置处于同一行为相区; K_{cand} 进一步增大主要带来平均评估候选数的增加, 而非性能改善——与 first-accept 设定一致。(b) $n_{\text{warmup}} \geq 100$ 时, 最终拓扑与下游性能保持稳定; $n_{\text{warmup}} < 50$ 时, 候选状态更易受初始继承偏差影响, 表现为接受率下降或临界配置增多。(c) 平均每次触发的实际评估候选数与 K_{cand} (即 $\arg\min$ 所必需的评估数) 之比, 在主实验配置 ($K_{\text{cand}} = 8$) 下约为 **[1/2–1/3]**, 对应结构检查阶段的计算节省。完整鲁棒性曲线见 Supplementary Fig. **[F-prop]**。

Supplementary Note 3 | Stability analysis and path dependence

本节分析统一目标 $\mathcal{V}(\theta, \phi)$ 在 SOMA 两阶段混合动力学下的稳定性, 并讨论离散结构编辑顺序引入的路径依赖。以下结论仅涉及目标值序列 $\{V_n\}$ 的分段单调性与有界性, 不构成混合状态轨迹 (θ, ϕ) 的全局收敛证明, 也不声称收敛到唯一的 "真实生成拓扑"。$\{V_n\}_{n \geq 0}$ 为在检查点或结构跃迁后记录的评估窗口目标值序列; 离散跃迁仅在接受准则 (式 (7)) 满足时发生。

Per-edit objective descent

SOMA 的接受准则要求每次实际结构跃迁满足 $\Delta\mathcal{V} < 0$ (式 (7))。因此, 每个被接受编辑都在接受判据所用的比较窗口上使统一目标下降。该性质与编辑算子类别无关, 仅依赖接受时的下降判据, 并构成下述分段单调性分析的基础。

Piecewise monotonicity

连续适配阶段。当 $\phi = (A, B, K)$ 固定, 且 $\mathcal{J}_{\text{cont}}$ 满足局部 L-光滑条件、步长 $\eta_t \in (0, 2/L)$ 时, 参数更新满足

$$\mathcal{J}_{\text{cont}}(\theta_{t+1}; \phi) \leq \mathcal{J}_{\text{cont}}(\theta_t; \phi) - \left(\eta_t - \tfrac{L}{2}\eta_t^2\right) \left\|\nabla_\theta \mathcal{J}_{\text{cont}}(\theta_t; \phi)\right\|_2^2. \tag{20}$$

由于固定 ϕ 时 $\lambda_{\text{cmp}}\mathcal{C}(\phi)$ 为常数, 在上述理想梯度下降条件下, 连续段内的 V_n 同样非增。

离散跃迁阶段。由接受准则可知, 每一次实际跃迁 $(\theta, \phi) \to (\theta_{\phi'}^{\text{warm}}, \phi')$ 均满足

$$\mathcal{V}(\theta_{\phi'}^{\text{warm}}, \phi') < \mathcal{V}(\theta, \phi),$$

故 V_n 在跃迁处严格下降。若候选池 $\mathcal{Q}_t$ 中所有候选均被拒绝, 结构状态保持不变, 离散检查点本身不引入目标上升。

因此, 在上述光滑性与步长条件下, 连续更新与接受编辑共同给出 $\{V_n\}$ 的分段非增性。在实际小批量自适应优化中, 式 (20) 的精确形式不再成立; 本文将分段非增性作为评估窗口上的经验稳定性趋势, 而非逐步确定性单调下降保证 (实验观测见 Supplementary Fig. [**F-stab**])。

Boundedness and self-limitation

在本文损失实现中, 重构项、KL 项与启用的正则项均采用数值上有下界的形式; 结构复杂度 $\mathcal{C}(\phi)$ 为非负加权和。因此, 在固定数值参数化与正则化设置下, 存在有效下界 V_{inf}:

$$\mathcal{V}(\theta, \phi) \geq V_{\text{inf}}. \tag{21}$$

在确定性梯度下降并满足式 (20) 的条件下, 若每个接受编辑满足 $\Delta\mathcal{V} < 0$, 则 $\{V_n\}$ 为有下界的非增实数序列, 因而收敛到某个 $V^* \geq V_{\text{inf}}$。在小批量自适应优化中, 该结论不被解释为逐步目标值收敛证明, 而仅作为窗口平均目标与接受编辑下降性的稳定性依据。

若采用带裕度的接受准则

$$\Delta\mathcal{V} < -\delta_{\text{acc}}, \qquad \delta_{\text{acc}} > 0, \tag{22}$$

则每次接受编辑至少带来 δ_{acc} 的目标下降, 接受编辑次数满足

$$N_{\mathrm{edit}} \leq \frac{V_0 - V_{\mathrm{inf}}}{\delta_{\mathrm{acc}}}. \tag{23}$$

若主实验采用 $\delta_{\mathrm{acc}} = 0$, 该上界不提供非平凡保证; 结构编辑的稀疏性与自限趋势主要由触发条件、复杂度惩罚与有限候选池共同控制, 并通过 phase-diagram experiments 经验检验 (Methods, *Phase-diagram experiments*)。因此, 本文不声称结构编辑次数在一般情形下具有有限上界。本文所称 "自限性" (Methods, *Complexity penalty and self-limitation*) 指复杂度惩罚、有界候选池与残差几何触发共同产生的经验性质, 而非本节论证给出的确定性保证。

Path dependence of accepted edits

上述 per-edit descent 只约束实际接受序列中的目标变化, 不在不同接受序列之间建立等价性。SOMA 的最终拓扑 ϕ^* 具有路径依赖性, 主要来自三方面。

(i) 触发时机。Stage II 触发由滑动窗口残差几何决定 (式 (5)); 触发时刻附近的残差分布受当前 θ 与最近观测序列共同影响, 随机种子与数据流实例的差异可能改变具体触发时刻。

(ii) 候选顺序。first-accept 按提案分数 s_{op} 顺序接受第一个满足 $\Delta\mathcal{V} < 0$ 的候选; s_{op} 的细微差异可能改变被接受候选, 并使后续轨迹分叉。

(iii) warm-up 状态。候选参数 $\theta_{\phi'}^{\mathrm{warm}}$ 由继承规则与 warm-up 优化路径共同决定, 并受继承初始化、优化器状态与小批量噪声影响; 候选是否满足 $\Delta\mathcal{V} < 0$ 取决于其具体 warm-up 实现。

因此, 即使两次运行得到相近的最终 V^*, 最终结构 ϕ^* 仍可能不同。若某次 Stage II 检查无候选被接受, 也仅表示在当前候选池、warm-up 预算与比较窗口下未发现下降候选, 并不表示当前结构为 $\mathcal{V}$ 的全局或局部极小。

Convergence claims and their limits

本节实际成立的结论是: 在理想下降条件下, $\{V_n\}$ 具有有界非增性 (式 (21)); 每个被接受编辑满足 per-edit descent; 未接受编辑仅表示当前局部候选池内未发现下降候选。本文不声称结构编辑在一般情形下必然有限, 也不声称最终结构为 $\mathcal{V}$ 的全局或唯一局部极小。

即使数据由明确的潜在拓扑生成, 该拓扑也未必是 $\mathcal{V}$ 的唯一全局极小; 其他与残差几何相容、且可由局部编辑路径到达的拓扑配置同样可能成为可接受的路径终态。最终结构 ϕ^* 应理解为在给定数据流、初始化、局部算子集、有限候选池与

warm-up 预算下未再发现可接受下降编辑的路径终态之一。其与底层生成拓扑的对应程度取决于数据流形是否能被该算子集与触发机制局部解析, 而非由本节下降性论证直接给出。这一定位与正文 *Limitations* 中关于结构唯一性的讨论一致。

因此, 自组织有效性的评价不依赖 "恢复唯一真实拓扑" 的假设, 而由结构规模 (K^*, d_c^*)、残差各向异性 Ξ^*、编辑时机, transition-aligned edit fraction, CAC, few-shot reuse 与下游线性探针性能等指标共同刻画。

Practical termination criterion

实际实现中, 稳定状态通过以下操作性判据识别:

$$\bar{g}_t < \varepsilon_\theta, \qquad \bar{\Xi}_t < \varepsilon_\phi, \tag{24}$$

且连续 M_{stop} 次结构检查中无候选满足 $\Delta\mathcal{V} < 0$。其中 $\bar{g}_t, \bar{\Xi}_t$ 为式 (4) 的滑动窗口估计。该判据不同于 Stage II 触发阈值 (G_θ, G_ϕ) (式 (5)): 触发阈值决定何时进入候选评估, 而 $(\varepsilon_\theta, \varepsilon_\phi)$ 与 M_{stop} 用于判定连续更新与结构触发信号是否同时低于稳定阈值。主实验仍运行至固定步数预算 T; 式 (24) 仅作为终点稳定性核对, 而非强制终止信号 (见 Supplementary Note 1, *Termination and reset behavior*)。

Supplementary Note 4 | Robustness of residual anisotropy statistics

本节检验残差各向异性统计量 Ξ_t 的鲁棒性, 考察其替代定义、窗口长度依赖、观测噪声与批量大小敏感性、低能量窗口处理以及高维残差下的实现稳定性, 以检验 Fig. 2 中基于残差几何的预测性与因果敏感性结论对这些实现选择的稳定性。

Residual feature and sliding-window covariance

每一时刻从当前推断–生成回路提取残差特征向量 $\boldsymbol{\epsilon}_t \in \mathbb{R}^{d_\epsilon}$，作为当前结构约束下未解释成分的内部表示。本文受控评估中默认采用观测空间重构残差 $\boldsymbol{\epsilon}_t = o_t - \hat{o}_\theta(\hat{z}_t)$，其中 $\hat{z}_t = \mathbb{E}_{q_\theta}[z_t \mid o_{\le t}]$ 为后验均值，$\hat{o}_\theta$ 为解码器条件均值；对高维或时序任务，$\boldsymbol{\epsilon}_t$ 亦可由潜在预测残差或特征空间残差替代 (见后文 *Residual dimensionality* 段)。

在长度为 W 的滑动窗口上估计残差的无偏样本协方差：

$$\widehat{\Sigma}_t = \frac{1}{W-1} \sum_{s=t-W+1}^{t} (\boldsymbol{\epsilon}_s - \bar{\boldsymbol{\epsilon}}_t)(\boldsymbol{\epsilon}_s - \bar{\boldsymbol{\epsilon}}_t)^\top, \qquad \bar{\boldsymbol{\epsilon}}_t = \frac{1}{W} \sum_{s=t-W+1}^{t} \boldsymbol{\epsilon}_s. \tag{25}$$

若 $\boldsymbol{\epsilon}_s$ 在窗口内沿少数方向系统性变化，$\widehat{\Sigma}_t$ 的谱集中于少数顶特征值；若残差方向近似随机，其谱不再由少数稳定方向主导。滑动窗口协方差的秩至多为 $W-1$，故在 $d_\epsilon > W-1$ 时取 $r_\Sigma = \min(d_\epsilon, W-1)$ 个非负特征值，负特征值数值截断为零，归一化得 $\{\tilde{\lambda}_{t,i}\}$，进入式 (2) 的谱熵计算。

Alternative spectral anisotropy definitions

除式 (2) 中的默认谱各向异性统计量外, 我们考察三类替代谱统计; 所有替代统计均归一为数值越大表示各向异性越强。

*归一化参与比各向异性。*设 $\widehat{\Sigma}_t$ 的特征值为 $\{\lambda_i\}_{i=1}^d$, 参与比为

$$\mathrm{PR}_t = \frac{\left(\sum_i \lambda_i\right)^2}{\sum_i \lambda_i^2}.$$

归一化参与比各向异性定义为

$$\Xi_t^{\mathrm{PR}} = \frac{d/\mathrm{PR}_t - 1}{d-1}, \tag{26}$$

其在谱近似均匀时接近 0, 在能量集中于少数方向时趋近 1。

*局部 PCA 能量集中度 (去基线归一化)。*设前 k 个主成分解释方差占比为 $\rho_k = \sum_{i=1}^k \lambda_i / \sum_{i=1}^d \lambda_i$, 定义

$$\Xi_t^{\mathrm{PCA}} = \frac{\rho_k - k/d}{1 - k/d}, \tag{27}$$

默认取 $k = \lceil d/10 \rceil$, 并以 $k=1$ 和 $k = \lceil d/4 \rceil$ 作敏感性检验 (重复值合并)。该量在各向均匀时接近 0, 在前 k 个方向解释几乎全部残差能量时接近 1。

*谱间隙统计。*为检验单一主方向是否从其余谱中分离, 定义

$$\Xi_t^{\mathrm{gap}} = \frac{\lambda_1 - \lambda_2}{\lambda_1 + \epsilon}. \tag{28}$$

该量对 “单一持续方向性” 特别敏感, 但可能低估多方向残差结构。

Robustness across trigger statistics

在受控双因子环面流与 dSprites[3] 上, 我们分别以 Ξ_t、Ξ_t^{PR}、Ξ_t^{PCA} 与 Ξ_t^{gap} 作为触发统计量, 并将阈值 G_ϕ 校准到阶段 1 稳态下基线统计量分布的相同分位数, 使四种触发量产生相同虚警率。四种定义下, 触发时刻、最终拓扑 (K^*, d_c^*)、TAEF

与下游探针性能保持相同定性趋势, 差异处于跨种子误差范围内 (Supplementary Fig. S2b,c)。这表明 Stage II 利用的是 “持续方向性残差” 这一类结构信号, 而非某一特定统计量的偶然性质。

Sensitivity to window length

窗口长度 W 控制 $\widehat{\Sigma}_t$ 的估计样本数, 因而存在偏差–方差权衡: W 过小时 Ξ_t 波动较大、易误触发; W 过大时估计更平滑但响应迟滞。在 $W \in \{10, 20, 50, 100, 200\}$ 上扫描, $W < 20$ 时稳定区间误触发率明显升高 ($> 10\%$) 并伴随 TAEF 下降; $W \in [20, 200]$ 内, TAEF、最终拓扑与下游线性探针性能未观察到系统性改变 (Supplementary Fig. S2d)。主实验取 $W = 50$, 作为稳定性与响应速度之间的折中; 该取值与 Fig. 2 中 Ξ_t 作为预测信号的 AUROC 评估窗口设置一致。

Observation noise and batch-size sensitivity

观测噪声。对受控数据流添加像素级高斯噪声 $o_t \mapsto o_t + \boldsymbol{\zeta}_t$, $\boldsymbol{\zeta}_t \sim \mathcal{N}(0, \sigma_{\text{obs}}^2 I)$, 并在 $\sigma_{\text{obs}} \in \{0, 0.01, 0.05, 0.1, 0.2\}$ 上扫描。随 σ_{obs} 增大, $\widehat{\Sigma}_t$ 的迹同步增大; 各向同性噪声在期望上主要增加谱的均匀成分, 不会单独产生稳定主方向。未校准阈值下, Ξ_t 的峰值幅度可能下降, 或有限样本下基线略有抬升; 但阶段切换处相对基线的方向性升高仍可检测, TAEF 与触发行为在 $\sigma_{\text{obs}} \leq 0.1$ 范围内未观察到系统性改变 (Supplementary Fig. S2e)。当 $\sigma_{\text{obs}} = 0.2$ 时, 各阶段基线整体抬升; 重新校准 G_ϕ 至基线分位数后, TAEF 与触发时机部分恢复。

批量大小。小批量大小 B 同时影响连续梯度估计与残差协方差估计的方差。在 $B \in \{32, 64, 128, 256, 512\}$ 上扫描, Ξ_t 与触发行为未显示出对 B 的系统性依赖: $\widehat{\Sigma}_t$ 在窗口内跨小批量累积, 其估计方差主要由窗口内有效残差样本数控制。$B = 32$ 时连续梯度噪声增加导致 Stage I 收敛略慢, 但 Stage II 触发时机与最终拓扑变化保持在跨种子误差范围内 (Supplementary Fig. S2f)。

Low-energy windows

当 $\text{tr}(\widehat{\Sigma}_t) \leq \eta_{\text{floor}}$ 时, $\widehat{\Sigma}_t$ 的谱方向主要反映数值噪声, 而非有意义的残差结构; 对应窗口被标记为 low-energy window, Ξ_t 被置为 0, 并在触发统计中视为非触发窗口 (参见 Supplementary Note 1, *Stage I details*)。在 $\eta_{\text{floor}} \in \{10^{-8}, 10^{-7}, 10^{-6}, 10^{-5}\}$ 上重复计算后, Fig. 2 中 Ξ_t 的峰值位置、AUROC 与干预对照模式未观察到系统性改变; η_{floor} 主要影响阶段切换初期低能量过渡窗口的纳入或剔除边界, 不改变整体结论。

Residual dimensionality and high-dimensional observations

当观测维度 $d_o \gg W$ 时, 直接在观测空间估计协方差可能出现秩亏, 导致 Ξ_t 不稳定。本文在此情形下改于编码器特征空间计算 Ξ_t (以编码器倒数第二层特征残差替代观测残差), 以获得更稳定的协方差估计。特征空间估计在编码器局部线性化下可视为观测残差方向性结构的低维投影近似, 而非与观测空间严格等价; 其有效维度由特征层宽度而非 d_o 决定。作为附加检查, 我们也在残差的随机正交投影上重复计算 Ξ_t。在投影维度足以保留主要残差方向时, 触发时刻与特征空间估计保持相同趋势, 偏差处于跨种子误差范围内 (Supplementary Fig. S2g), 表明结论不由特征层的具体选择驱动。

Stability of Fig. 2 conclusions

综合上述鲁棒性扫描, Fig. 2 中 Ξ_t 作为外部事件预测信号的 AUROC 与 lead time, 以及干预实验 (I1–I4) 中 Ξ_t 对几何成分的敏感性与对纯幅度缩放的相对不敏感性, 在以下选择上未观察到系统性改变: 谱各向异性定义 (谱熵、归一化参与比、去基线 PCA 或谱间隙); 滑动窗口长度 $W \in [20, 200]$; 观测噪声 $\sigma_{\text{obs}} \leq 0.1$; 批量大小 $B \in [32, 512]$; 能量底阈 $\eta_{\text{floor}} \in [10^{-8}, 10^{-5}]$; 以及残差在观测空间、编码器特征空间或随机正交投影空间中计算的选择。这些扰动不改变 Ξ_t 相对于标量拟合诊断量 (重构误差、残差 ℓ_2 范数、ELBO 变化率、KL 散度) 的 AUROC 排序, 也不改变 I1/I3 (几何成分) 与 I2/I4 (幅度成分) 的干预对照模式 (完整扫描结果见 Supplementary Fig. S2)。因此, Fig. 2 的结论不由 Ξ_t 的某一具体形式或单一参数设定驱动。

Supplementary Note 5 | Phase-diagram classification and scaling collapse

Phase-diagram analysis and regimes

本节给出主文 Discussion 中提及的相图分析的完整判据与统计方法（Extended Data Fig. **??**）。该分析的目的不是寻找最优超参数点，而是检验 SOMA 的自组织行为是否为一个稳健的工作区域，还是仅出现在精细调谐的孤立配置上。我们在复杂度权重 λ_{cmp} 与残差触发阈值 G_ϕ 张成的控制平面上系统扫描，得到三个清晰分离的操作性相区：高复杂度惩罚或高触发阈值下的欠组织相区，其中结构编辑很少被触发或接受，最终结构规模低于底层需求，残差在结构转变后保持持续方向性；低复杂度惩罚或低触发阈值下的过度碎片化相区，其中短暂残差波动即可触发编辑，结构无收益增长且累计适配成本升高；以及二者之间的自组织相

区，其中结构编辑集中发生在真实结构变化附近、残差在编辑后回落、结构增长自限、累计适配成本最低。这一划分将“自组织”从一个定性概念转化为一组可量化、可在控制平面上识别的机制特征（判据见下）。该自组织相区覆盖约 [REGIME-WIDTH] 个数量级的 λ_{cmp} 范围，说明 SOMA 的有效行为并不依赖精细调节；以内在维度与基线各向异性归一化后，S^1、T^2 与 S^2 上的自组织边界塌缩至同一曲线（Extended Data Fig. **??**e），表明该相区由数据内在维度与拟合–复杂度权衡共同主导。本节其余部分给出相区判据、边界提取与跨流形塌缩的技术细节。

Regime criteria

本节中的“相区”指模型行为的操作性区域，不表示热力学相变或临界现象。三类相区由 Methods *Phase-diagram experiments* 中的四个操作特征联合判定：编辑对齐 TAEF $\geq \eta_{\mathrm{align}}$，残差恢复 $\Xi^* \leq \Xi_{\mathrm{base}}+\delta_{\Xi}$，结构自限（终段编辑频率 $\leq \eta_{\mathrm{slim}}$，$K^* \leq K^{\mathrm{int}} + \Delta K_{\mathrm{tol}}$，$d_c^* \leq d^{\mathrm{int}} + \Delta d_{\mathrm{tol}}$），以及累计代价判据

$$\mathrm{CAC} \leq \eta_{\mathrm{cac}}^{\mathrm{lo}} \mathrm{CAC}_{\mathrm{base}} \quad \text{or} \quad \mathrm{CAC} \geq \eta_{\mathrm{cac}}^{\mathrm{hi}} \mathrm{CAC}_{\mathrm{base}}.$$

其中 Ξ_{base} 与 $\mathrm{CAC}_{\mathrm{base}}$ 为同一流形固定拓扑基线在阶段 1 稳态窗口内的跨种子均值；δ_{Ξ} 为加性恢复裕度，用于避免乘性阈值在 Ξ_{base} 较小时过严。$\Delta K_{\mathrm{tol}} \leq \Delta K_{\mathrm{frag}}$，$\Delta d_{\mathrm{tol}} \leq \Delta d_{\mathrm{frag}}$；两组裕度分别用于自限通过条件与碎片化判据，取值见 Supplementary Table S2.

自组织相区要求四项条件同时通过。过度碎片化相区要求高代价、终段编辑频率超阈值，且

$$K^* > K^{\mathrm{int}} + \Delta K_{\mathrm{frag}} \quad \text{or} \quad d_c^* > d^{\mathrm{int}} + \Delta d_{\mathrm{frag}}.$$

欠组织相区要求编辑对齐失败或残差恢复失败，且同时满足以下至少一项：稳态残差未恢复（$\Xi^* > \Xi_{\mathrm{base}}+\delta_{\Xi}$），或最终结构规模低于参考需求（阈值见 Supplementary Table S2）。判据冲突的配置标记为 critical。在主扫描中，critical 配置占全部配置的 [X]%，主要分布于相区边界附近。

阈值在 Methods 预设候选范围内经独立预扫描选定；预扫描以相区标签的种间一致性为目标，不使用下游性能、K^*, d_c^* 或 probe 准确率，以避免阈值选择与被验证假设循环耦合。预扫描使用独立保留配置，不参与主图边界估计。对每个配置，跨 $n_{\mathrm{seed}} = 10$ 个种子按 $p_{\mathrm{maj}} = 0.7$（至少 7/10 个种子同一标签）多数聚合；critical 配置不参与主边界拟合，并在 Extended Data 中单独显示。

Boundary extraction

将控制平面的扫描配置视为四邻接网格 (4-connectivity)。若相邻配置中一者为自组织, 另一者为欠组织或过度碎片化, 则在连线中点放置边界点, 并按非自组织邻居归属分为 “朝向欠组织” 与 “朝向过度碎片化” 两支; critical 配置不参与邻接对。

两支边界点按 $\tilde{\lambda}$ 排序后, 以带单调约束的三次样条拟合。内部节点数 $K_{\text{knot}} \in \{3, \ldots, 8\}$ 由 leave-one-seed-out 交叉验证选取, 目标为最小化留出种子上边界点到曲线的中位距离。单调性约束用于抑制网格与种子噪声造成的局部折返, 并以边界在扫描范围内的经验单调趋势为依据。单调性约束用于抑制网格与种子噪声造成的局部折返。若某支边界在交叉验证中显著偏离单调（留出残差超过非单调拟合的 [X]%），则该支不施加单调约束，在 Extended Data 中单独标记，且不用于主边界塌缩估计。

Cross-manifold normalization

跨流形比较采用归一化坐标

$$\tilde{\lambda} = \log_{10}\left(\frac{\lambda_{\text{cmp}}}{d^{\text{int}}}\right), \qquad \tilde{G} = \text{logit}(G_\phi) - \text{logit}(\Xi_{\text{base}}).$$

其中 d^{int} 校正内在维度带来的结构复杂度基线差异; Ξ_{base} 将 G_ϕ 表示为相对于该流形基线各向异性的 log-odds 偏移。Ξ_{base} 由固定拓扑基线在该流形阶段 1 稳态窗口内估计, 不依赖 $(\lambda_{\text{cmp}}, G_\phi)$; logit 自变量裁剪到 $[\epsilon, 1-\epsilon]$ 以避免端点奇异。

$\tilde{G}$ 采用 logit 差分而非比值的 logit, 以确保 $G_\phi, \Xi_{\text{base}} \in (0, 1)$ 时定义良好。该坐标与扫描的对数/logit 采样网格一致, 使边界距离和样条拟合均在相同尺度上计算。该归一化不预设跨流形边界重合, 仅用于将不同流形的边界比较置于同一尺度下。

Collapse error and cross-seed stability

对每对流形 (M, M') 与每一支边界 $b \in \{\text{under/self}, \text{self/frag}\}$, 记归一化坐标下边界为 $\tilde{G} = f_{M,b}(\tilde{\lambda})$。塌缩误差定义为

$$D_{M,M',b} = \frac{1}{|\mathcal{I}_{M,M',b}|} \int_{\mathcal{I}_{M,M',b}} |f_{M,b}(\tilde{\lambda}) - f_{M',b}(\tilde{\lambda})| \, d\tilde{\lambda},$$

其中 $\mathcal{I}_{M,M',b}$ 为两条边界共同覆盖的 $\tilde{\lambda}$ 区间。D_{coll} 对三对流形 $\{(S^1, T^2), (S^1, S^2), (T^2, S^2)\}$ 及两支边界取平均。

作为对照, 在未作跨流形校正的扫描坐标 $(\log_{10}\lambda_{\mathrm{cmp}}, \mathrm{logit}(G_\phi))$ 下计算 $D_{\mathrm{coll}}^{\mathrm{raw}}$, 并报告

$$\mathcal{R}_{\mathrm{coll}} = D_{\mathrm{coll}}/D_{\mathrm{coll}}^{\mathrm{raw}}.$$

$\mathcal{R}_{\mathrm{coll}} < 1$ 表示归一化后边界距离降低。

统计不确定性由 $B_{\mathrm{boot}} = 200$ 次 by-seed bootstrap 估计。每次重采样均重新执行单种子标记、配置聚合与边界拟合; $f_{M,b}(\tilde{\lambda})$ 的 1σ 范围作为 Fig. **??**e 的阴影。经验 p_{coll} 定义为 bootstrap 样本中 $\mathcal{R}_{\mathrm{coll}} \geq 1$ 的比例。$\mathcal{R}_{\mathrm{coll}} < 1$ 及对应的 bootstrap 经验 p_{coll} 在阈值 $[0.5\times, 2\times]$ 扰动、$p_{\mathrm{maj}} \in \{0.5, 0.6, 0.8, 1.0\}$、$\Xi_{\mathrm{base}}$ leave-one-out 扰动以及 K_{knot} 全范围下保持相同定性结论 (完整扫描见 Fig. S1)。

本节判据均为操作性定义。主文相图用于比较 SOMA 行为区域及其跨流形标度, 不构成临界性、普适类或严格临界点主张。

Supplementary Note 6 | Controlled non-stationary manifold stream

本节给出 Fig. 1 所用受控数据流的完整规格，包括底层流形参数化、像素渲染映射、三阶段切换协议与阶段长度的预扫描判据。本节对应 Methods 中 *Controlled non-stationary manifold stream* 小节所引用的 “具体设定”；该数据流的目的是分离两类适配情形：连续参数可吸收的表观分布变化，以及需要潜在拓扑调整的结构变化。

Stage 1: single circle S^1

底层流形为单一圆周，内在维度 $d^{\mathrm{int}} = 1$。每一时刻在 $\theta \sim \mathrm{Unif}[0, 2\pi)$ 采样，得底层坐标 $\xi = (\cos\theta, \sin\theta) \in \mathbb{R}^2$。该阶段不引入额外因子，作为基线适配阶段。

Stage 2: torus T^2

底层流形扩展为 $T^2 = S^1 \times S^1$，$d^{\mathrm{int}} = 2$。每一时刻独立采样 $(\theta_1, \theta_2) \sim \mathrm{Unif}[0, 2\pi)^2$，得底层坐标 $\xi = (\cos\theta_1, \sin\theta_1, \cos\theta_2, \sin\theta_2) \in \mathbb{R}^4$。相对 Stage 1，该阶段引入一个独立变化因子，要求潜在表征在共性子空间中新增一维。

Stage 3: locally split structure

底层流形保留 T^2 的全局坐标，但在 θ_1 落入预设局部区域 $\theta_1 \in [\theta_a, \theta_b]$ 时，额外采样一个离散子组标签 $\kappa \sim \mathrm{Unif}\{1, \ldots, K^{\mathrm{int}}\}$，$K^{\mathrm{int}} = 4$。$\theta_1$ 不落入该区域时 $\kappa = 0$ (无子组)。该阶段不增加 d^{int}，但引入需要表征粒度细化的局部结构，要求潜在节点数从 1 增至 4。

***Pixel rendering map* Φ**

所有阶段共用同一固定渲染映射 $\Phi : \mathbb{R}^{d^{\text{int}}+1} \to [0,1]^{H_{\text{img}} \times W_{\text{img}}}$，$(H_{\text{img}}, W_{\text{img}}) = (32, 32)$。$\Phi$ 由一个两层卷积解码网络实现，权重在所有阶段、所有种子、所有实验间保持不变：

$$\Phi(\xi, \kappa) = \sigma\big(W_2\, \text{GELU}(W_1[\xi;\, b_\kappa])\big),$$

$W_1 \in \mathbb{R}^{256 \times (d^{\text{int}} + d_\kappa)}$，$W_2 \in \mathbb{R}^{H_{\text{img}} W_{\text{img}} \times 256}$，$\sigma$ 为 sigmoid，$b_\kappa \in \mathbb{R}^{d_\kappa}$ $(d_\kappa = 8)$ 为子组 κ 的固定偏置向量 ($\kappa = 0$ 时 $b_\kappa = 0$)。$W_1, W_2, \{b_\kappa\}$ 由固定随机种子 (seed = 0) 初始化，后续不更新。该渲染映射使底层坐标到像素的关系对所有方法、所有种子保持同一非线性形态，跨种子差异仅来自模型权重初始化、小批量采样与触发统计窗口。

Phase lengths and pre-scan criterion

三阶段长度 T_1, T_2, T_3 由独立预扫描确定。预扫描中固定拓扑 VAE (与主实验同骨干、同优化器、同种子集) 在每个阶段上以固定步长持续训练，监测两个滑动统计量：窗口内重构误差均值 $\bar{\mathcal{L}}_{\text{rec}}$ 与残差各向异性 Ξ_t。阶段长度取为同时满足以下两条件后再延长 $\Delta T = 2{,}000$ 步：(i) $\bar{\mathcal{L}}_{\text{rec}}$ 在长度为 $W_{\text{ps}} = 2{,}000$ 步的两个相邻滑动窗口间相对变化幅度小于该阶段末段标准差的 0.5σ；(ii) Ξ_t 在相同窗口对内跨 $n_{\text{seed}} = 10$ 种子的均值变化幅度亦小于 0.5σ。该延长用于覆盖阶段切换后的连续适配过程，保证测得的持续方向性残差不能仅由短暂的优化未收敛解释。预扫描仅依赖固定拓扑基线的稳态判据，不使用 SOMA 终段结构、K^*, d_c^*、Ξ^* 或下游探针准确率，以避免阶段长度选择与被验证机制循环耦合。主实验中所采用的 (T_1, T_2, T_3) 数值见 Supplementary Table S2。

What is exposed to the model

模型仅接收图像序列 $\{o_t = \Phi(\xi_t, \kappa_t)\}$。阶段边界、底层流形类型、内在维度 d^{int}、T^2 的两个独立坐标、局部分裂区域 $[\theta_a, \theta_b]$ 与子组标签 κ 均不向模型暴露。这些信息仅在离线评估时使用，用于计算 TAEF、恢复时间以及 Ξ_t 与真实变化点的对齐 (见 Supplementary Note 8)；训练期间 Stage II 仅由 $\bar{g}_t < G_\theta$ 与 $\bar{\Xi}_t \geq G_\phi$ 触发 (式 (5))。

Supplementary Note 7 | Factor-controlled visual diagnostics

Datasets and preprocessing

因子可控视觉诊断在三套具有显式生成因子标注的基准上进行: dSprites [3]、Shapes3D [18] 与 MPI3D [33]; 具体规格与因子层级见 Supplementary Table S3A。每套数据集按 Supplementary Table S3B 在诊断中划分为稳定可复用因子 $\mathcal{F}_{\text{inv}}$ 与情境相关因子 $\mathcal{F}_{\text{side}}$; 该划分仅用于冻结编码器后的探针评估, 不参与 SOMA 或基线训练。图像统一缩放至 64×64, 像素值归一化至 $[0, 1]$。本节使用每数据集独立的训练/验证/测试划分, few-shot probe 中再从保留评估划分构造互不重叠的 support/query episodes; 划分比例、episode 数与随机种子见 Supplementary Table S3。本节实验用于机制诊断, 而非静态解耦基准的单点最优比较; 结果作为 Extended Data 支撑, 不构成主文 Results 的独立基准主张。

Disentanglement metrics

报告三类与生成因子可对照的解耦指标。*MIG* [4]: 对每个生成因子 v_k, 计算其与所有潜在维度 $\{z_j\}$ 的互信息, 取最大与次大互信息之差, 并按因子熵归一化:

$$\text{MIG} = \mathbb{E}_k\left[H(v_k)^{-1}\big(I_{(1)}(v_k) - I_{(2)}(v_k)\big)\right],$$

其中 $I_{(1)}$ 与 $I_{(2)}$ 为排序后的前两位互信息。*DCI Disentanglement* [34]: 由 $z_j \to v_k$ 的特征重要性矩阵 $R \in \mathbb{R}_{\geq 0}^{J \times m}$ 给出, 其中 R 由梯度提升回归器估计, m 为生成因子数, J 为潜在维度数:

$$\text{DCI} = \sum_j \rho_j \left[1 - \frac{H\big(R_{j\cdot}/\textstyle\sum_k R_{jk}\big)}{\log m}\right], \qquad \rho_j = \frac{\sum_k R_{jk}}{\sum_{j',k} R_{j'k}}.$$

其中 ρ_j 为第 j 个潜维度的相对重要性权重, $H(\cdot)$ 为离散分布熵。*FactorVAE score* [18]: 固定一个生成因子, 随机采样其余因子形成 batch, 以 batch 内方差最小的潜在维度作为该因子的 "投票", 多数投票分类器的准确率即为得分。

所有模型均在冻结编码器输出的完整潜表示 z_t 上计算指标。对 SOMA 额外报告 c 与 r 分量结果, 以诊断 Stage I 的功能分工 (Methods, *Inference model and structure-induced prior*); 对无显式 c/r 分解的基线, 仅报告完整 z 的指标。由于 c 与 r 的维度可能不同, SOMA 的分量分数仅作为功能分工诊断, 不用于不同维度分量之间的容量公平绝对比较。互信息估计采用 MIG 原文的离散化协议, 连续因子按等频分位数离散化为 20 桶。

Few-shot reuse protocol

Few-shot 探针用于评估冻结表示在有限监督下的可复用性。对每个支持集大小

$$k \in \mathcal{K}_{\text{shot}} = \{1, 2, 5, 10, 20, 50\},$$

从保留评估划分构造互不重叠的 support/query episodes: 按因子标签均匀抽取 k-shot support 样本训练线性探针, 并在固定 query 集上评估。每个 k 独立采样多个 support 集以降低方差; query 集大小与 episode 数见 Supplementary Table S3。报告 $\text{AUC}_{\text{shot}} \in [0, 1]$ 作为准确率–$\log k$ 曲线的归一化梯形面积 (Methods, *Evaluation metrics and statistical analysis*)。

$\mathcal{F}_{\text{inv}}$ 与 $\mathcal{F}_{\text{side}}$ 独立计算 AUC_{shot}, 分别评估稳定因子的可复用性以及 side factors 在 c 与 r 中的可读性分布。所有方法的 probe 使用相同结构、优化器、训练轮数与早停规则。对 SOMA, 分量探针以 c 或 r 单独为输入, 分别预测对应因子组, 作为 Stage I 功能分工的诊断指标: c 应支持 $\mathcal{F}_{\text{inv}}$, r 应主要承载或吸收 $\mathcal{F}_{\text{side}}$ 相关变化。对无显式 c/r 分解的基线, 仅报告完整 z 的探针结果。所有分量探针仅用于离线评估, 不回传至 SOMA 训练。

Diagnostic comparisons

将 SOMA 与同骨干的解耦学习和容量对照基线比较: VAE [2]、β-VAE [3]、FactorVAE [18]、β-TCVAE [4] 与 DIP-VAE [35]; 另以高容量固定拓扑 VAE 作为容量对照 (其潜在维度不低于该数据集内 SOMA 终段 $d_c^* + d_r$ 的跨种子最大值, d_r 固定)。基线超参数见 Supplementary Table S2。所有方法使用相同骨干、优化器和总步数 T: SOMA 在该预算内允许结构编辑, 并在 T 末端读取终段稳定结构 (K^*, d_c^*); 基线在相同预算下保持固定拓扑。

报告三类对照: (i) MIG、DCI、FactorVAE score 在完整 z 上的跨方法比较, 并额外报告 SOMA 的 c, r 分量值; (ii) AUC_{shot} 在 $\mathcal{F}_{\text{inv}}$ 与 $\mathcal{F}_{\text{side}}$ 上的差异; (iii) SOMA 分量探针的对角占优性:

$$A_{c \to \mathcal{F}_{\text{inv}}} > A_{c \to \mathcal{F}_{\text{side}}}, \qquad A_{r \to \mathcal{F}_{\text{side}}} > A_{r \to \mathcal{F}_{\text{inv}}}.$$

为避免因子组类别数差异造成难度偏差, 对角占优性同时以 chance-normalized accuracy 报告:

$$A^{\text{norm}} = \frac{A - A_{\text{chance}}}{1 - A_{\text{chance}}},$$

其中 A_{chance} 为对应 probe 任务标签空间下的随机猜测准确率, 按因子组内每个因子的类别数分别计算后取平均。

由于本节仅作为 Extended Data 机制诊断, 每组结果在 $n_{\text{seed}} = 5$ 个独立种子上聚合, 报告均值 ± s.e.m.; 主文关键非平稳实验仍采用 $n_{\text{seed}} = 10$。跨方法成对比较采用种子内配对的 Wilcoxon signed-rank test, p 值经 Benjamini–Hochberg 校正。由于该部分种子数较少且仅作机制诊断, p 值作为辅助统计量报告; 解释以效应方向和跨种子一致性为主。数值结果见 Extended Data Table **[ED-tab-disent]**。

作为与主文机制的衔接, 在非平稳转变诊断中, 固定拓扑模型即使保持相近重构误差, 仍可能出现残差各向异性 Ξ_t 升高, 且 $\mathcal{F}_{\text{inv}}$ 上的 AUC_{shot} 恢复较差。该对照用于区分拟合误差与结构性残差, 并与 Fig. 2 的几何信号一致。本节诊断用于说明 Stage I 的 c–r 分工与 SOMA 终段结构 (K^*, d_c^*) 在因子可控条件下与解耦及容量基线的关系, 而非提出新的解耦学习基准主张。

Supplementary Note 8 | Implementation details, compute and adaptation cost

本节给出 SOMA 与对照基线的实现细节、默认超参数、累计适配代价 (CAC) 的离散实现、以及计算资源。所有具体数值默认值与扫描范围见 Supplementary Table S1 与 Supplementary Table S2; 本节侧重各默认值的取定方式以及方法间公平比较所依赖的实现约定。机制层面的鲁棒性与替代统计量见 Supplementary Notes 3–5。

Evaluation conventions and notation

本节统一以下评估约定，后续指标定义与 *Cumulative adaptation cost* 段共用。对每个数据流 (受控合成流形 / CLEAR / CLOC)，定义一组评估时刻 $\mathcal{T}_{\text{eval}} = \{t_1, \ldots, t_{N_t}\} \subset [1, T]$，间隔 τ_{eval}；评估在每个 $t \in \mathcal{T}_{\text{eval}}$ 时冻结编码器，不更新任何模型参数或 SOMA 内部状态。对每个数据流定义一组评估窗口 $\mathcal{W} = \{w_1, \ldots, w_{N_w}\}$；窗口 w_k 由其所属的数据段 $\mathcal{D}_k$ (训练集) 与 $\mathcal{D}_k^{\text{test}}$ (独立测试集) 共同确定。线性探针准确率 $A(t, k) \in [0, 1]$ 表示在时刻 t 冻结编码器，在 $\mathcal{D}_k$ 上训练线性分类器，在 $\mathcal{D}_k^{\text{test}}$ 上得到的 top-1 准确率。对每个早期窗口 k，其 “编码完成时” 的准确率 $A^{\text{enc}}(k) \triangleq A(t_k^{\text{enc}}, k)$ 定义为 $\mathcal{D}_k$ 对应数据访问首次完成时刻 t_k^{enc} 的准确率。该约定保证 BWT 中使用的参考准确率不依赖于模型未来对该窗口的重访。所有指标在 $n_{\text{seed}} = 10$ 个独立种子上聚合，报告均值与跨种子标准误 (s.e.m.)。

Representation-quality metric: average linear-probe accuracy

作为表征质量的主要度量，

$$\bar{A} = \frac{1}{N_t N_w} \sum_{t \in \mathcal{T}_{\text{eval}}} \sum_{k=1}^{N_w} A(t,k). \tag{29}$$

$\bar{A}$ 用于 Fig. 4b (CLEAR 与 CLOC 子面板) 中报告的 “平均准确率”。

Continual-learning metrics: forgetting, BWT, recovery time

遗忘衡量每个窗口准确率相对其历史峰值的下降幅度。对窗口 k，其历史峰值 $A^{\max}(k) = \max_{t \in \mathcal{T}_{\text{eval}}} A(t,k)$，对应时刻 $t_k^{\max} = \arg\max_t A(t,k)$；窗口 k 的遗忘量

$$F_k = A^{\max}(k) - \min_{t \in \mathcal{T}_{\text{eval}},\, t \geq t_k^{\max}} A(t,k), \tag{30}$$

全局遗忘 $F = \mathbb{E}_k[F_k]$。

后向迁移 [32] 衡量训练结束时各窗口准确率相对其编码完成时的变化：

$$\text{BWT} = \frac{1}{N_w} \sum_{k=1}^{N_w} \big[A(T,k) - A^{\text{enc}}(k)\big]. \tag{31}$$

$\text{BWT} > 0$ 表示后续训练改善了早期窗口的表征，$\text{BWT} < 0$ 对应遗忘倾向。

恢复时间衡量评估窗口切换后准确率首次达到预定义恢复阈值所需的训练步数。对每次窗口切换 $k \to k+1$，设其切换时刻为 t_k^{swap}，切换前峰值为 $A^{\max}(k)$；恢复阈值为 $\eta_{\text{rec}} \cdot A^{\max}(k)$ ($\eta_{\text{rec}} = 0.95$，分析前固定)：

$$T_{\text{rec}}(k) = \min\big\{\Delta t \geq 0 : A\big(t_k^{\text{swap}} + \Delta t,\, k+1\big) \geq \eta_{\text{rec}} \cdot A^{\max}(k)\big\}. \tag{32}$$

若至训练结束 $A(t, k+1)$ 仍未达到该阈值，该切换记为右删失。报告 T_{rec} 在所有切换上的中位数。该指标对应 Fig. 4 中报告的 “恢复时间”。

Topology–data alignment: TAEF

受控数据流上额外报告 *time-aligned edit fraction* (TAEF)，衡量接受编辑事件与真实结构变化点的时间对齐程度。设接受编辑事件集合 $\mathcal{E}_{\text{edit}} = \{t_i^{\text{edit}}\} \subset \mathcal{H}_{\text{edit}}$ (由 Algorithm 1 记录)，真实阶段边界集合 $\mathcal{B} = \{b_1, \ldots, b_{|\mathcal{B}|}\}$ (仅在离线评估时可

见)。则

$$\mathrm{TAEF} = \frac{\left|\{t^{\mathrm{edit}} \in \mathcal{E}_{\mathrm{edit}} : \min_{b\in\mathcal{B}} |t^{\mathrm{edit}} - b| \le \Delta_{\mathrm{TAEF}}\}\right|}{|\mathcal{E}_{\mathrm{edit}}|}, \tag{33}$$

Δ_{TAEF} 为预设容差窗口 (默认 $\Delta_{\mathrm{TAEF}} = 1{,}000$ 步；数值见 Supplementary Table S2)。TAEF $= 1$ 表示所有接受编辑均与真实结构变化对齐，TAEF $\approx \Delta_{\mathrm{TAEF}}/(T/|\mathcal{B}|)$ 对应随机时机的零模型期望。该指标对应 Fig. 1f 的纵轴。

Residual-geometry external validation: AUROC and lead time

Fig. 2b,c 中对每个候选信号 $s \in \{\Xi_t,\ \mathcal{L}_{\mathrm{rec}}(t),\ \|\boldsymbol{\epsilon}_t\|_2,\ |\Delta\mathrm{ELBO}|,\ D_{\mathrm{KL}}\}$ 与每类外部事件 $\mathcal{E}_{\mathrm{ext}} \in \{$真实变化点, 探针崩溃$\}$，计算两个指标。

AUROC：将时间轴划分为长度 $W_{\mathrm{AUROC}} = 500$ 步的不重叠窗口，每个窗口标签 $y_w = \mathbf{1}\{w$ 含有$\mathcal{E}_{\mathrm{ext}}$ 中事件$\}$，窗口预测分数 $\bar{s}_w = \mathbb{E}_{t\in w}[s_t]$。为避免事件附近的标签泄漏，所有与最近事件距离不超过 $\Delta_{\mathrm{leak}} = W_{\mathrm{AUROC}}$ 步的负样本窗口不参与 AUROC 计算。AUROC 为剩余窗口集合上 $(\bar{s}_w, y_w)$ 的标准 ROC 曲线下面积。

Lead time：对每个事件 $\tau^{\mathrm{event}} \in \mathcal{E}_{\mathrm{ext}}$，设信号首次跨越阈值的时刻 $\tau_s^{\mathrm{signal}} = \min\{t < \tau^{\mathrm{event}} : s_t > \theta_s\}$，则

$$\ell_s(\tau^{\mathrm{event}}) = \tau^{\mathrm{event}} - \tau_s^{\mathrm{signal}}. \tag{34}$$

若 s_t 在事件前未跨越阈值，该事件记为右删失。阈值 θ_s 在与所测事件类型无关的独立保留窗口上按固定虚警率 $\alpha = 0.05$ 校准 (即 θ_s 取保留窗口内 s_t 的 95 分位数)，保证不同信号的 lead time 在相同虚警率水平下可比。报告 ℓ_s 在所有事件上的中位数。

emphReal-stream external validation. 真实流外部事件不依赖任何 SOMA 内部变量。预先定义的评估分布转变取自 CLEAR[19] 与 CLOC[20] 官方评估协议中的时间分桶边界；冻结探针准确率持续下降事件为：准确率相对转变前 $W_{\mathrm{base}} = 5$ 个评估点的滚动基线下降超过 $\delta = 5$ 个百分点，并在连续 $h = 2$ 个评估点上保持。Ξ_t 与所有标量对照诊断均从一个固定拓扑的被动监测模型上计算，该模型与 SOMA 共享骨干、优化器、训练数据流与平滑窗口 ($W_{\mathrm{smooth}} = W_{\mathrm{AUROC}}$)，但不允许任何拓扑编辑。标量诊断候选集合 $\{\mathcal{L}_{\mathrm{rec}}(t), \|\boldsymbol{\epsilon}_t\|_2, |\Delta\mathrm{ELBO}|, D_{\mathrm{KL}}\}$ 在分析前固定。Lead time 在评估频率的时间分辨率上度量。完整 AUROC 矩阵与固定虚警率 $\alpha = 0.05$ 下的误报统计见 Source Data。

四组因果干预 (I1–I4) 的施加位置、注入幅度与对照基线见 Methods 中 *Residual geometry: external prediction and causal interventions* 小节及 Fig. 2 图注。

Software, hardware and seeds

所有实验在 PyTorch (CUDA [ver]) 下实现, 统一使用单卡 NVIDIA [GPU-type] 训练; 所有 CAC 报告均基于单卡运行。启用 cuDNN `deterministic` 模式, 关闭 `benchmark`。主实验使用 n_{seed}=10 个独立种子, 覆盖模型初始化、数据划分、minibatch 采样与非平稳协议中的变点抖动; 因子可控视觉诊断 (Supplementary Note 6) 另用独立的 n_{seed}=5 子集。种子编排在 SOMA 与所有基线间一一对应, 以支持 Methods (*Evaluation metrics and statistical analysis*) 所述的种子内配对比较。软件版本、GPU 型号、显存与非确定性操作说明见 Supplementary Table [tab:compute]。

Architecture and optimization

SOMA 与所有重构类基线共用 Supplementary Table S1A 所列骨干: 卷积层 He 初始化, 全连接层 Xavier 初始化, 激活函数 GELU; 解码器输出层接 Sigmoid, 重构项在像素空间实现为 binary cross-entropy loss。对连续 RGB 图像 (Shapes3D, MPI3D, CLEAR, CLOC), BCE 被用作归一化像素重构损失; 所有重构类模型使用相同实现。SOMA 初始结构 $\phi_0=(I_1, b_0, 1)$, $d_{c,0}$=1; 潜在双头共享主干特征 $h_\theta(o) \in \mathbb{R}^{256}$ (Methods, *Inference model and structure-induced prior*)。连续参数 θ 由 AdamW [36] 更新, 学习率 η_0 线性预热 T_{warm}=[·] 步后保持常数; 权重衰减、动量与 minibatch 大小见 Supplementary Table S2。重构类模型共享同一优化器、基础学习率与总训练步数 T; 非重构类基线 (SimCLR, DINO, ER, A-GEM, DER++) 按其原文使用附加头部、辅助损失或记忆模块, 但保持相同骨干、训练步数、数据流与种子编排, 具体设置见 Supplementary Table S2。反向梯度施加 ℓ_2 全局裁剪 c_{clip}=[·]; 触发判据中的 g_t (eq. (4)) 在裁剪之前记录。

辅助归纳偏置项的权重 $\{\lambda_{\text{dis}}, \lambda_{\perp}, \lambda_{\text{sym}}\}$ 取为在预扫描中能稳定训练并避免 c/r collapse 与 posterior collapse 的最小值。合格判据仅检查训练损失曲线的有限性与 c, r 后验方差不退化至先验, 不使用下游探针准确率、Ξ^*、终段 (K^*, d_c^*) 或主文报告的任何指标。TC 与 $I_q(c;r)$ 估计采用 minibatch-weighted sampling [4]; KSG 估计 [37] 仅作为 Supplementary Note 6 中低维诊断的 sanity check, 不参与训练或主指标。

Residual statistics and Stage-II schedules

残差滑动窗口默认 W=50, 稳定区间 $[20, 200]$ (Fig. S2d); 能量阈值 η_{floor} 取为阶段 1 稳态校准窗口 $\text{tr}(\widehat{\Sigma}_t)$ 经验分布的第 5 百分位, 作为数值稳定下界。触发检查周期 τ_{check}=100, 触发判据 (eq. (5)) 在 M_{smooth}=[·] 个连续检查周期上联合判定。梯度门控 G_θ 取为同种子下阶段 1 稳态校准窗口 $\bar{g}_t$ 的经验中位数; G_θ 在此仅作为排除明显未收敛连续适配阶段的宽门控, 实际触发主要由持续高 $\bar{\Xi}_t$ 与 M_{smooth} 个连续检查周期共同决定。远离真实变点窗口 (定义同 Supplementary Note 4) 的非对齐 Stage-II 触发率在主扫描下保持 $< 10\%$。残差门控 G_ϕ 取为同窗口 Ξ_t 的经验第 95 百分位。G_θ 与 G_ϕ 在阶段 1 稳态校准窗口估计后冻结, 不随后续残差分布更新。窗口长度、能量阈值与替代谱统计量 (Ξ_t^{PCA}, 参与比倒数等) 下的鲁棒性见 Supplementary Note 4 与 Fig. S2。

Structural editing and complexity penalty

候选池规模 K_{cand}、split 幅度 α_{sp}、merge 数值稳定项 ϵ_w、warm-up 步数 n_{warmup}=50 (扫描区间 $[20, 200]$) 与结构预算上界 $K_{\max}, d_{c,\max}$ 见 Supplementary Table S2。在受控流形实验中, $K_{\max}, d_{c,\max}$ 取为内在拓扑参考量 $(K^{\text{int}}, d^{\text{int}})$ 的 4×; 在无解析内在拓扑的视觉基准 (dSprites, Shapes3D, MPI3D, CLEAR, CLOC) 中, 设为相同数量级的保守上界 (具体数值见 Supplementary Table S2)。在所有报告设置中, SOMA 终段结构均未触及该上界; 该上界仅作为数值安全约束, 不作为结构先验。warm-up 优化器与 Stage I 同构, 沿用 η_0。复杂度系数 λ_{cmp}=0.1, 稳定带 $[0.05, 0.5]$。

结构复杂度 $\mathcal{C}(\phi) = \omega_K K + \omega_E \|A\|_\tau + \omega_B d_c$ 中三分量权重 $(\omega_K, \omega_E, \omega_B)$ 按“单位结构编辑代价等量化” 原则设定: 新增一个节点、$\|A' - A\|_\tau$ 中一条 $|\Delta A_{ij}| > \tau_{\text{conn}}$ 的单条连接幅度变化、与一维共性维度在阶段 1 稳态校准窗口附近贡献相近数量级的复杂度增量。预扫描仅检查无单一项主导, 不使用相图、塌缩误差、Ξ^*、终段结构或下游指标。有效连接范数 $\|A\|_\tau$ 的阈值 τ_{conn} 取同种子下 A 元素绝对值分布中位数的固定比例 (具体比例见 Supplementary Table S2); 该阈值仅用于复杂度计数, 不参与 A 在 Stage I 中的连续梯度更新。

Baselines and training budgets

所有基线使用与 SOMA 相同的骨干、数据流、总训练步数 T 与随机种子集。重构类基线共享 SOMA 的 minibatch 大小与 Stage I 优化器; 非重构类基线的 batch 组织、增广视图、辅助头部与损失设置按原文实现, 具体见 Supplementary Table S2。β-VAE [3]、FactorVAE [18]、β-TCVAE [4] 与 DIP-VAE [35] 的解耦权

重在原文报告区间内通过独立预扫描设定, 准则为验证集 ELBO, 不使用主文非平稳指标。ER [23]、A-GEM [24]、DER++ [25] 共享统一 reservoir buffer, 不暴露任务标识。SimCLR [21] 与 DINO [22] 采用其原文增广与温度设置。高容量固定拓扑 VAE 的 d_z 设为同数据集 SOMA 终段 $d_c^* + d_r$ 的跨种子最大值, 其中 d_r 为该数据集固定的 side-component 维度, 以保证容量不低于 SOMA 终段。固定调度结构编辑基线沿用 SOMA 的算子集、继承规则、warm-up 预算与接受准则, 仅以预设间隔 τ_{fs} 触发; τ_{fs} 由独立预扫描中 SOMA 在保留配置上的平均触发率匹配, 不使用主实验中 SOMA 的实际触发次数 (Methods, *Controlled non-stationary manifold stream*)。所有基线超参数的具体数值与扩展扫描见 Supplementary Table S2 与 Extended Data Table **[ED-tab-baselines]**。

Geometric motivation for Cumulative adaptation cost (CAC)

SOMA 的适配同时包含两类更新——Stage I 的连续参数更新与 Stage II 的离散结构跃迁——我们希望用同一指标度量 "适配总成本"，而不是将两类更新分别用不可比较的单位 (例如 "参数变化量" 与 "编辑次数") 报告。CAC 的设计正是为此：它将参数路径与结构跃迁视为同一适配过程的两个分量，并以一个对参数化与算子选择都不敏感的度量统一度量其 "长度"。

对连续参数轨迹 $\theta : [0, T] \to \Theta$，其在模型诱导的概率分布族 $\{p_\theta(o \mid z, \phi)\}$ 上的 Fisher–Rao 路径长度为

$$L_{\text{FR}}(\theta) = \int_0^T \sqrt{\dot\theta(t)^\top F(\theta(t))\dot\theta(t)}\, dt, \tag{35}$$

$F(\theta)$ 为 θ 处的 Fisher 信息矩阵。L_{FR} 度量参数轨迹在该分布族上累计走过的距离，对参数的可逆重参数化保持不变。这一不变性对 CAC 的跨方法比较至关重要：不同方法 (SOMA、β-VAE、ER、DER++) 可能使用不同的参数化方式，若直接以参数欧氏距离作为代价，其数值会被参数化的人工选择决定，不再反映 "模型实际改变了多少"。

对离散结构跃迁 $\phi_{n-1} \to \phi_n$，Fisher–Rao 路径长度的自然推广是：跃迁前后两个模型在观测空间上的 KL 散度的平方根。直接计算该量需要在每次候选编辑后完整训练新结构，代价过高。我们因此在结构空间上引入与连续路径同尺度的局部度量 d_ϕ，以与复杂度先验 $\mathcal{C}(\phi)$ 相同的 $(\omega_K, \omega_E, \omega_B, \tau_{\text{conn}})$ 加权 (具体形式见下段)；这一选择使 "结构变化的复杂度" 与 "结构变化的代价" 在同一单位下度量，并由结构–参数耦合系数 μ 将两类更新对齐至同一尺度。

CAC 因此具有以下结构：

$$\mathrm{CAC} = \underbrace{W_{\mathrm{param}}(\theta_{0:T})}_{\text{Fisher–Rao 路径离散化}} + \mu \cdot \underbrace{\sum_n d_\phi(\phi_{n-1}, \phi_n)}_{\text{结构跃迁累计代价}}, \tag{36}$$

其中 W_{param} 是式 (35) 的可计算离散近似，具体取法在下段给出。该分解使 SOMA 与各基线之间的 CAC 比较不被 “某方法不编辑结构因而结构代价为零” 这一表面差异主导：连续参数路径与结构跃迁代价在同一度量框架下加和。

CAC implementation

本节给出式 (36) 中两个分量的具体离散化与跨方法统一计算约定。主 CAC 仅度量表征模型本体 (encoder、decoder 与潜在分支头部) 的适配路径，且仅记录被接受轨迹上的参数位移与结构跃迁；被拒绝候选的临时 warm-up 参数随候选丢弃 (Supplementary Note 1)，不计入 CAC。辅助网络 (FactorVAE 判别器、DINO 教师网络、SimCLR projection head) 与显式记忆 (DER++ logit/feature buffer, ER 与 A-GEM 的 reservoir buffer) 所对应的额外参数更新与存储成本在 Extended Data 中另行报告。该约定在所有基线间一致。

参数路径分量 W_{param}。作为式 (35) 在 $F \approx I$ 时的离散近似，

$$W_{\mathrm{param}} = \sum_n \|\theta_{t_n} - \theta_{t_{n-1}}\|_2, \tag{37}$$

快照间隔 Δt_{snap} 跨方法统一；快照仅包含表征本体的参数，不含优化器状态。该近似在所有方法使用相同骨干、相同初始化规模、相同优化器配置时构成合理代理。作为 robustness check，我们额外报告对角 Fisher 缩放版本 $\sum_n \sum_i \hat{F}_{ii}^{(n)} (\theta_{t_n,i} - \theta_{t_{n-1},i})^2$，$\hat{F}_{ii}^{(n)}$ 由小批量梯度平方平均估计；两种度量下 SOMA 相对固定拓扑与固定调度基线的 CAC 排序一致 (Extended Data Fig. [ED-fig-cac])。

结构跃迁分量 $d_\phi(\phi_{n-1}, \phi_n)$。使用与 $\mathcal{C}(\phi)$ 相同的 $(\omega_K, \omega_E, \omega_B)$ 与 τ_{conn} 对节点变化、有效连接变化与共性维度变化加权，使 “结构变化的复杂度” 与 “结构变化的代价” 在同一单位下度量。τ_{conn} 的具体取值与 $\mathcal{C}(\phi)$ 共用，见 *Structural editing and complexity penalty* 段。

结构–参数耦合系数 μ。μ 设为阶段 1 稳态校准窗口内 W_{param} 与单位结构编辑代价 d_ϕ^{unit} 的中位比值：

$$\mu = \mathrm{median}_s \left[W_{\mathrm{param}}^{(s)} / d_\phi^{\mathrm{unit}} \right],$$

d_ϕ^{unit} 由独立校准流中候选单位编辑的 d_ϕ 中位数估计。候选单位编辑包括一次节点 split/merge、一条 $|\Delta A_{ij}| > \tau_{\text{conn}}$ 的连接变化，或一维 d_c 的 grow/prune。校准流与主实验数据互不重叠。该定义对 $\mathcal{C}(\phi)$ 的初始尺度不敏感，跨方法沿用同一 μ；μ 在 $[0.5\times, 2\times]$ 扰动下跨方法 CAC 排序不变。

Compute budget

单种子典型墙钟运行时长: 受控流形流 [[·] **GPU-h**], 非平稳视觉基准 [[·] **GPU-h**], 残差几何外部诊断 [[·] **GPU-h**], 相图扫描单配置 [[·] **GPU-h**]。Stage II 的边际墙钟成本来自两部分: 残差统计的滑动更新与周期性谱分解 (具体复杂度随残差维度与是否启用低秩/特征空间实现而定; 实现细节见 Supplementary Table S2), 以及触发后候选 warm-up 的额外计算 (上界为 $K_{\text{cand}} \cdot n_{\text{warmup}}$ step; first-accept 可提前终止, 且仅在触发周期产生)。该额外开销作为 compute budget 单独报告, 不计入 CAC (被接受轨迹之外的临时更新不进入 CAC, 见上一段)。SOMA 相对固定拓扑 VAE 的训练时间增量 $\leq$ [[·]%]。主实验、敏感性扫描与 Supplementary 实验合计约 [[·] **GPU-h**]。

Sensitivity analyses and reproducibility

主要超参数在 Supplementary Table S2 列出的扫描区间内对 (K^*, d_c^*)、Ξ^*、forgetting、T_{rec} 与 CAC 的影响汇总于 Fig. S1。该扫描为事后敏感性检查, 独立于默认值选取流程。稳定带定义为: 效应方向跨种子一致, 且指标变化处于跨种子误差范围 (s.e.m.) 之内; 显著性检验 (Wilcoxon signed-rank, BH 校正) 作为辅助参考。据此识别出的稳定区间为 $\lambda_{\text{cmp}} \in [0.05, 0.5]$, $W \in [20, 200]$, $\tau_{\text{check}} \in [50, 200]$, $n_{\text{warmup}} \in [20, 200]$, η_{floor} 与 G_θ 的 $[0.5\times, 2\times]$ 区间; G_ϕ 在 P_{90}–P_{99} 内, 仅触发频次随分位数下移而升高。辅助权重 $\{\lambda_{\text{dis}}, \lambda_\perp, \lambda_{\text{sym}}\}$ 在 $[0.5\times, 2\times]$ 范围内不改变主文指标的效应方向, 跨数据集的中位相对变化低于 5%。本节稳定带与 Supplementary Note 3 中关于结构编辑接受序列的路径依赖讨论一致: 稳定带内 SOMA 终段 (K^*, d_c^*) 与 Ξ^* 跨种子分布保持一致, 具体编辑历史可在路径依赖允许范围内变化。随机种子、数据划分、变点时刻、配置文件与预扫描日志均随 Code/Data availability 中的仓库发布; 默认值、扫描范围与稳定带分别对应仓库的 `configs/` 与 `sensitivity/` 目录。

表 S1 Model architecture and structural-variable parameterization. A 部分列出编码/解码骨干; **B** 部分列出 SOMA 结构状态 $\phi = (A, B, K)$ 的参数化。输入图像尺寸 $64 \times 64 \times 3$; 所有实验共享该骨干, 基线与 SOMA 的差异仅在目标函数与结构状态是否可演化。

Module	Layer configuration	Output dim	Note
A. Encoder/decoder backbone			
Encoder	Conv(32,4,2) → Conv(32,4,2) → Conv(64,4,2) → Conv(64,4,2) → FC(256)	$64^2 \to 4^2 \times 64 \to 256$	GELU; 所有基线共用
Posterior heads	FC_{μ_c}, $\mathrm{FC}_{\log\sigma_c}$, FC_{μ_r}, $\mathrm{FC}_{\log\sigma_r}$	d_c / d_c / d_r / d_r	c–r 双分头
Decoder	FC(256) → Deconv(64,4,2) → Deconv(64,4,2) → Deconv(32,4,2) → Deconv(3,4,2)	$\to 64^2 \times 3$	GELU, 输出 Sigmoid; 对称结构
B. Structural variables $\phi = (A, B, K)$			
Nodes K	离散, 由 split/merge 演化	—	初始 K=1
Connection matrix A	$A = \mathrm{softplus}(W_A)$,$W_A \in \mathbb{R}^{K\times K}$	$K \times K$	初始 I_K, 非负
Basis matrix B	可学习, 由 grow/prune 改变行数	$d_c \times K$	初始 d_c=1

表 S2 Default hyperparameters of SOMA and their rationale. 参数按功能角色分组;"$[0.5\times, 2\times]$" 表示相对默认值的扫描范围。详细敏感性分析见 Supplementary Note 7 与 Fig. S1。

Parameter	Default	Search range	Rationale
Objective function weights			
λ_{cmp}	0.1	$[0.01, 1.0]$	稳定带 $[0.05, 0.5]$ 中值;Fig. S1a
λ_{dis}	[•]	$[0.5\times, 2\times]$	指标变化 $< 5\%$
$\lambda_{\perp}$	[•]	$[0.5\times, 2\times]$	同上
λ_{sym}	[•]	$[0.5\times, 2\times]$	同上
Structural triggers and checks			
τ_{check}	100	$\{50, 100, 200, 500\}$	响应延迟可接受
W	50	$[20, 200]$	误触发率 $< 10\%$
G_θ	[•]	$[0.5\times, 2\times]$	梯度门控, 稳定
G_ϕ	P_{95}	—	预训练残差 95 分位数
Candidate evaluation and stopping			
n_{warmup}	50	$\{10, \ldots, 200\}$	可靠性 / 成本折中
ε_θ	[•]	$[0.5\times, 2\times]$	仅影响步数
ε_ϕ	[•]	$[0.5\times, 2\times]$	仅影响步数
γ (CAC 权重)	[•]	[•]	见 Supplementary Note 8

表 S3 Dataset specifications, factor partitions and non-stationary protocol parameters. A 列出 Stage I 几何流形与少样本视觉基准的数据规格; **B** 列出三套视觉基准上 $\mathcal{F}_{\text{inv}}$ 与 $\mathcal{F}_{\text{side}}$ 的因子归类, 仅用于冻结编码器后的评估; **C** 列出三类非平稳协议的参数化。Protocol A–C 均以 Shapes3D 为底层数据源。字段含义与度量定义见 Supplementary Note 8。

A. Dataset specifications

Dataset	N_{total}	Channels	Resolution	Factors (levels)
S^1	[•]	3	64^2	$\alpha \in [0, 2\pi)$
T^2	[•]	3	64^2	$(\alpha_1, \alpha_2) \in [0, 2\pi)^2$
S^2	[•]	3	64^2	(ϑ, φ) on S^2
dSprites[3]	737,280	1	64^2	shape(3), scale(6), orient.(40), x(32), y(32)
Shapes3D[18]	480,000	3	64^2	floor(10), wall(10), obj-col(10), scale(8), shape(4), orient.(15)
MPI3D[33]†	1,036,800	3	64^2	obj-col(6), shape(6), size(2), cam-h(3), bg-col(3), x(40), y(40)

B. Dataset-specific factor partitions

Dataset	$\mathcal{F}_{\text{inv}}$ (stable, reusable)	$\mathcal{F}_{\text{side}}$ (contextual)
dSprites	shape, scale	orientation, x-pos, y-pos
Shapes3D	object color, object shape, scale	floor color, wall color, orientation
MPI3D	object color, object shape, size	camera height, bg color, x-pos, y-pos

C. Non-stationary protocols

Protocol	Shift form	M	Δ / P	Manipulated factors
A (abrupt)	step at $\{\tau_m\}$	[•]	—	shape subset
B (drift)	linear on $[\tau, \tau{+}\Delta]$	[•]	$\Delta = [\cdot]$ ep.	floor hue
C (cyclic)	period-P over M envs	[•]	$P = [\cdot]$ ep.	{shape, wall, light} triple

T_{run}=[·] episodes;online batch size B=[·]; 变点 τ_m 在有效运行区间内近似均匀放置, 附 ±[·] ep. 抖动。†MPI3D subversion: [·].

Supplementary tables and figures

Data availability

Publicly available datasets used in this study are obtainable from their original sources: dSprites[3] (https://github.com/deepmind/dsprites-dataset),

Shapes3D[18] (https://github.com/google-deepmind/3d-shapes), MPI3D[33] (authors' project page), CLEAR[19] and CLOC[20] (official benchmark distributions). Per-seed numerical values underlying all panels of Figs. 1–4 and the Extended Data figures and table are provided as Source Data with this paper. The controlled non-stationary streams used in Figs. 1 and **??**, together with all topology-edit logs, are deposited at Zenodo (`10.5281/zenodo.[XXXXXXX]`).

Code availability

Training and analysis code, configuration files and figure-generation scripts are available at https://github.com/ORG/soma **[replace ORG with org name]** and permanently archived at Zenodo (`10.5281/zenodo.XXXXXXX`) **[insert Zenodo DOI]**.

Acknowledgements

感谢国家自然科学基金 (项目编号：XXXXX) 对本研究的支持。

Author contributions

J.X. 提出了 SOMA 框架并推导了自由能目标函数；C.Y. 实现了拓扑算子并进行了数值模拟；J.X. 与 C.Y. 共同分析了实验数据并撰写了论文。

Competing interests

The authors declare no competing interests.

图 S1 Hyperparameter sensitivity of SOMA. 扫描分为三组, 对应目标函数权重、结构触发与检查机制、以及候选评估预算与跨数据集复现; 每点 n=5 独立随机种子, 均值 ± s.e.m., 除特别说明外均在双因子环面数据上进行。**a,** 复杂度权重 λ_{cmp} 扫描; 绿色阴影标注稳定带 $[0.05, 0.5]$。**b,** 三联子面板:λ_{dis}、$\lambda_{\perp}$、λ_{sym} 分别在默认值 $[0.5\times, 2\times]$ 邻域内对 MIG / DCI / S_{inv} 的影响。**c,** 结构检查间隔 τ_{check}; **d,** 梯度门控阈值 G_θ; 两者在默认值的合理邻域内均保持最终拓扑不变。**e,** 短程重适配步数 n_{warmup} 对编辑命中率 (左轴, 实线) 与单次评估计算开销 (右轴, 虚线) 的影响, 黑箭头示主实验取值。**f–g,** λ_{cmp} 与 n_{warmup} 在 dSprites 上的重复扫描, 稳定带位置与双因子环面结果一致。残差窗口 W 的敏感性属 Ξ_t 估计机制的组成部分, 另见 Supplementary Note 6 与 Fig. S2d。详细阈值、统计检验与逐项讨论见 Supplementary Note 7 正文。

图 S2 Robustness of the trigger statistic and the proposal-scoring mechanism. a, 协方差归一化提案分数 s_{op} 与欧氏基线分数 $s_{\mathrm{op}}^{\mathrm{Euc}}$ 的比较，评估指标包括触发精度、错误编辑率以及最终收敛目标值 $\mathcal{V}$。在残差各向异性较强的情形下，协方差归一化分数表现出更高的可靠性。**b,** 三种残差统计量所得到的触发时刻一致性比较：正文采用的条件数统计量 Ξ_t、参与比倒数统计量 $1/\Xi_t^{\mathrm{PR}}$，以及前 k 个主成分累计能量统计量 Ξ_t^{PCA}。结果在双因子环面与 dSprites 数据上给出。**c,** 在三种触发统计量下得到的最终涌现结构 (K^*, d_c^*) 以及解耦相关指标 (MIG、DCI 与 S_{inv}) 比较。不同统计量下得到的结构与表征指标总体保持一致。**d,** 残差窗口长度 $W \in \{10, 20, 50, 100, 200\}$ 的敏感性分析，评估指标包括编辑命中率、稳定阶段误触发率以及最终涌现拓扑。在较宽的中间区间内，性能整体稳定；仅当窗口过短时，误触发有所升高。**a** 为 10 次独立重复的均值 ± s.d.。精确统计结果见 Supplementary Note 3 与 Supplementary Note 6。**b–d** 为 5 个独立随机种子的均值 ± s.e.m.；

图 S3 Extended Data Fig. 1 | Full results of topological emergence across synthetic manifolds. a–c, 三类合成流形 (**a**, 单因子环;**b**, 双因子环面;**c**, 球面) 上节点数 K(上) 与共性流形维度 d_c(下) 随训练步数的演化轨迹; 浅色线为 5 随机种子, 深色线为均值, 灰色虚线为各场景的真实内在维度。**d,** 误差–复杂度平面上 SOMA 的演化路径 (彩色实线, 对应 **a–c** 三场景) 与固定拓扑扫描构建的参考帕累托前沿 (灰色虚线)。**e,** 不同随机种子下最终 (K^*, d_c^*) 的收敛分布 (散点 + 核密度等高线); 红色十字标记数据真实内在维度。**f,** 三场景下 S_{inv}、MIG 与 DCI 三指标的跨种子分布 (SOMA 与 β-VAE、FactorVAE 对比, 小提琴图内为箱线图)。n=5 独立随机种子, 均值 ± s.e.m.; 双侧配对置换检验 + Holm 校正,$^{**}P$<0.01,$^{***}P$<0.001。

图 S4 Extended Data Fig. 2 | Full cross-dataset few-shot reuse and component-wise linear-probe results. a–c, dSprites、Shapes3D 与 MPI3D 上的线性探针准确率–支撑样本数曲线; SOMA 与全部五基线 (VAE、β-VAE、FactorVAE、DIP-VAE、Ada-GVAE) 对比, $k \in \{1, 2, 5, 10, 20, 50\}$, 阴影为 s.e.m. **d–f,** 对应数据集上的达标适配步数 T_{adapt} 与单位性能适配代价 $\text{Cost}_{\text{adapt}}$ 柱图。**g,** 分量线性探针实验。分别以 c 与 r 为输入训练线性读出器，比较稳定因子 (形状、大小、颜色) 与情境相关因子 (位置、朝向、光照) 的解码准确率。三数据集均值显示，c 在稳定因子上、r 在情境相关因子上分别取得更高解码准确率。n=5 独立随机种子, 均值 ± s.e.m.; 双侧配对置换检验 + Holm 校正,$^{**}P$<0.01,$^{***}P$<0.001。

图 S5 Extended Data Fig. 3 | Per-protocol full results of non-stationary continual adaptation. a–c, 三类非平稳协议下的完整性能恢复曲线: **a**, 概念集合突变;**b**, 参数渐变漂移;**c**, 环境循环切换; SOMA 与四个基线 (固定拓扑、固定频率调度、EWC、变化检测 + 手动扩展) 的逐协议对比; 虚线标记真实分布变化时刻, 阴影为 s.e.m. **d–f,** 对应协议下累计适应成本 CAC 的两分量分解 (W_{param} 参数路径代价 vs. C_{topo} 结构编辑代价)。**g,** Stage II 机制在三协议下的稳定性: 触发精度 (正确触发 / 总触发) 与编辑命中率 (至少一个候选通过 $\Delta\mathcal{V} < 0$ 接受准则的触发事件占比)。**h,** CAC sensitivity to the structural-cost weight λ_{struct} on CLEAR (top) and CLOC (bottom). For each value of $\lambda_{\text{struct}} \in [\lambda_{\text{lo}}, \lambda_{\text{hi}}]$ (default in bold), the CAC reduction of SOMA relative to the strongest non-SOMA replay baseline is plotted; the relative ranking of SOMA versus baselines is preserved over this range, indicating that the CAC advantage reported in Fig. 4e is not an artefact of the default weight choice. n=5 独立随机种子, 均值 ± s.e.m.; 双侧配对置换检验 + Holm 校正,$^{**}P$<0.01,$^{***}P$<0.001。

图 S6 Extended Data Fig. [N] | Edit proposal, acceptance dynamics and external diagnostic validation on the controlled and non-stationary visual streams. Complement to Figs. 1, 4 and 2. **a,** Post-adaptation $\Delta\mathcal{V}$ for all proposed edits on the controlled stream. Points, individual proposals; inset, fraction satisfying $\Delta\mathcal{V}<0$. Residual-driven proposals yield a higher fraction of negative $\Delta\mathcal{V}$ than fixed-schedule proposals. **b,** Timing of proposed (grey ticks) and accepted edits on the controlled stream (blue, SOMA; orange, fixed-schedule). SOMA proposals concentrate near ground-truth phase boundaries (dashed lines); fixed-schedule proposals occur at preset intervals. **c,** AUROC of Ξ_t and the four pre-specified scalar diagnostics ($\mathcal{L}_{\text{rec}}$, $\|\boldsymbol{\epsilon}\|_2$, $|\Delta\text{ELBO}|$, D_{KL}) on CLEAR and CLOC, computed on a passive fixed-topology monitor (Methods, *Real-stream external validation*). External events: pre-defined evaluation-protocol distributional shifts and sustained frozen-probe accuracy drops. **d,** Lead time of Ξ_t versus the strongest scalar diagnostic on each stream. Bars and points, mean ± s.e.m. across n=10 random seeds; full diagnostic matrices and false-alarm summaries are reported in Source Data.

图 S7 Extended Data Fig. [N] | Trigger-signal controls on the controlled stream. Editing variants share SOMA's local edit operators, parameter-inheritance rules, short re-adaptation budget and $\Delta\mathcal{V}<0$ acceptance criterion, and differ only in when candidate edits are proposed. **a,** Time-aligned edit fraction (TAEF) for residual-geometry triggering (SOMA), residual-magnitude triggering (M-trig), random triggering matched for the number of candidate edits (R-trig, candidate-matched), and oracle triggering at ground-truth structural transitions (O-cp). TAEF is computed within a fixed $\pm\Delta_{\text{TAEF}}$-sample window around known transition times. SOMA approaches the oracle-triggered control; M-trig and R-trig reduce alignment. **b,** Cumulative adaptation cost (CAC) for the same editing variants, normalized to SOMA. **c,** Directional-residual persistence under the compute-matched fixed-topology control (CM-fix): residual anisotropy Ξ_t during phase 3 at three compute budgets (1×, 2× and 3× the default T). Residual directionality remains under the additional optimization budgets tested here. **d,** Robustness check: TAEF and CAC for an accepted-edit matched variant of R-trig (post-hoc diagnostic control). Results are qualitatively consistent with the candidate-matched version in **a,b**. **e,** Downstream linear-probe accuracy on phase 3 for SOMA and all trigger controls. SOMA and O-cp recover comparable accuracy; M-trig, R-trig and fixed-schedule baselines recover incompletely. Bars/lines, mean across n=10 seeds; error bars or shading, s.e.m.

表 S4 Extended Data Table 1 | Full ablation matrix of SOMA design components. Ablation of SOMA's design components on the controlled stream, complementing the mechanism reported in Figs. 1 and 4. Rows: full SOMA and five ablation variants—removal of $\mathcal{L}_{\text{dis}}$, $\mathcal{L}_{\perp}$ or $\mathcal{L}_{\text{sym}}$ (auxiliary inductive biases), removal of the complexity prior $\mathcal{C}(\phi)$ (reconstruction-only acceptance), and replacement of the residual-geometry proposal score by random candidate selection. Columns: common-subspace invariance S_{inv} (higher is better), time-aligned edit fraction TAEF (higher is better), over-evolution rate (fraction of accepted edits reversed within $\leq 2\tau_{\text{check}}$ steps; lower is better), cumulative adaptation cost CAC (lower is better), and backward transfer BWT (higher is better). ↓ / ↑ marks differences from full SOMA significant at $P < 0.05$ (two-sided Wilcoxon signed-rank, BH-corrected for FDR across variants within each metric). Ablation protocol and per-seed values are given in Source Data.

消融设置	S_{inv} ↑	TAEF ↑	过度演化率 ↓	CAC ↓	BWT ↑
完整 SOMA	[·]	[·]	[·]	[·]	[·]
去 $\mathcal{L}_{\text{dis}}$	[•]↓	[•]↓	[•]↑	[•]	[•]↓
去 $\mathcal{L}_{\perp}$	[•]↓	[•]	[•]	[•]	[•]
去 $\mathcal{L}_{\text{sym}}$	[•]↓	[•]	[•]	[•]	[•]
去 $\mathcal{C}(\phi)$ (仅重构接受)	[•]	[•]↓	[•]↑↑	[•]↑	[•]↓
去提案分数 (随机候选排序)	[•]	[•]↓	[•]	[•]↑	[•]↓

$n = 10$ 独立种子, 均值 ± s.e.m.; ↓ / ↑ 标记与完整 SOMA 相比显著下降 / 上升 ($P < 0.05$, BH-corrected)。

表 S5 Extended Data Table S5 | SOMA relative to methods that change representational capacity, routing or structure. The contrast is not whether capacity can change, but when, and on what internal signal, latent topology is reorganized. The last column marks three properties that define SOMA's mechanism: (O) parameter adaptation and structural acceptance share one fit–complexity objective; (L) structural growth is complexity-limited; (G) residual covariance geometry is used as the trigger and as an independent diagnostic. •, present; ○, partial; —, absent. Rows summarize representative families rather than all variants.

Method family	What changes?	When?	Trigger signal	O / L / G
Growing neural gas / SOM[5, 6]	nodes / map	continually	local quantization error	— / ○ / —
Bayesian nonparametrics[7]	components	inference	likelihood–prior trade-off	○ / • / —
Dynamic architectures / NAS[**? ? ?**]	architecture	search phase	validation objective	— / ○ / —
Mixture-of-experts[8–11]	active experts	every input	learned router	— / — / —
Modular networks[12, 13]	module routing	every input	learned controller	— / — / —
Adapter / LoRA expansion[14–16]	adapter capacity	per task / stage	task identity or val. loss	— / ○ / —
Continual-learning replay[24, 25, 32]	parameters / memory	continually	replayed loss	— / — / —
Change-point / drift detection	detection only	at detected shift	statistical test	— / — / —
SOMA (this work)	latent topology	event-triggered	residual covariance geometry	• / • / •