Xi-B 残差谱信号实验报告

四组数据集：controlled（受控流形）、dSprites、3D Shapes、CIFAR / CIFAR-C
报告日期：2026-08-26　信号：Xi-B / Psi（白化重构残差的超 MP 边缘谱质量）

1. 实验目的

在纯 loss-only VAE 训练下，测量重构残差经白化后协方差谱在 Marchenko-Pastur（MP）边缘之上的超边缘谱质量 Xi-B / Psi，作为「谱组织」而非「统一幅度」的被动诊断信号。

2. 信号定义

每步残差 ε = x_hat − x 投影到固定特征空间 h(ε)，用当前阶段基线 (μ0, Σ0) 白化得到 η = Σ0^(-1/2)(h(ε) − μ0)。
取长度为 W 的滚动窗口 η，构造迹归一化协方差 C_tilde = d·C / tr(C)，MP 边缘 λ_edge = (1 + sqrt(d/(W−1)))^2。
Xi-B = Σ_i [λ_i(C_tilde) / λ_edge − 1]+（超边缘谱质量），spike_rank = #{λ_i > λ_edge}。

3. 训练协议

- loss-only VAE：目标 = 重构损失 + β_KL·KL（β_KL = 0.001），信号不参与训练。
- 三阶段课程：每阶段 1000 step，共 3000 step；每阶段 4096 训练样本 + 4096 probe 样本（probe 内部 70/30 切分）。
- 每个 latent 维度跑 seed = 0, 1, 2 三个种子。
- 共同超参：gamma = 0.00625，alpha = 0.1，读出方式 = spectral mass。

4. 方法与跨数据集说明

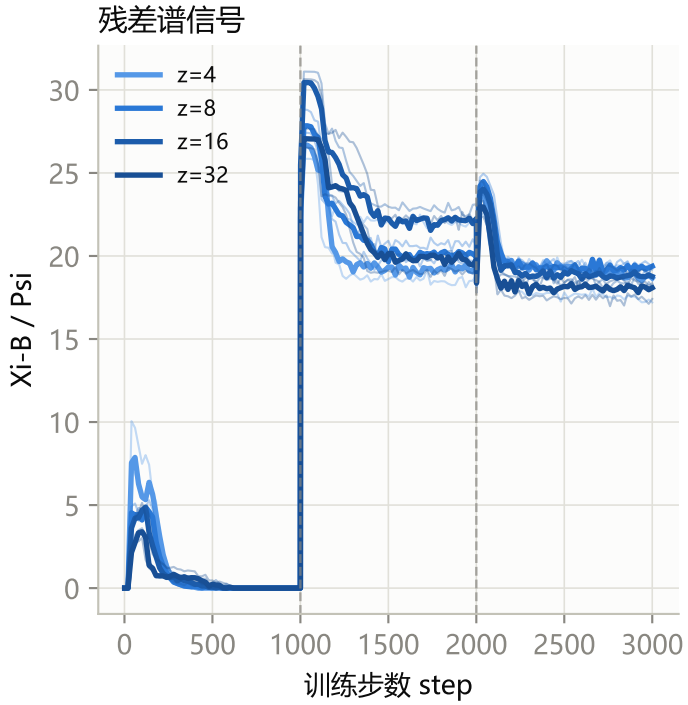
四组数据集均测量同一 Xi-B / Psi 信号（白化重构残差的超 MP 边缘谱质量）；controlled 的 xi_pw 与其余三组的 xi_b 是同一信号的两种内部命名。

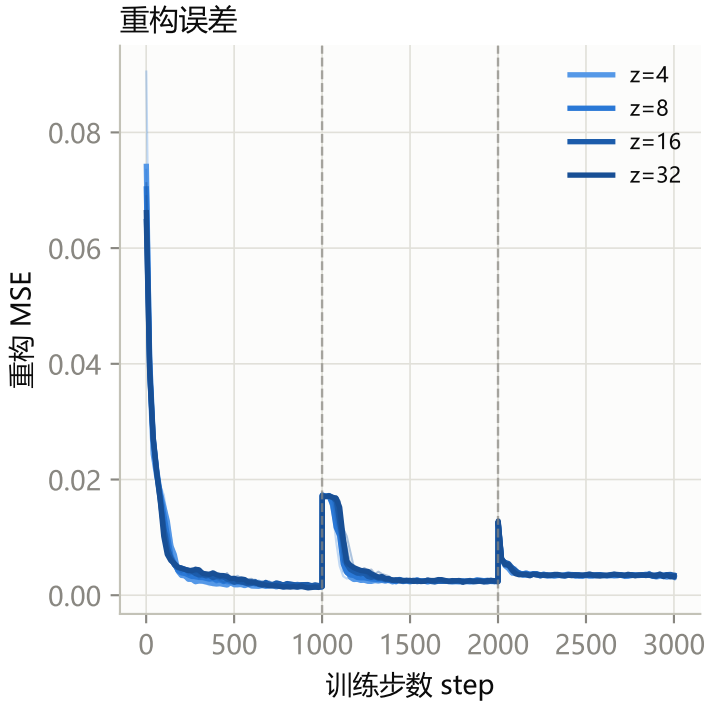
注：controlled 的参数化与其余三组略有差异（特征维 d=64、窗口 W=1024、阈值采用经验校准 tau_null；其余为 d=256、W=512、理论 λ_edge），故绝对量级对比需结合参数一并理解，跨组以趋势与稳定性为准。

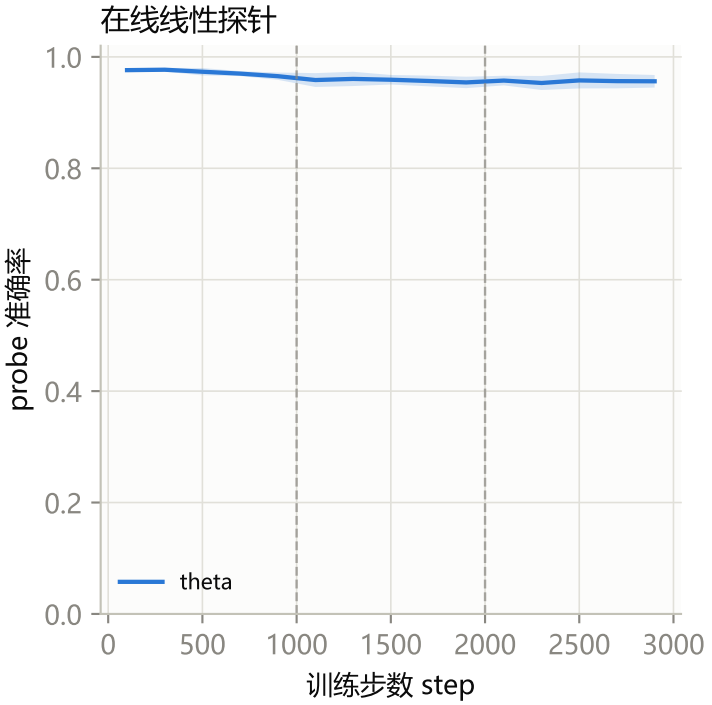
跨数据集汇总（最终 step 3000，3 个种子均值）

数据集	z	Xi-B / Psi	重构 MSE	KL	spike_rank	probe 准确率（最终）
controlled（受控流形	4	18.4 ± 0.878	0.0033	5.92	3.0	theta 0.97
controlled（受控流形	8	19.3 ± 0.0976	0.0032	5.95	3.0	theta 0.96
controlled（受控流形	16	18.8 ± 0.547	0.0035	5.98	3.0	theta 0.94
controlled（受控流形	32	18 ± 0.396	0.0033	5.96	3.0	theta 0.95
dSprites	8	0 ± 0	0.0067	13.1	0.0	orientation 0.02, shape 0.55, x 0.21, y 0.26
dSprites	16	0 ± 0	0.0065	13.4	0.0	orientation 0.03, shape 0.42, x 0.19, y 0.24
dSprites	32	0.00753 ± 0.0107	0.0065	14	0.3	orientation 0.03, shape 0.46, x 0.25, y 0.29
CIFAR / CIFAR-C	16	0.0706 ± 0.0135	0.0208	7.19	2.7	class 0.32
CIFAR / CIFAR-C	32	0.0597 ± 0.0236	0.0206	6.92	3.3	class 0.34
CIFAR / CIFAR-C	64	0.058 ± 0.0227	0.0209	6.75	3.0	class 0.37
3D Shapes	16	5.06 ± 5.45	0.0391	2.72e+04	15.3	floor_hue 0.99, object_hue 0.97, orientatio
3D Shapes	32	1.92 ± 1.05	0.0103	7.47	10.0	floor_hue 1.00, object_hue 0.98, orientatio
3D Shapes	64	1.38 ± 0.288	0.0097	7.44	9.7	floor_hue 1.00, object_hue 1.00, orientatio

controlled（受控流形）







最终指标（3 个种子均值 ± 标准差）

z=4: 信号 18.4 ± 0.878　MSE 0.0033　KL 5.92　spike_rank 3.0

　　probe → theta=0.97

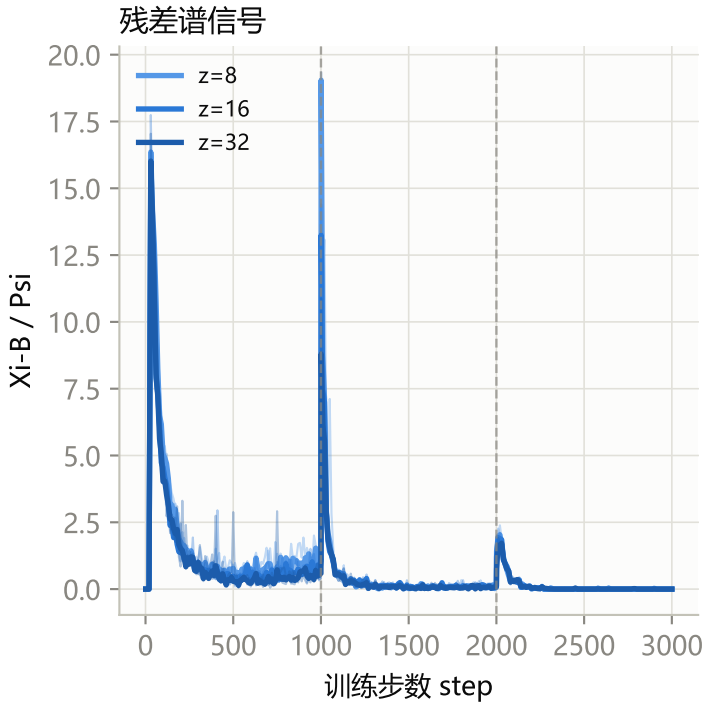
z=8: 信号 19.3 ± 0.0976　MSE 0.0032　KL 5.95　spike_rank 3.0

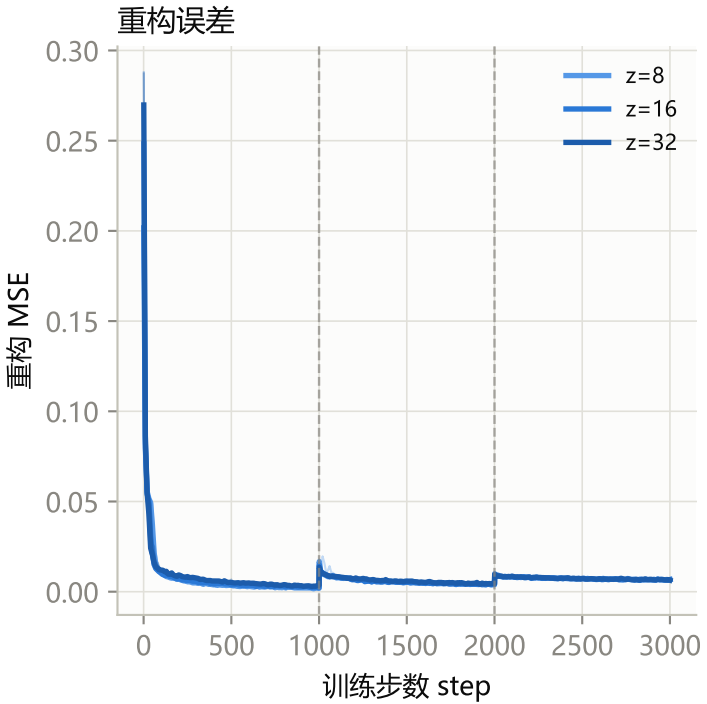
　　probe → theta=0.96

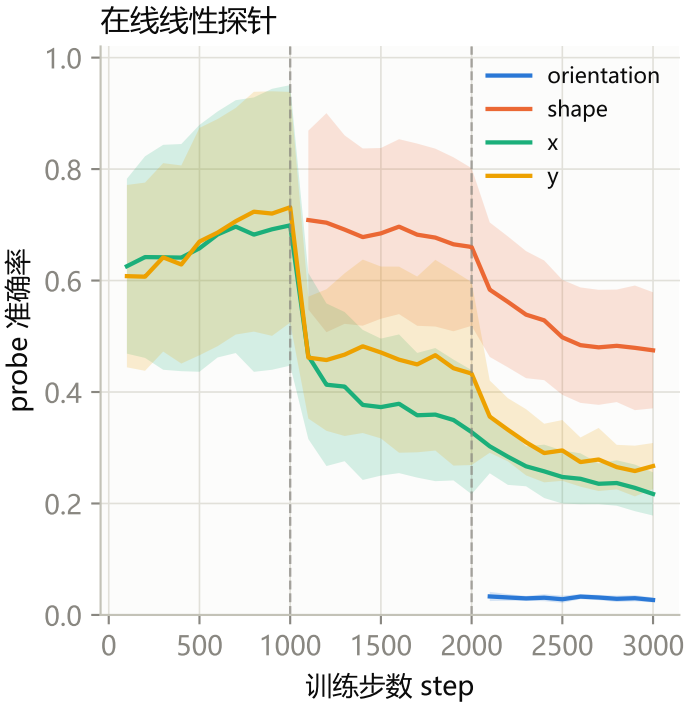
z=16: 信号 18.8 ± 0.547　MSE 0.0035　KL 5.98　spike_rank 3.0

　　probe → theta=0.94

dSprites


残差谱信号
Xi-B / Psi
z=8
z=16
z=32
20.0
17.5
15.0
12.5
10.0
7.5
5.0
2.5
0.0
0
500
1000
1500
2000
2500
3000
训练步数 step


重构误差
重构 MSE
z=8
z=16
z=32
0.30
0.25
0.20
0.15
0.10
0.05
0.00
0
500
1000
1500
2000
2500
3000
训练步数 step


在线线性探针
probe 准确率
orientation
shape
x
y
1.0
0.8
0.6
0.4
0.2
0.0
0
500
1000
1500
2000
2500
3000
训练步数 step

最终指标（3 个种子均值 ± 标准差）

z=8: 信号 0 ± 0　MSE 0.0067　KL 13.1　spike_rank 0.0

　　probe → orientation=0.02, shape=0.55, x=0.21, y=0.26

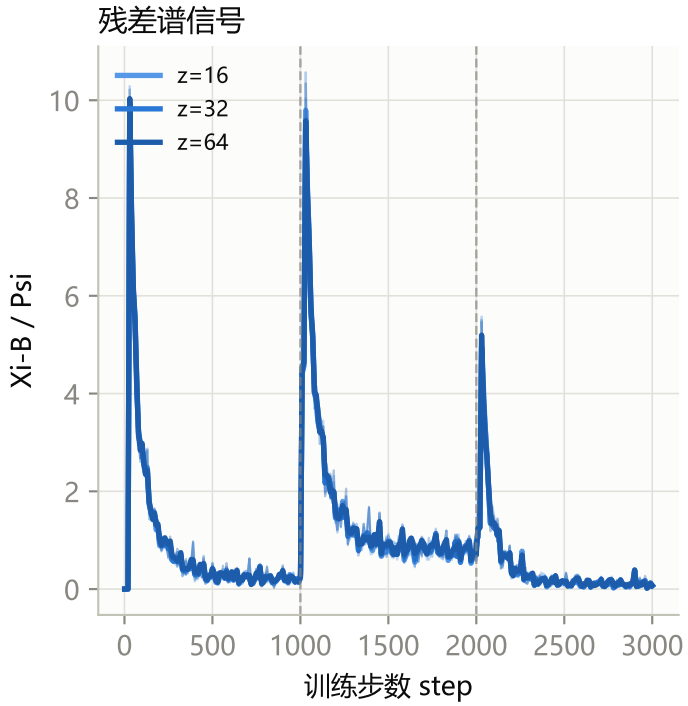
z=16: 信号 0 ± 0　MSE 0.0065　KL 13.4　spike_rank 0.0

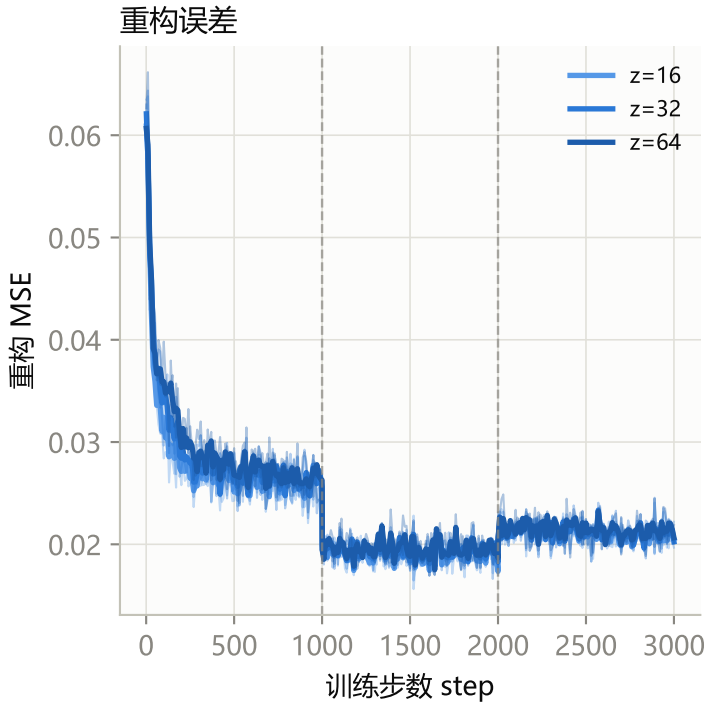
　　probe → orientation=0.03, shape=0.42, x=0.19, y=0.24

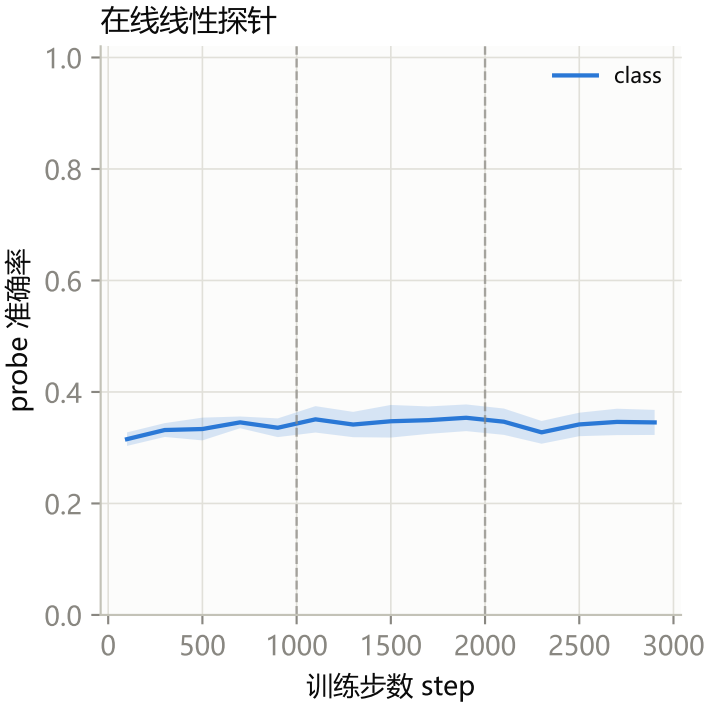
z=32: 信号 0.00753 ± 0.0107　MSE 0.0065　KL 14　spike_rank 0.3

　　probe → orientation=0.03, shape=0.46, x=0.25, y=0.29

CIFAR / CIFAR-C







最终指标（3 个种子均值 ± 标准差）

z=16: 信号 0.0706 ± 0.0135   MSE 0.0208   KL 7.19   spike_rank 2.7

probe → class=0.32

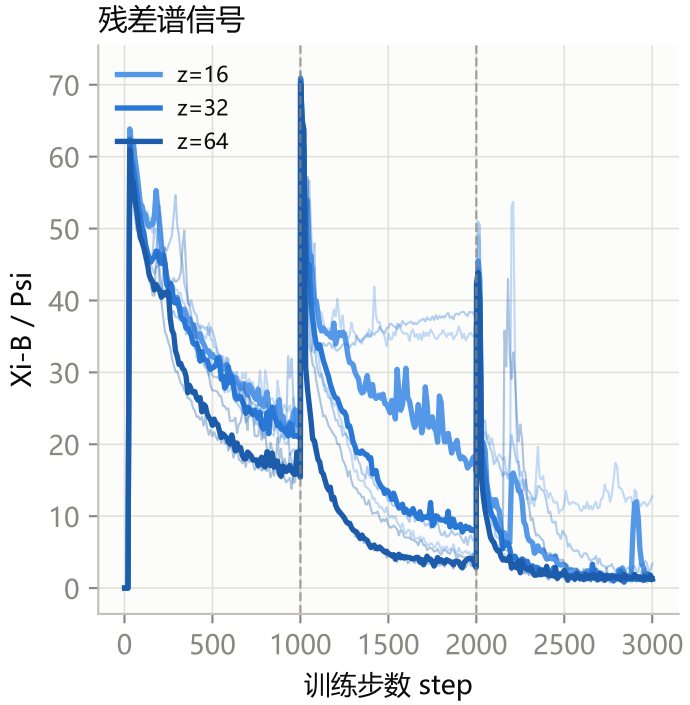
z=32: 信号 0.0597 ± 0.0236   MSE 0.0206   KL 6.92   spike_rank 3.3

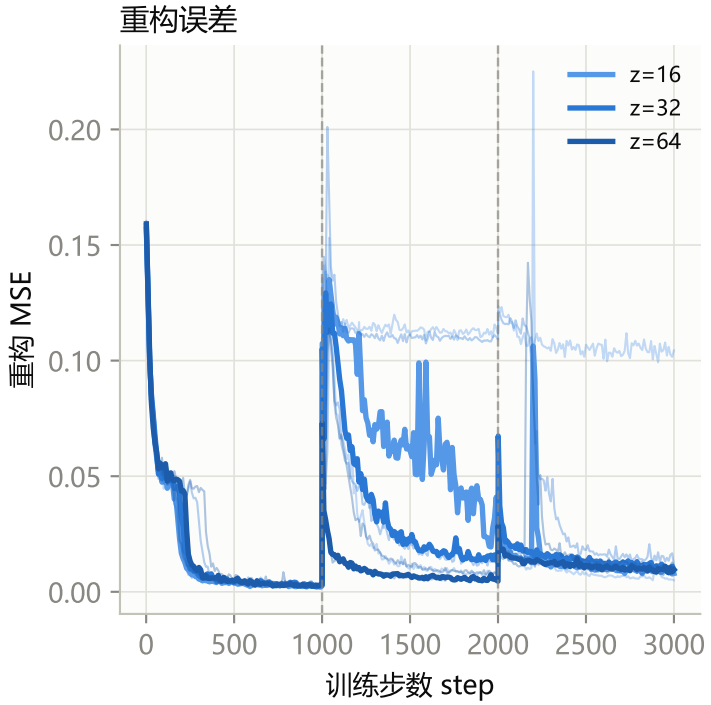
probe → class=0.34

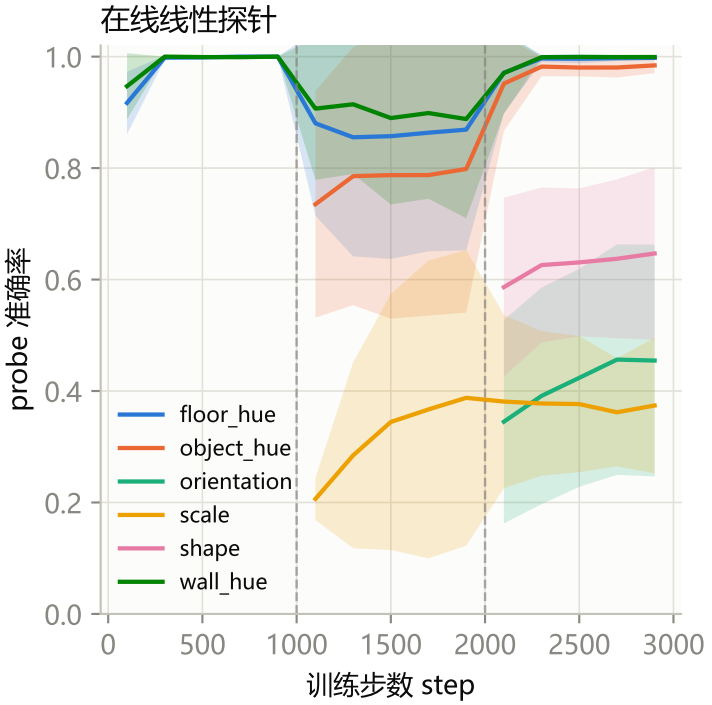
z=64: 信号 0.058 ± 0.0227   MSE 0.0209   KL 6.75   spike_rank 3.0

probe → class=0.37

3D Shapes


残差谱信号
z=16
z=32
z=64
Xi-B / Psi
训练步数 step


重构误差
z=16
z=32
z=64
重构 MSE
训练步数 step


在线线性探针
floor_hue
object_hue
orientation
scale
shape
wall_hue
probe 准确率
训练步数 step

最终指标（3 个种子均值 ± 标准差）

z=16: 信号 5.06 ± 5.45   MSE 0.0391   KL 2.72e+04   spike_rank 15.3

probe → floor_hue=0.99, object_hue=0.97, orientation=0.23, scale=0.28, shape=0.46, wall_hue=1.00

z=32: 信号 1.92 ± 1.05   MSE 0.0103   KL 7.47   spike_rank 10.0

probe → floor_hue=1.00, object_hue=0.98, orientation=0.47, scale=0.31, shape=0.65, wall_hue=1.00

z=64: 信号 1.38 ± 0.288   MSE 0.0097   KL 7.44   spike_rank 9.7

probe → floor_hue=1.00, object_hue=1.00, orientation=0.67, scale=0.53, shape=0.83, wall_hue=1.00

结论与注意事项

核心观察

- controlled：Psi 稳定在高值（≈18–19），三个种子、四个 latent 维度之间一致，重构 MSE 最低（≈0.003）。
- dSprites：Xi-B ≈ 0（9 个 run 仅 1 个出现 0.023 的微弱信号），无超边缘谱质量；probe 中 shape 显著高于机会（0.49 vs 0.33），orientation 处于机会水平（0.02 vs 0.025）。
- CIFAR / CIFAR-C：Xi-B 弱但非零（≈0.03–0.09），spike_rank 2–4；class probe ≈0.32（机会 0.10）。
- 3D Shapes：Xi-B 中等（≈1.1–3.4），但存在训练不稳定 —— seed2/z16 出现 KL≈8.1e4、Xi-B≈12.8 的发散 run，seed1/z16 KL≈89、seed1/z32 Xi-B≈3.4 亦偏高。

方法学提醒

- 四组均使用同一 Xi-B 信号：controlled 的 xi_pw 与其余三组的 xi_b 为同一信号的不同命名，仅在 d、W、阈值参数化上略有差异。
- 3D Shapes 的发散 run 会抬高中位数/均值，报告均值时需结合单个 seed 判断；建议在正文中标注训练失败样本。
- dSprites orientation 探针接近机会水平，应作为「弱可解因子」而非信号证据。

本报告基于 2026-08-25 同步的主训练结果；不含 I1–I4 干预、checkpoint 与 parent residual chunk。